

סיכום - EM

23 ביולי 2026

גיא יער-און

נתונות לנו n נקודות - $x_1, \dots, x_n \in \mathbb{R}^d$. כשמסתכלים על נקודות אלו רואים שהגישו גושים - הנקודות הגיעו מכמה אוכלוסיות שונות אך אף אחד לא סיפר לנו איזו נקודה שייכת לאיזו אוכלוסייה. זו בעיית Clustering. K-means אנו יודעים שכל נקודה משויכת באופן קשה לאשכול מסוים. אך מה עם נקודה שיושבת באמצע, בין שני גושים? הגיוני יותר לומר - היא שייכת לאשכול 1 בהסתברות 0.55 ובהסתברות 0.45 לאשכול 2. בשביל זה - צריך מודל הסתברותי של איך נוצרו הנתונים. זהו מודל EM/

נניח כי הטבע מייצר כל נקודה בתהליך דו שלבי. שלב א': הטבע מטיל קובעיה עם K פאות ובוחר אשכול, הקוביה לא הוגנת. ההסתברות לבחור באשכול k היא $\pi_k = \Pr[z = k]$. את תוצאת ההטלה מסמנים $z_i \in \{1, \dots, K\}$. שלב ב': בהינתן שנבחר אשכול k באמת, הנקודה נדגמת מגאוסיאן של אותו אשכול. $x_i \sim N(\mu_k, \Sigma_k)$. הנקודה x_i - אותה אנו רואים. אך תוצאת ההטלה z_i - איזה אשכול יצר את ההטלה, נשארת נסתרת מאיתנו. לכן z_i נקרא משתנה חבוי - משתנה שקיים בסיפור שאנו מספרים, אך לא נצפה בפועל. אילו מיישהו היה מגלה לנו את כל ה- z_i , הבעיה הייתה הופכת לטריוויאלית: היינו מחשבים ממוצע ושונות לכל קבוצה בנפרד. כל הקושי נובע מכך ש- z_i חסרים. על מנת להמחיש את הבעיה בצורה טובה יותר - נניח שאנו נכנסים לאולם עם 1000 אנשים. קיבלנו רשימה של 1000 מספרים (x_i) - אנו יודעים שבאולם היו גם גברים וגם נשים, והתפלגות הגברים בגובהם שונה מזו של הנשים. אבל ברשימתנו מספרים בלבד - אף אחד לא כתב ליד כל גובה אם הוא של גבר או אישה. ה- z_i זו למעשה העמודה החסרה הזו - לכל נקודה x_i ישנו z_i - התשובה לשאלה "מאיזו אוכלוסיה (גברים נשים) הגיע האדם הזה?". אנו לא רואים את המשתנה הזה, לכן הוא נחשב לחבוי. זו "עמודה" בטבלה שמישהו מחק. לכן, הפרמטרים של המודל הם תמיד

$$\theta = (\mu_1, \dots, \mu_k, \mu_1, \dots, \mu_k, \Sigma_1, \dots, \Sigma_k)$$

אם אנו לא יודעים איזה אשכול יצר כל נקודה, מהי הצפיפות הכוללת של x ? ובכן, לפי הנוסחה של ההסתברות השלמה מתקיים תמיד כי

$$P(x) = \sum_{k=1}^K \Pr(z = k) \Pr(x|z = k)$$

מזג את כל התרחישים האפשריים של מי יצר את הדגימה x . באופן שקול, לפי המשקלים π_k נקבל:

$$\Pr(x_i) = \sum_{k=1}^K \pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)$$

(שכן בהינתן שאנו יודעים כבר מהיכן הגענו, זה גאוסיאן). המטרה שלנו - למצוא את θ לעיל שממקסם את Log-likelihood של כל הדטה. כלומר:

$$\ell(\theta) = \sum_{i=1}^n \log(\Pr(x_i)) = \sum_{i=1}^n \log \left(\sum_{k=1}^K \pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k) \right)$$

אי אפשר לגזור את זה ולהשוות לאפס. כי סכום של Log לא מתפרק יפה. הפונקציה לא קמורה - אין פתרון אנליטי סגור ולכן יש להשתמש בשיטה איטרטיבית.

כל אלגוריתם EM (לא רק לגאוסיאנים) מורכב מזוג שלבים.

שלב E

בשלב זה הפרמטרים הנוכחיים קבועים $\theta^{(t)} = (\pi^{(t)}, \mu^{(t)}, \Sigma^{(t)})$. לכל נקודה x_i ולכל אשכול k אנו שואלים - בהינתן שראיתי את הנקודה הזו, מה ההסתברות שדווקא האשכול k יצר אותה? (אנחנו הרי כל הזמן מעדכנים את הנתונים של הגאוסיאנים). זו למעשה האחריות של אשכול k על נקודה x_i . האחריות היא:

$$\gamma_{ik} = \Pr(z_i = k | x_i) = \frac{\Pr(x_i | z_i = k) \Pr(z_i = k)}{\Pr(x_i)} = \frac{\Pr(x_i | z_i = k) \Pr(z_i = k)}{\sum_{j=1}^K \Pr(z_i = j) \cdot \Pr(x_i | z_i = j)} = \frac{\pi_k \cdot \mathcal{N}(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(x_i | \mu_j, \Sigma_j)}$$

זהו בעצם השלב של מילוי המידע החסר. במקום לנחש ערך אחד ל z_i אנו מחזיקים את כל ההתפלגות שלו.

שלב M

בשלב זה אנחנו מקבעים את האחריות γ_{ik} לכל נקודה x_i ולכל מחלקה k . אנחנו הולכים לעדכן את הפרמטרים $\theta^{(t+1)}$ כך שימקסמו את הנראות.

א. ראשית, לכל k מעדכנים את הממוצע:

$$\mu_k = \frac{\sum_{i=1}^n \Pr(z_i = k | x_i) x_i}{\sum_{i=1}^n \Pr(z_i = k | x_i)} = \frac{\sum_{i=1}^n \gamma_{ik} x_i}{\sum_{i=1}^n \gamma_{ik}}$$

ב. לכל k מעדכנים את מטריצת השונות המשותפת:

$$\Sigma_k = \frac{\sum_{i=1}^n \Pr(z_i = k | x_i) (x_i - \mu_k)(x_i - \mu_k)^T}{\sum_{i=1}^n \Pr(z_i = k | x_i)} = \frac{\sum_{i=1}^n \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^T}{\sum_{i=1}^n \gamma_{ik}}$$

בעצם כמה נקודות של האשכול מפורזות סביב מרכזו.

ג. בסוף, לכל k מעדכנים את משקולות התערובת:

$$\Pr(z = k) = \frac{1}{n} \sum_{i=1}^n \Pr(z_i = k | x_i) = \frac{1}{n} \sum_{i=1}^n \gamma_{ik}$$