

# סיכום למידת מכונה - תשפ"ו 2026

16 במרץ 2026

גיא יער-און

הסיכום נכתב במהלך סמסטר ב' תשפ"ו (2026), ומבוסס על הרצאותיהם של פרופסור גל צצ'יק, ד"ר אורי שוהם וד"ר אורן גליקמן, לכן יתכן שנפלו טעויות בסיכום, כך שהשימוש בו על אחריותכם בלבד.

## תוכן עניינים

|   |                         |    |
|---|-------------------------|----|
| 1 | הרצאה 1                 | 1  |
| 1 | 1.1 רקע מתמטי לקורס     |    |
| 6 | 1.2 הגרדיאנט (Gradient) |    |
| 8 | 2 הרצאה 2               | 2  |
| 8 | 3 הרצאה 3               | 3  |
| 8 | 4 הרצאה 4               | 4  |
| 8 | 5 הרצאה 5               | 5  |
| 8 | 6 הרצאה 6               | 6  |
| 8 | 7 הרצאה 7               | 7  |
| 8 | 8 הרצאה 8               | 8  |
| 8 | 9 הרצאה 9               | 9  |
| 8 | 10 הרצאה 10             | 10 |
| 8 | 11 הרצאה 11             | 11 |

## 1 הרצאה 1

### 1.1 רקע מתמטי לקורס

**הגדרה 1.** תהי  $A \in \mathbb{R}^{d \times d}$ . הוקטורים  $v \in \mathbb{R}^d$   $0 \neq v$  כך שהפעלת  $A$  עליהם לא תשנה את הכיוון שלהם נקראים **וקטורים עצמיים**. כלומר, מתקיים  $Av = \lambda v$ ,  $\lambda \in \mathbb{C}^d$  נקרא **ערך עצמי** ול  $\frac{v}{\|v\|}$  נקרא וקטור עצמי המתאים ל  $\lambda$ .

הערה 2. תמיד ננרמל את הוקטורים העצמיים.

הערה 3. בפועל, וקטור עצמי הוא וקטור שהפעלת המטריצה עליו רק משנה את גודל הוקטור, ולא את הכיוון. המטריצה משנה את הגודל בהתאם ל  $\lambda$ , הערך העצמי.

הערה 4. באופן כללי: כאשר מטריצה  $A$  פועלת על וקטור  $v$ , מתקבל הוקטור  $Av$ .  $A$  משנה את  $v$  באופן לינארי: סיבוב + הזזה.

**משפט 5.** תהי  $A \in \mathbb{R}^{d \times d}$  סימטרית. ויהי  $\lambda$  ע"ע של  $A$ . אזי,  $\lambda$  בהכרח ממשי.

הערה 6. לכל מטריצה  $A \in \mathbb{R}^{d \times d}$  ישנם  $d$  ע"ע מעל  $\mathbb{C}$  (הם לא בהכרח שונים זה מזה, ויכולים להיות מרוכבים).

**הגדרה 7.** המכפלה הסקלרית הסטנדרטית בהינתן  $v_1 = (x_1, \dots, x_n), v_2 = (y_1, \dots, y_n) \in \mathbb{R}^n$  מוגדרת כך:

$$\langle v_1, v_2 \rangle = v_1^T v_2 = \sum_{i=1}^n x_i y_i$$

**הגדרה 8.** יהיו שני וקטורים  $v, u \in \mathbb{R}^n$ .

א. נאמר כי  $u, v$  הם **אורתוגונליים** אם, ורק אם  $\langle v, u \rangle = v^T u = 0$   
ב. נאמר כי  $u, v$  הם **אורתונורמליים** אם הם אורתוגונליים וגם  $\sum_{i=1}^n v_i^2 = 1$   $\forall v : \|v\| = \sqrt{v^T v}$

**משפט 9.** תהי  $A \in \mathbb{R}^{d \times d}$  סימטרית, ויהיו  $v_1, v_2 \in \mathbb{R}^d$  ו"ע השייכים לע"ע המתאימים  $\lambda_1 \neq \lambda_2$ . אזי,  $v_1$  אורתוגונליים (ולכן אורתונורמליים) זה לזה.  
**הוכחה:** מתקיים  $Av_1 = \lambda_1 v_1$  ו- $Av_2 = \lambda_2 v_2$  ולכן:

$$\lambda_2 v_1^T v_2 = v_1^T \lambda_2 v_2 = v_1^T A v_2 = v_1^T A^T v_2 = (A v_1)^T v_2 = (\lambda_1 v_1)^T v_2 = \lambda_1 v_1^T v_2$$

$$\implies (\lambda_1 - \lambda_2) v_1^T v_2 = 0$$

כיוון ש- $\lambda_1 \neq \lambda_2$  הרי ש- $\lambda_1 - \lambda_2 \neq 0$  ולכן  $v_1^T v_2 = 0$ , כלומר  $\langle v_1, v_2 \rangle = 0$ , ולכן  $v_1, v_2$  אורתוגונליים. כנדרש.

■

**משפט 10.** תהי  $A \in \mathbb{R}^{d \times d}$  סימטרית. אזי,

א.  $A$  לכסינה.

ב. קיים לה בסיס אורתונורמלי של ו"ע של  $\mathbb{R}^d$ .

**משפט 11.** תהי  $A \in \mathbb{R}^{d \times d}$  סימטרית בעלת הע"ע  $\{\lambda_i\}_{i=1}^n$  כך ש- $\lambda_i \geq 0, \forall 1 \leq i \leq n$ , אזי לכל וקטור  $z \in \mathbb{R}^d$  מתקיים  $z^T A z \geq 0$ .  
**הוכחה:**  $A$  סימטרית ולכן קיים לה בסיס אורתונורמלי של וקטורים עצמיים (לפי משפט לעיל), נסמנו  $\{v_1, \dots, v_d\}$ . מכאן, כל וקטור  $z$  ניתן לכתוב כצירוף לינארי של הו"ע כך:  $z = \sum_{i=1}^d c_i v_i$ , באשר  $\{c_i\}_{i=1}^d$  המקדמים. כעת:

$$Az = A \times \sum_{i=1}^d c_i v_i = \sum_{i=1}^d c_i \times A v_i = \sum_{i=1}^d c_i \lambda_i v_i$$

כעת, נעבור לביטוי  $z^T A z$ :

$$z^T A z = \left( \sum_{i=1}^d c_i v_i \right)^T \left( \sum_{j=1}^d c_j \lambda_j v_j \right) \implies \sum_{i=1}^d \sum_{j=1}^d c_i c_j \lambda_j (v_i^T v_j)$$

לפי הגדרת בסיס אורתונורמלי, אם  $i \neq j$  הרי ש- $v_i^T v_j = 0$  ואחרת  $v_i^T v_i = 1$  (נורמלי). כלומר, כל האיברים בהם  $i \neq j$  מתאפסים ונשאר עם האיברים בהם  $i = j$ , ולכן:

$$\implies \sum_{i=1}^d c_i^2 \lambda_i \geq 0$$

שכן,  $\{\lambda_i\}_{i=1}^n \geq 0$ , ולכן סה"כ קיבלנו  $z^T A z \geq 0$ , כנדרש.

■

**הגדרה 12.** תהי  $A \in \mathbb{R}^{d \times d}$ . אזי,

1. נאמר כי  $A$  היא  $PSD$  (Positive Semi Definite) אם לכל  $z \in \mathbb{R}^d$  מתקיים  $z^T A z \geq 0$
2. נאמר כי  $A$  היא  $PD$  (Positive Definite) אם לכל  $z \in \mathbb{R}^d$  מתקיים  $z^T A z > 0$

**משפט 13.** תהי  $A \in \mathbb{R}^{d \times d}$  סימטרית. אזי, כל הע"ע של  $A$  הם אי שליליים אם"מ  $A$  היא  $PSD$ . בדומה, כל הע"ע של  $A$  הם חיוביים ממש אם"מ  $A$  היא  $PD$ .  
**הוכחה:**

$\Leftarrow$  לפי משפט 10.

$\Rightarrow$  יהי  $\lambda$  ע"ע עם ו"ע תואם לו  $v$  המקיים  $\|v\| = 1$  (מנורמל). אזי,

$$0 \leq v^T A v = v^T \lambda v = \lambda v^T v = \lambda \|v\|^2 = \lambda \cdot 1 = \lambda$$

כנדרש.

■

14.  $\hat{n}$  ÷ מסקנה מפשט 13: מטריצת PSD היא גם סימטרית, וגם כל הערכים העצמיים שלה אי שליליים.

15.  $\hat{a}$  תהי מטריצה  $A \in \mathbb{R}^{n \times n}$ . נאמר כי  $A$  אורתוגונלית אם  $A^T A = A A^T = I$ .

16.  $\hat{a}$  בפועל, במטריצה אורתוגונלית הכוונה כי כל זוג שורות ועמודות במטריצה הם אורתוגונליים זה לזה ואורתונורמליים (מאונכים, בגודל וקטור יחידה).

17. הערה. אם נפעיל וקטור על מטריצה אורתוגונלית וגם PSD - מה יקרה? נזכר כי הע"ע של מטריצה אורתוגונלית הם  $\pm 1$ . כיוון שהיא PSD, אזי רק 1 הוא ערך עצמי. לכן לא יקרה כלום.

18. משפט (כלל בייס). יהיו  $A, B$  זוג מאורעות. אזי,  $Pr(A|B) = \frac{Pr(B|A)Pr(A)}{Pr(B)}$

19. הגדרה. יהיו 2 משתנים מקריים,  $X$  ו- $Y$ . כך ש- $X$  מקבל ערכים  $x_1, \dots, x_k$  עם ההסתברות  $Pr(X = x_i)$  ו- $Y$  מקבל ערכים  $y_1, \dots, y_k$  עם ההסתברות  $Pr(Y = y_i)$ . נגדיר את ההתפלגות המשותפת שלהם  $Pr(X = x_i, Y = y_i)$ . נוכל להכליל זאת עבור  $d$  משתנים מקריים  $\{X_i\}_{i=1}^d$ , כך שכל  $X_i$  מקבל ערכים  $X_i^1, \dots, X_i^{k_i}$  וההתפלגות המשותפת שלהם הינה:

$$Pr(X_1 = x_1, \dots, X_d = x_d)$$

כמו כן, נוכל להגדירו כמשתנה מקרי יחיד רב ממדי, וקטור  $X = (X_1, \dots, X_d)$  ולשאול מתי הוא מקבל את הערך  $(x_1, \dots, x_d)$ .

20. הגדרה. נגדיר את התוחלת של משתנה מקרי רב ממדי להיות וקטור רב ממדי של התוחלות כך:

$$\mu = \mathbb{E}[X] = (\mathbb{E}[X_1], \dots, \mathbb{E}[X_d])$$

21. הגדרה. יהיו  $X, Y$  זוג משתנים מקריים. נגדיר את Covariance שלהם להיות השונות המשותפת שלהם, בצורה הבאה:

$$Cov(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

מדד זה בודק כמה ישנו קשר בניהם, בפרט אם  $Cov(X, Y) > 0$  אזי ישנו קשר חיובי בין השניים (עולים יחד), אם  $Cov(X, Y) < 0$  אזי ישנו קשר שלילי בין השניים (אחד עולה, השני יורד) ואם  $Cov(X, Y) = 0$  אזי אין קשר לינארי בניהם.

22. משפט. כל ההגאים מתקיימים:

$$Cov(X, X) = Var(X) \quad \text{א.}$$

$$Cov(X, Y) = Cov(Y, X) \quad \text{ב.}$$

$$Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y) \quad \text{ג.}$$

$$\text{ד. אם } X, Y \text{ ב"ת אזי הם בלתי מתואמים.}$$

23. הגדרה. נגדיר את מטריצת Covariance באופן הבא:

$$\begin{pmatrix} Cov(X, X) & Cov(X, Y) \\ Cov(Y, X) & Cov(Y, Y) \end{pmatrix}$$

ונבחין כי היא מטריצה סימטרית.

24. הגדרה. יהי  $X = (X_1, \dots, X_d)$  משתנה מקרי רב ממדי, נגדיר את מטריצת Covariance כך:

$$\Sigma = Cov(X) = \begin{pmatrix} Cov(X_1, X_1) & \dots & \dots & Cov(X_1, X_d) \\ & Cov(X_2, X_2) & & \\ \vdots & & \ddots & \vdots \\ Cov(X_1, X_{d-1}) & \dots & & Cov(X_d, X_d) \end{pmatrix} = \mathbb{E}[(X - \mathbb{E}[X])(X - \mathbb{E}[X])^T]$$

25. הערה. לכל  $i, j \in [n]$  מתקיים כי  $\Sigma_{ij} = Cov(X_i, X_j)$  כאשר בתא זה של המטריצה ישנו ערך Covariance בין שני המשתנים.

הערה 26. המטריצה  $\Sigma$  היא מטריצה סימטרית, לכן היא לכסינה אורתוגונלית, כמו כן, המטריצה היא  $PSD$  ולכן כל הע"ע שלה הם אי שליליים לפי משפט שראינו קודם.

**משפט 27.** מטריצת  $\Sigma$  היא  $PSD$ , כלומר לכל וקטור  $z \in \mathbb{R}^d$  שונה מאפס מתקיים  $z^T \Sigma z \geq 0$ .  
הוכחה:

$$z^T \Sigma z =_{def} z^T \mathbb{E}[(X - \mu)(X - \mu)^T] z$$

כעת, כיוון ש  $z$  הוא וקטור קבוע, הרי מתקיים עבור קבוע  $\mathbb{E}[aX] = a\mathbb{E}[X]$  ותכונה זו נכונה גם עבור וקטור קבוע, ולכן נוכל להכניסו:

$$= \mathbb{E}[z^T (X - \mu)(X - \mu)^T z]$$

נבחין כי  $z^T (X - \mu)$  הוא מכפלה סקלרית (וקטור שורה, כפול וקטור עמודה), לכן תוצאתו סקלר. הביטוי השני, הוא בדיק טרנספוז של סקלר זה. כיוון שטרנספוז של סקלר שווה לסקלר עצמו, הרי שנוכל לכתוב כי:

$$= \mathbb{E}[(z^T (X - \mu))(z^T (X - \mu))^T] = \mathbb{E}[(z^T (X - \mu))^2] \geq 0$$

שהרי המעבר האחרון נובע מכך שאם  $m$  הוא אי שלילי, גם התוחלת שלו היא אי שלילי. כנדרש. ■

**הגדרה 28.** יהי  $X \sim N(\mu, \sigma^2)$  משתנה מקרי גאוסיאני (נורמלי), אזי פונקציית הצפיפות שלו מקיימת:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2} \cdot \left(\frac{x-\mu}{\sigma}\right)^2}$$

**הגדרה 29.** יהי  $X$  וקטור רב ממדי, כך ש  $X \in \mathbb{R}^d$ , המתפלג גאוסיאני  $X \sim N(\mu, \Sigma)$ , אזי פונקציית הצפיפות שלו מקיימת:

$$f(x) = \frac{1}{(2\pi)^{\frac{d}{2}} \sqrt{\det(\Sigma)}} e^{-\frac{1}{2} \cdot (x-\mu)^T \cdot \Sigma^{-1} \cdot (x-\mu)}$$

באשר  $x$  הוא וקטור הקלט,  $\mu$  הוא וקטור התוחלת,  $\Sigma$  היא מטריצת ה  $Covariance$  (קובעת את "צורת" הפעמון),  $\det(\Sigma)$  היא הדטרמיננטה של המטריצה. הביטוי במעריך מחליף את הריבוע בנוסחה המקורית, והוא מודד כמה רחוק  $x$  מהמרכז  $\mu$ , אך הוא מתחשב ב  $Covariance$ . מרחק זה נקרא Mahalanobis Distance.

הערה 30. מאוד חשוב לשים לב - משתנה רב ממדי מתפלג נורמלי כאשר  $\Sigma$  מייצגת את השונות, נבחין כי למשתנה רב ממדי אין שונות כערך מספרי בודד, אלא מטריצת  $Covariance$  שעל האלכסון מייצגת את השונות של הערכים  $\{X_i\}_{i=1}^d$ .


ישנם כמה מקרים פרטיים שנרצה לדון בהם:

1. **מקרה ראשון** -  $\Sigma = I$ : במקרה זה יתקיים,

$$f(x) = \frac{1}{(2\pi)^{\frac{d}{2}}} e^{-\frac{1}{2} \cdot \|X - \mu\|^2}$$

כאן כל השונות שוות לאחד, וכן כל זוג מימדים  $x_i \neq x_j$  בלתי מתואמים, כלומר  $Cov(X_i, X_j) = 0$ . לבסוף, קיבלנו כי ההסתברות של הוקטור הנ"ל תלויה אך ורק במרחק הגאומטרי הישיר שלה מהמרכז  $(\mu)$ . יש צפיפות גבוהה מאוד סביב התוחלת, ואם נחפש את כל הנקודות שיש להן את אותה הסתברות נקבל את המשוואה  $\|X - \mu\|^2 = c$  באשר במרחב דו ממדי מדובר במעגל, ובמרחב רב ממדי על כדור.

**לדוגמה:** נקודות שנלקחות מתוך התפלגות המקיימת  $\Sigma = I$ , ענן הנקודות נראה כמו עיגול סימטרי, הסיבה היא כי על האלכסון יש רק 1 ולכן השונות של  $x$  שווה בדיק לשונות של  $y$ : הפיזור לגובה שווה לפיזור לרוחב. כיוון שהערכים מחוץ לאלכסון הם אפס, אין קשר בין המשתנים, לכן הם בלתי מתואמים ולכן ענן הנקודות לא נוטה באלכסון. כמו כן, רוב הנקודות קרובות ל  $(0,0)$ , כיוון שכאן מתקיים  $\mu = (0,0)$ .



2. מקרה שני -  $\Sigma$  היא מטריצה אלכסונית: כלומר:  $\Sigma = \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ \vdots & \sigma_2^2 & & \vdots \\ 0 & & \ddots & 0 \\ 0 & \dots & 0 & \sigma_d^2 \end{pmatrix}$  נפתח אלגברית מעט:

$$f(x) = \frac{1}{(2\pi)^{\frac{d}{2}} \sqrt{\det(\Sigma)}} e^{-\frac{1}{2} \cdot (x-\mu)^T \cdot \Sigma^{-1} \times (x-\mu)} = \frac{1}{(2\pi)^{\frac{d}{2}} \sqrt{\prod_{i=1}^d \sigma_i^2}} e^{-\frac{1}{2} \cdot (x-\mu)^T \cdot \begin{pmatrix} \frac{1}{\sigma_1^2} & 0 & \dots & 0 \\ \vdots & \frac{1}{\sigma_2^2} & & \vdots \\ 0 & & \ddots & 0 \\ 0 & \dots & 0 & \frac{1}{\sigma_d^2} \end{pmatrix} \times (x-\mu)}$$

$$= \prod_{i=1}^d \frac{1}{\sqrt{2\pi\sigma_i^2}} \cdot \exp\left(-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}\right)$$

נתעכב להסביר את החלק הכי פחות טריוואלי, המעריך. הרי  $x - \mu$  הוא וקטור, נוכל לסמן את ערכיו על מנת שיהיו לנו חיים קלים ע"י

$$\{x_i - \mu_i\}_{i=1}^d. \text{ מכאן, } \begin{pmatrix} \frac{1}{\sigma_1^2} & 0 & \dots & 0 \\ \vdots & \frac{1}{\sigma_2^2} & & \vdots \\ 0 & & \ddots & 0 \\ 0 & \dots & 0 & \frac{1}{\sigma_d^2} \end{pmatrix} \times (x - \mu) = \begin{pmatrix} \frac{x_1 - \mu_1}{\sigma_1^2} \\ \vdots \\ \frac{x_d - \mu_d}{\sigma_d^2} \end{pmatrix},$$


שמוקבל את הערכים  $\{x_i - \mu_i\}_{i=1}^d$ , מכאן מדובר במכפלה סקלרית:

$$(x_1 - \mu_1, \dots, x_d - \mu_d) \times \begin{pmatrix} \frac{x_1 - \mu_1}{\sigma_1^2} \\ \vdots \\ \frac{x_d - \mu_d}{\sigma_d^2} \end{pmatrix} = \prod_{i=1}^d \frac{(x_i - \mu_i)^2}{\sigma_i^2}$$

לאחר מכפלה ב  $-\frac{1}{2}$ , מקבלים את הדרוש.

שוב, תהיה צפיפות סביב  $\mu$  גבוהה מאוד, אך הפעם בודו מימד מדובר בצורת אליפסה (ולא במעגל) וברב מימד צורות מעניינות אף יותר ככל שהמימד ימשיך לגדול.

**דוגמה:** כאן, אכן מדובר במטריצה אלכסונית. בדוגמה משמאל נראה כי שונות  $x$  היא 2, ושונות בציר ה  $y$  היא 1 ולכן ציר ה  $x$  נראה מתוח יותר לצדדים וקיבלנו אליפסה אופקית. בדוגמה מימין, זה בדיוק הפוך, קיבלנו אליפסה אנכית כיוון שהשונות בציר ה  $y$  גדולה מהשונות בציר ה  $x$ .



$$\Sigma = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \quad \Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$$

**משפט 31.** יהי  $X = (X_1, \dots, X_d)$  משתנה מקרי רב ממדי גאוסיאני  $X \sim N(\mu, \Sigma)$ . אזי,  $X_i | X_j$  גאוסיאן (כלומר, גם אם יודעים ערך של אחד מ- $\{X_i\}_{i=1}^d$  אזי עדיין המשתנה הרב ממדי ממיד קטן יותר הוא גאוסיאן, וכן  $\int_{-\infty}^{\infty} f_X(x_1, \dots, x_d) dx_1$  גאוסיאן גם כן).

**משפט 32.** אם מטריצת  $\Sigma$  Covariance היא מטריצה אלכסונית (כלומר לכל  $i \neq j$  מתקיים  $Cov(X_i, X_j) = 0$ ) אזי  $\{X_i\}_{i=1}^n$  הם ב"ת.

הערה 33. לא כמעט אך לשים לב: כל תזוזה לינארית (כולל הכפלה במטריצה וכו') של גאוסיאן היא גאוסיאן.

## 1.2 הגרדיאנט (Gradient)

הערה 34. מהו הגרדיאנט? מדובר בוקטור, ש"זוכר" את כל הנגזרות החלקיות של פונקציה בכמה משתנים. במקום להסתכל רק על כיוון אחד, הגרדיאנט מייצג את השיפוע של הפונקציה בכל הכיוונים בבת אחת. הוא אומר לנו באיזה כיוון הפונקציה עולה הכי מהר ובאיזו עוצמה. ופורמלית:

**הגדרה 35.** תהי פונקציה  $f(x_1, x_2, \dots, x_d)$  המוגדרת בתחום  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ . נגדיר את הגרדיאנט של  $f$  כך:

$$\nabla f(x) = \left[ \frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_d} \right]$$

**הגדרה 36.** תהי  $f$  פונקציה, נגדיר את **קצב השינוי של הפונקציה**  $f$  בנקודה  $x$  לאורך כיוון  $u$  **כנגזרת הכיוונית** של  $f$  בכיוון  $u$  (כאשר  $u$  הוא וקטור יחידה כלומר  $\|u\| = 1$ ) כך:

$$D_u f(x) = \lim_{h \rightarrow 0} \frac{f(x + hu) - f(x)}{h}$$

**משפט 37.** תהי  $f: \mathbb{R}^d \rightarrow \mathbb{R}$  פונקציה גזירה בנקודה  $x \in \mathbb{R}^d$ . אזי, קצב השינוי של הפונקציה  $f$  בנקודה  $x$  בכיוון וקטור יחידה  $u$  הוא מקסימלי כאשר  $u$  בכיוון הגרדיאנט.

**הוכחה:** תהי  $f$  פונקציה גזירה, אזי הקירוב עבורה מסדר ראשון הינו:

$$f(x + hu) \approx f(x) + \nabla f(x) \cdot (hu) + \varepsilon(h)$$

כאשר  $\varepsilon(h)$  מסמלת שארית ששואפת לאפס כאשר  $h \rightarrow 0$ . מכאן, נציב בהגזרת הנגזרת הכיוונית:

$$D_u f(x) = \lim_{h \rightarrow 0} \frac{f(x) + \nabla f(x) \cdot (hu) + \varepsilon(h) - f(x)}{h} = \lim_{h \rightarrow 0} \frac{\nabla f(x) \cdot (hu) + \varepsilon(h)}{h} =$$

$$\lim_{h \rightarrow 0} (\varepsilon + \nabla f(x) \cdot u) = \nabla f(x) \cdot u$$

מסקנה: קצב השינוי של הפונקציה בכיוון  $u$  הוא המכפלה הסקלרית  $\nabla f(x) \cdot u$ . נעזר באי שוויון שורץ:  $a \cdot b \leq \|a\| \cdot \|b\|$  ונקבל:

$$D_u f(x) = \nabla f(x) \cdot u \leq \|\nabla f(x)\| \cdot \|u\|$$

אנו מניחים כי  $u$  וקטור יחידה והרי  $\|u\| = 1$  ומכאן:

$$D_u f(x) \leq \|\nabla f(x)\|$$

כלומר, הערך המקסימלי של  $D_u f(x)$  חסום ע"י  $\|\nabla f(x)\|$  ויש שוויון לפי א"ש שורץ רק כאשר הוקטורים תלויים זה בזה, מכאן: הפונקציה משתנה הכי מהר בכיוון  $\nabla f(x)$ .

**משפט 38.** נגדיר את הפונקציה  $f(x) = x^T x = \|x\|^2$ , אזי  $\nabla f(x) = 2x$ .  
**הוכחה:** נבחין כי אם נסמן  $x = (x_1, \dots, x_d)$  הרי שמתקיים לכל  $1 \leq i \leq d$  כי:

$$\frac{\partial}{\partial x_i} x^T x = \frac{\partial}{\partial x_i} \left( \sum_{j=1}^d x_j^2 \right) = 2x_i$$

$$\nabla f(x) = (2x_1, \dots, 2x_d) = 2x, \text{ ולכן}$$

**הגדרה 39.** מטריצת הסימטרית  $(Hessian)$  היא מטריצה ריבועית שמגדירה את הנגזרות החלקיות מסדר שני. כלומר,

$$H_f = \nabla^2 f = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & & \frac{\partial^2 f}{\partial x_1 \partial x_d} \\ \vdots & & \vdots \\ \frac{\partial^2 f}{\partial x_d \partial x_1} & \dots & \dots & \frac{\partial^2 f}{\partial x_d^2} \end{pmatrix}$$

**משפט 40.** נגדיר את התכנית הריבועית  $f(x) = \frac{1}{2} x^T A x$  כאשר  $A$  היא מטריצה סימטרית ממיד  $d$ . אזי  $\nabla^2 f = A$ .  
**הוכחה:** בשלב ראשון נראה כי:

$$\frac{\partial f}{\partial x_k} \left( \frac{1}{2} \cdot \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j \right) =$$

$$\frac{\partial f}{\partial x_k} \left( \frac{1}{2} \left( \sum_{i,j \neq k} a_{ij} x_i x_j + \sum_{i=k, j \neq k} a_{kj} x_k x_j + \sum_{j=k, i \neq k} a_{ik} x_i x_k + a_{kk} x_k^2 \right) \right) =$$

$$\frac{1}{2} \left( \sum_{j \neq k} a_{kj} x_j + \sum_{i \neq k} a_{ik} x_i + 2a_{kk} x_k \right) = \frac{1}{2} \left( \sum_{i=1}^d a_{ik} x_i + \sum_{j=1}^d a_{ki} x_i \right) = \sum_{i=1}^d a_{ik} x_i = (Ax)_k$$

המעבר \* נכון כיוון ש  $A$  סימטרית ולכן  $a_{ik} = a_{ki}$ . מכאן,

$$\nabla f = \begin{bmatrix} (Ax)_1 \\ (Ax)_2 \\ \vdots \\ (Ax)_d \end{bmatrix} = Ax$$

$$H_f = \nabla^2 f = \frac{\partial^2 f}{\partial x^2} (\nabla f(x)) = \frac{\partial^2 f}{\partial x^2} (Ax) = A, \text{ ומכאן,}$$

**הגדרה 41.** פונקציה היא קמורה אם הקטע שמחבר כל זוג נקודות על גרף הפונקציה נמצא מעל או על הגרף עצמו. פורמלית, לכל  $0 \leq t \leq 1$  ולכל  $x, y$ :

$$f(tx + (1-t)y) \leq tf(x) + (1-t)f(y)$$

הערה 42. אנחנו נעדיף פונקציות הפסד קמורות, כיוון שבהן כל מינימום מקומי הוא בהכרח מינימום גלובלי. כלומר - אם מצאת נקודה בה השיפוע הוא אפס (נקודת מינימום מקומית), היא בהכרח תהיה הנקודה הנמוכה ביותר בכל הפונקציה.

**משפט 43.** תהי  $f$  פונקציה גזירה פעמיים בתחום קמור.  $f$  היא פונקציית קמורה אם ורק אם מטריצת ההסיאן שלה  $H_f(x)$  היא  $PSD$ .

|    |          |
|----|----------|
| 2  | הרצאה 2  |
| 3  | הרצאה 3  |
| 4  | הרצאה 4  |
| 5  | הרצאה 5  |
| 6  | הרצאה 6  |
| 7  | הרצאה 7  |
| 8  | הרצאה 8  |
| 9  | הרצאה 9  |
| 10 | הרצאה 10 |
| 11 | הרצאה 11 |