

למידת מכונה - פתרון מבחנים

28 ביולי 2026

גיא יער-און

במהלך הלמידה למבחן פתיתי את מבחני 2025–2023 של אוניברסיטת בר אילן. אשמח לשתף אתכם את הפתרונות שלי, שכן לחלק מהבחינות אין פתרונות רשמיים. אך, יתכן שנפלו טעויות לכן אין להתייחס לפתרון זה כפתרון רשמי.

1 מבחן 2023 לדוגמה

מודלי תערובת גאוסיאניים (GMM).

א. נתון מערך נתונים ללא תיוג הכולל n דגימות $\{x_1, \dots, x_n\}$ כאשר $x_i \in \mathbb{R}$. ברצונך למדל אותו כתערובת של k רכיבים גאוסיאניים, כך שלכל רכיב יש פרמטרים משלו (π_k, σ_k, μ_k) כך ש $\sum_k \pi_k = 1$. כתוב את פונקציית הנראות של הנתונים בהינתן פרמטרים של המודל. פתרון:

הרי שפונקציית הנראות הינה

$$\Pr(x|\theta) = \prod_{i=1}^n \Pr(x_i|\theta)$$

נזכר שבתערובת גאוסיאנים מתקיים:

$$\Pr(x_i|\theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x_i|\mu_k, \sigma_k)$$

לכן נקבל:

$$\Pr(x|\theta) = \prod_{i=1}^n \sum_{k=1}^K \pi_k \cdot \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{1}{2} \frac{(x_i - \mu_k)^2}{\sigma_k^2}\right)$$

ב. כתוב פסודו קוד של אלגוריתם EM למקסום הנראות מסעיף א'. באופן ספציפי, האלגוריתם שלך צריך לכלול את שלבי העדכון עבור הממוצעים ואת התפלגות הבסיס על פני הרכיבים. הנח כי השונות של כל הרכיבים בעלת ערך קבוע של 1. פתרון: במקרה זה פונקציית הנראות מסעיף א' הופכת להיות

$$\Pr(x|\theta) = \prod_{i=1}^n \sum_{k=1}^K \pi_k \cdot \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(x_i - \mu_k)^2\right)$$

הפסודו כעת:

קלט: מדגם נקודות $\{x_i\}_{i=1}^n$ ומס' K של מחלקות.

- אתחל $\theta^0 = (\pi^0, \mu^0, \sigma^0)$ אקראית.

- חזור עד שהפרמטרים של $\Pr(x|\theta)$ כלומר θ כולם מפסיקים להשתנות:

- $E - step$: סדר את $\theta^{(t)}$. חשב לכל נקודה x_i ולכל מחלקה k את:

$$\gamma_{ik} = \frac{\pi_k^{(t)} \mathcal{N}(x_i|\mu_k^{(t)}, \sigma_k^{(t)})}{\sum_{j=1}^K \pi_j^{(t)} \mathcal{N}(x_i|\mu_j^{(t)}, \sigma_j^{(t)})}$$

(כלומר את רמת האחריות)
 $M - step$: עדכן את הפרמטרים θ^{t+1} באופן הבא:

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{ik} x_i}{\sum_{i=1}^n \gamma_{ik}}$$

$$\pi_k^{(t+1)} = \frac{1}{n} \sum_{i=1}^n \gamma_{ik}$$

נשים לב כי כיוון שהשונות קבועה אין מה לעדכנה.
 ג. הנח כי במהלך איטרציות ה-EM, לאחר חישוב $Pr(Z = z|X = x)$ לוקחים גרסה קשיחה של התפלגות זו שבה הרכיב הסביר ביותר $Z = z$ עבור דגימה מקבל הסתברות של אחד $Pr(Z = z|X = x)$ וכל שאר הערכים של Z מקבלים הסתברות של 0.
 הוכח כי במקרה זה האלגוריתם הופך להיות שקול ל-K-means.
 רמז. דרך אחת על מנת להראות זאת היא להראות שהרכיב z בעל הנראות הלוגריתמית הגבוהה ביותר $Pr(X|Z = z)$ הוא זה שיש לו את המרחק האוקלידי הקטן ביותר $x - \mu_z$.

פתרון:

הרי כי:

$$\gamma_{ik} = \Pr(Z = k|X = x_i)$$

כלומר, אחרי שראינו את x , ההסתברות שהנקודה הגיעה ממחלקה k . נראה כי ב- $K - means$ כל נקודה משויכת למרכז הקרוב ביותר אליה.
 כאן, ל:

$$\arg \max_k \Pr(Z = k|X = x_i)$$

(כלומר לזה עם ההסתברות הגבוהה ביותר להשתייך אליו). נרצה להוכיח:

$$\arg \max_k \Pr(Z = k|X = x_i) = \arg \min_k \|x_i - \mu_k\|^2$$

כעת נעזר ברמז, נסתכל על $\log$ -נראות של

$$\log Pr(X|Z = z) = \log \Pr(x_1, \dots, x_n|Z = z) = \sum_{i=1}^n \log \Pr(x_i|Z = z) =$$

$$\sum_{i=1}^n \ln \left(\frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2} (x_i - \mu_k)^2 \right) \right) = \sum_{i=1}^n \ln \left(\frac{1}{\sqrt{2\pi}} \right) - \frac{1}{2} (x_i - \mu_k)^2$$

$$= \text{const} - \frac{1}{2} \sum_{i=1}^n (x_i - \mu_k)^2$$

כלומר על מנת למקסם זאת יש למזער את $\sum_{i=1}^n (x_i - \mu_k)^2$
 כלומר:

$$\arg \max_z \log Pr(x_1, \dots, x_n|Z = z) = \arg \min_{\mu_z} \sum_{i=1}^n (x_i - \mu_z)^2$$

נשים לב כי באלגוריתם ה- $K - means$ בוחרים את זה שהכי קרוב אליו המרכז כלומר (μ_z) .

כעת בגרסה הקשיחה שהוגדרה אנו מחפשים לכל נקודה את המרכז הספציפי ששייך לה. נראה כי עבור נקודה בודדת על מנת למזער את $(x_i - \mu_z)^2$ אנו בעצם רוצים למזער את $\|x_i - \mu_z\|^2$. כלומר,

$$= \arg \min_{\mu_z} \sum_{i=1}^n \|x_i - \mu_z\|^2$$

והרי, קיבלנו:

$$\arg \max_z \log Pr(x_1, \dots, x_n | Z = z) = \arg \min_{\mu_z} \sum_{i=1}^n \|x_i - \mu_z\|^2$$

כלומר, לכל x_i הרכיב μ_z שיבחר הוא זה שממזער את המרחק האוקלידי ביניהם, ובכך זה בדיוק כפי שעושה אלגוריתם $K - means$.

מודלים לינאריים: פרספטרון.

א. נתון מערך נתונים $\{x_1, \dots, x_n\}$ כך ש $x_i \in \mathbb{R}^d$ עם תוויות $y_i \in \{+1, -1\}$ לכל נקודה. נסח בעיית אופטימיזציה של למידת מסווג לינארי (מודל הפרספטרון) כבעיית מזעור סיכון אמפירי. פתרון:

נגדיר פונקציית $loss$ באופן הבא:

$$\ell(w, x_i, y_i) := \begin{cases} 0 & y_i w^T x_i \geq 0 \\ 1 & o.w \end{cases}$$

ואז ממוצע השגיאות הוא $\frac{1}{n} \sum_{i=1}^n \ell(w, x_i, y_i)$ ובעיית האופטימיזציה היא:

$$\min_w \frac{1}{n} \sum_{i=1}^n \ell(w, x_i, y_i)$$

ב. כתוב אלגוריתם SGD לאופטימיזציה של פרמטרי המודל שהגדרת בסעיף א', השתמש בפונקציית $hinge$. פתרון:

נגדיר את פונקציית הפסד Hinge כך:

$$\ell(w, x_i, y_i) := \begin{cases} 0 & y_i w^T x_i \geq 1 \\ 1 - y_i w^T x_i & o.w \end{cases}$$

והרי נגזרתה:

$$\ell'(w, x_i, y_i) := \begin{cases} 0 & y_i w^T x_i \geq 1 \\ -y_i x_i & o.w \end{cases}$$

לכן נגדיר את האלגוריתם הבא:

$$A(\{(x_i, y_i)\}_{i=1}^n, \ell)$$

א. אתחל w באופן אקראי.

ב. חזור עד שאין שיפור:

ג. בחר דוגמה אקראית (x_i, y_i) מהדטה-סט.

ד. אם $y_i w^T x_i \geq 1$, עבור לאיטרציה הבאה.

ה. אחרת: $w = w + \eta y_i x_i$

ג. התבונן כעת על המקרה בו כל דגימה x בינארית ב $\{+1, -1\}^d$ כאשר d זוגי. סמן ב $x^1, \dots, x^d$ את המאפיינים של דגימה x . התוויות האמיתיות y של דגימה x נקבעת דרך ההקשר הבא:

$$y = \text{sign}(a_1 \text{Xor}(x^1, x^2) + a_2 \text{Xor}(x^3, x^4) + \dots + a_{\frac{d}{2}} \text{Xor}(x^{d-1}, x^d))$$

- הם ערכים ממשיים שאינם ידועים לנו.
 - האם מערך הנתונים ניתן להפרדה לינארית? הוכח.
 - הצע אריקטורת רשת שיכולה לסווג נכון את מערך הנתונים הנ"ל, וניתנת לאימון באמצעות SGD כמו אלגוריתם הפרספטרון בסעיף א'.
- פתרון:
- הדטה סט אינו פריד לינארית. נניח בשלילה שהוא כן, אזי קיים וקטור משקולות w וקבוע b המסווג נכון את הנתונים. נתבונן על המקרה הפשוט בו $d = 2$. אזי,

$$y = \text{sign}(a_1 \text{Xor}(x^1, x^2))$$

ובכן, כאשר $x = (0, 0)$ אזי $\text{Xor}(0, 0) = 0$ ונקבל $\text{sign}(0) = 0$ לכן עבור נקודה זו הסיווג אמור להיות שלילי, כלומר $w_1 \cdot 0 + w_2 \cdot 0 + b = b < 0$.
 כאשר $x = (1, 0)$ נקבל $\text{Xor}(1, 0) = 1$. אזי $\text{sign}(a_1)$. נניח $a_1 > 0$ תמיד [מקרה לגיטימי].
 אזי, הסימן במקרה זה חיובי לכן $w_1 + b > 0$.
 אם $x = (0, 1)$ אותו דבר רק ש $w_2 + b > 0$.
 כעת $(1, 1)$ מסווג ל-0. אבל:

$$w_1 + w_2 + b > -b + -b + b = -b > 0$$

שכן $w_1, w_2 > -b$ וכן $-b > 0$ מהמשוואה הראשונה. כלומר $(1, 1)$ יסווג ל-1, בסתירה.
 כיוון שהראנו מקרה ספציפי $d = 2$ ו $a_1 > 0$ בו אין הפרדה לינארית סה"כ הנתונים לא פרידים לינארית.
 כעת נציג אריקטורה שניתן לאמן איתה:
 נבנה רשת ניורונים עם $\frac{d}{2}$ ניורוני קלט שתחשב את הפונקציות Xor . יהיו

$$O_i = \text{Xor}(X^i, X^{i+1})$$

עבור i אי זוגי ניורוני קלט המחשבים פונקציית Xor בין המשתנים x^i, x^{i+1} . ישנם $\frac{d}{2}$ כאלו.
 מהן יוצאות משקולות $a_1, a_2, \dots, a_{\frac{d}{2}}$ אשר המודל לומד - ומגיעים אל y :
 y הוא ניורון בודד נוסף - הוא מקבל את $a_1, \dots, a_{\frac{d}{2}}$ משוקללים בפונקציות O_i ומחשב פונקצייה לא לינארית - sign .
 כפלט, y פולט את תוצאת הרשת.
 סה"כ רשת זו ניתנת לאימון על המשקולות $a_1, \dots, a_{\frac{d}{2}}$.

2 מועד א' 2023

שאלה 1.

- כתוב פסאודו קוד של אלגוריתם הפרספטרון שהוצג בכיתה. אילו תכונות צריכות להתקיים בנתונים כדי שיובטח שהאלגו' יתכנס?
- כתבו אלגוריתם לאימון מסווג לינארי עם כלל עדכון מבוסס SGD עבור פונקציית מחיר מסוג Hinge Loss בעלת שולי בטחון. מה ההבדל בין אלגו' זה לפרספטרון מסעיף א'?
- כיצד ישתנה האלגוריתם שכתבתם בסעיף ב' אם תשתמשו במומנטום? כתוב פסאודו קוד לאלגו' החדש.

פתרון:

- בהינתן קלט מדגם $\{(x_i, y_i)\}_{i=1}^n$ כך ש $x_i \in \mathbb{R}^d$ וכן $y_i \in \{+1, -1\}$ נגדיר את האלגוריתם הבא:
 $\text{Preceptron}(\{(x_i, y_i)\}_{i=1}^n)$
 - א. אתחל וקטור משקולות $w \in \mathbb{R}^d$ באופן אקראי.
 - ב. חזור עד שכל הדגימות מסווגות נכון:
 - ג. לכל $1 \leq i \leq n$:
 - חזה $\hat{y}_i = \text{sign}(w^T x_i)$.
 - אם $\hat{y}_i \neq y_i$: $w = w + y_i x_i$.
 - ד. החזר את w .
- האלגוריתם מתכנס רק כאשר הנתונים ניתנים להפרדה לינארית. כלומר, זהו המקרה הריאזיבלי. בהכרח קיים וקטור $w \in \mathbb{R}^d$ כך שלכל דוגמה i יתקיים $y_i(w^T x_i) > 0$.
 ב. נזכר כי הגדרת ה Hinge Loss הינה:

$$\ell(w, x_i, y_i) := \begin{cases} 0 & y_i w^T x_i \geq 1 \\ 1 - y_i w^T x_i & y_i w^T x_i < 1 \end{cases}$$

וכן נגזרתה

$$\ell'(w, x_i, y_i) := \begin{cases} 0 & y_i w^T x_i \geq 1 \\ -y_i x_i & y_i w^T x_i < 1 \end{cases}$$

מכאן כי צעד העדכון:

$$w = w - \eta \nabla_w \ell' = w - \eta(-y_i x_i) = w + \eta y_i x_i$$

נגדיר את האלגוריתם באופן הבא.

Precptron-Hinge-Loss $(\{(x_i, y_i)\}_{i=1}^n)$:א. אתחל וקטור משקולות $w \in \mathbb{R}^d$ באופן אקראי.

ב. בצע עד שהמודל מפסיק להשתפר:

- בחר דוגמה מהדטה (x_i, y_i) באופן אקראי.- אם $y_i w^T x_i > 1$, התקדם לאיטרציה הבאה.- אחרת, עדכן: $w = w + \eta y_i x_i$ ג. בסיום, החזר את w .

ההבדלים מסעיף ב': נשים לב כי כאשר $\eta = 1$ כלל העדכון זהה ומדובר באותו אלגוריתם פרט לפספטרון. ההבדל העיקרי הוא שכאן מדובר בצעד עדכון מבוסס SGD, כלומר בכל פעם בוחרים דגימה אחת ומשפרים. באלגוריתם של סעיף א', אנחנו מבצעים זאת כל פעם בלולאה על כל הדגימות יחד. כמו כן, כאן ישנו מרווח שול. גם כאשר הדגימה חוקית אך $y_i w^T x_i \in [0, 1]$ אנחנו מעדכנים. לוקחים מרווח מסוים. ג. נזכר כי גישת המומנטום היא בכל שלב לעקוב אחר המהירות v_t . כלומר מעדכנים את

$$v_t = \gamma v_{t-1} + \eta \cdot \nabla_w L$$

ואז בכל שלב מעדכנים

$$w_{t+1} = w_t - v_t$$

נשים לב כי בכל שלב אם טעינו:

$$v_t = \gamma v_{t-1} + \eta \cdot (-y_i x_i) = \gamma v_{t-1} - y_i x_i \eta$$

כמו כן, γ הוא היפר פרמטר שיקבע מראש. לפיכך נעדכן את האלגוריתם מסעיף ב':Precptron-Momentum $(\{(x_i, y_i)\}_{i=1}^n, \gamma)$:א. אתחל וקטור משקולות $w \in \mathbb{R}^d$ באופן אקראי. אתחל $v = 0$.

ב. בצע עד שהמודל מפסיק להשתפר:

- בחר דוגמה מהדטה (x_i, y_i) באופן אקראי.- אם $y_i w^T x_i > 1$, התקדם לאיטרציה הבאה.

- אחרת, עדכן:

$$1. v = \gamma v - \eta y_i x_i$$

$$2. w = w - v$$

ג. בסיום, החזר את w .

שאלה 2

א. כתוב את בעיית האופטימיזציה של SVM לינארי עם Slack Variables. יש לכלול את כל האילוצים ולהסביר אילו משתנים עוברים אופטימיזציה, מהם הפרמטרים ואילו ערכים כל אלו יכולים לקבל.

ב. עבור בעיית סיווג בינארי, הגדירו את השוליים ρ של מסווג לינארי נתון w . הראה כי בעיית האופטימיזציה הריבועית של SVM שקולה לבעיית מקסום השוליים של מסווג לינארי. ניתן להניח כי הנתונים ניתנים להפרדה לינארית.

ג. נתונה בעיית מסווג כדורי שמוגדרת כך:

בהינתן נק' מרכז $a \in \mathbb{R}^d$ ורדיוס חיובי $r \in \mathbb{R}^+$. המסווג צריך לחזות תיוג $\hat{y} = +1$ אם הדגימה נמצאת בתוך הכדור $\|x - a\| < r$ ויחזה תיוג $\hat{y} = -1$ אחרת. $\|\cdot\|$ מסמל מרחק אוקלידי. יהיו $x_1, \dots, x_n \in \mathbb{R}^d$ דוגמאות עם התיוגים המתאימים $y_1, \dots, y_n \in \{+1, -1\}$. תיוגים יכולים להיות רועשים.

בהינתן דטה מתויג, אנו מעוניינים למצוא את הכדור הקטן ביותר עם מרכז a לא ידוע שיסווג נכון את הנתונים.

נסחו בעיית אופטימיזציה עם אילוצים בסגנון בעיית SVM למציאת המרכז והכדור, יש לאזן בין גודל הכדור ודיוק הסיווג ע"י משתני Slack Variables.

פתרון:

נפתור את א' וב' יחדיו.

נגדיר את בעיית האופטימיזציה של SVM לינארי באופן הבא.
יהי מדגם נתונים $\{(x_i, y_i)\}_{i=1}^n$ כך ש $x_i \in \mathbb{R}^d$ וכן $y_i \in \{+1, -1\}$ לכל i .
נגדיר לכל i את המשתנה $\xi_i \in \mathbb{R}$ להיות $\xi_i \geq 1 - (y_i \cdot (w^T x_i))$ ונגדיר את בעיית האופטימיזציה הבאה:

$$\min_{\xi_1, \dots, \xi_n \in \mathbb{R}, w \in \mathbb{R}^d} \frac{1}{2} \|w\|^2 + C \cdot \sum_{i=1}^n \xi_i$$

המשתנים שעוברים אופטימיזציה הם $\xi_1, \dots, \xi_n, w$. תפקיד C הוא היפר פרמטר שתפקידו לדאוג שקיום הדרישות יענה. אם C נמוך אזי האילוצים יכולים להיות מופרים ואם גבוה אז לא.
בהינתן משוואת ישר $w^T x - b = 0$, השוליים ממנה בטווח של 1 (למשל, אחרי נרמול) מוגדרים להיות המרחק של נקודה מהשוליים לישר. כלומר,

$$\frac{\|w^T x - b\|}{\|w\|} =_* \frac{1}{\|w\|}$$

נגדיר את בעיית מקסום השוליים של מסווג לינארי באופן הבא. אנו מעוניינים

$$\max_{w \in \mathbb{R}^d} \frac{1}{\|w\|} \text{ s.t } \forall i : y_i w^T x_i \geq 1 \equiv \min_{w \in \mathbb{R}^d} \|w\| \text{ s.t } \forall i : y_i w^T x_i \geq 1 \equiv$$

$$\min_{w \in \mathbb{R}^d} \frac{1}{2} \|w\|^2 \text{ s.t } \forall i : y_i w^T x_i \geq 1 \equiv$$

$$\min_{\xi_1, \dots, \xi_n \in \mathbb{R}, w \in \mathbb{R}^d} \frac{1}{2} \|w\|^2 + C \cdot \sum_{i=1}^n \xi_i \text{ s.t } \xi_i = 1 - y_i w^T x_i$$

כנדרש.

ג. למעשה נשים לב כי באופן שקול, נוכל להגדיר שהחזיון:

$$\begin{aligned} -1 \text{ אם } \|x - a\| > r & \text{ כלומר } \|x - a\|^2 \geq r^2 \\ 1 \text{ אם } \|x - a\| < r & \text{ כלומר } \|x - a\|^2 \leq r^2 \\ 0 & \text{ כלומר } \|x - a\|^2 = r^2 \end{aligned}$$

נטען שזה שקול ל:

$$y_i (\|x - a\|^2 - r^2) \leq 0$$

כלומר, נגדיר לכל i את האילוץ $\xi_i \geq y_i (\|x - a\|^2 - r^2)$.
המטרה שלנו היא למזער את גודל הכדור. לשם כך, נצטרך למזער את רדיוס הכדור. כלומר נגדיר את בעיית האופטימיזציה הבאה:

$$\min_{r \in \mathbb{R}^+, \xi_1, \dots, \xi_n \in \mathbb{R}} r^2 + C \sum_{i=1}^n \xi_i \text{ s.t } \xi_i \geq y_i (\|x - a\|^2 - r^2) \forall i$$

שאלה 3.

א. תארו אריכטורה של שכבת קונבולוציה ברשת CNN המיועדת לסיווג תמונות RGB . בתשובתכם התייחסו במפורט למימד המסננים (Filters), כיצד הם מתממשקים עם הקלט וכיצד הם משולבים עם פונקציות האקטיבציה $ReLU$.
ב. בכיתה תיאנרו פונקציית הפסד מסוג MultiClass, $\ell = D_{KL}(t|\hat{y})$, כאשר t היא התפלגות המטרה על פני המחלקות, ו $\hat{y}$ היא ההתפלגות החזויה שלרוב מחושבת עם Softmax. הראו שכאשר התפלגות המטרה היא One-hot-vector (הסתברות של 1 עבור המחלקה הנכונה) מזעור של הלוס הזה שקול למקסימיזציה של הנראות של המחלקה הנכונה.
תזכורת: יהי X משתנה מקרי רנדומי עם הערכים $x_1, \dots, x_k$ ויהיו p, q זוג התפלגויות מעל הערכים הללו. אזי

$$D_{KL}(p||q) = \sum_{j=1}^k Pr(x_j) \cdot \log\left(\frac{Pr(x_j)}{Q(x_j)}\right)$$

ג. מעוניינים לבנות רשת עמוקה שמשפרת את הרזולוציה של תמונות נתונות. עליכם לתאר אריכטורה של רשת עמוקה שמקבלת כקלט תמונות RGB בגודל $100 \cdot 100$ ומוציאה תמונות ברזולוציה $200 \cdot 200$.

- תארו סט של שכבות שבהן תשתמשו
- תנו דוגמאות ספציפיות של מימדי הפילטרים ומספרם
- איך תאמנו את המודל? באיזה לוס תשתמשו? איך תשיגו סט גדול של תמונות מטרה כדי לאמן את המודל? פתרון:

א. למעשה שכבת קונבולוציה ברשת CNN המסווגת תמונות RGB היא כזו מגודל תמונה x, x' אזי $x \times x' \times 3$ כי ישנן 3 שכבות פילטרי צבע. ברשת מסוג זה, אנו משתמשים בפילטרים בגודל למשל k אזי $k \times k \times 3$ שעוברים וסורקים את התמונה. הם עוברים על התמונה (נוכל להחליט שמוסיפים $Padding$ למשל בצדדים) וכן נקבע s Stride כגודל הצעד שבו אנו עוברים. בכל שלב אנחנו סורקים פילטר מסוים בתמונה, הוא סורק את האזור הספציפי $\{x'\}$ שמצא בתמונה והולך לפונקציית $ReLU$ (אקטיביציה לא לינארית!). כך אנחנו ממשיכים להתקדם, באופן של משמאל לימין על גבי התמונה, וכשמגיעים לקצה יורדים מטה בתמונה אם יש וכך מתקדמים על כל התמונה. כתוצאה, מקבלים מפת אקטיביזציה - מפה זו מייצגת את הפילטר. באזורים שבו מצאנו בהסתברות גבוהה יחסית משהו שקשור לפילטר שחיפשנו, אזור זה במפת האקטיביזציה יהיה דולק יחסית וכך לאחר המעבר עם הפילטר על כל התמונה, נוכל לדעת באיזה אזורים בתמונה יש המאפיין שחיפשנו.

ב. נראה כי

$$\min D_{KL}(t||\hat{y}) = \min \sum_{i=1}^k P(y_i) \log \frac{P(y_i)}{\text{softmax}(y_i)} =$$

$$\min \sum_{i=1}^k P(y_i) \cdot \log(P[y_i]) - \log(\text{softmax}(y_i)) =$$

נשים לב שנתון כי יש הסתברות של 1 רק במחלקה הנקודה, נניח שהיא המחלקה i . בשאר זה פשוט יתאפס. לכן נקבל

$$\min P(y_i) \log P(y_i) - \log(\text{softmax}(y_i))$$

נשים לב כי במחלקה הנכונה $P(y_i) = 1$ ולכן $\log(1) = 0$ ולכן נקבל

$$\min -\log(\text{softmax}(y_i)) = \max \log(\text{softmax}(y_i))$$

שאלה 4.

א. כתבו פסאודו קוד עבור אלגוריתם K-means לקיבוץ n דגימות $x_1, \dots, x_n \in \mathbb{R}^d$ אל k קבוצות (קלסטרים) עם צנטרואידים $c_1, \dots, c_k \in \mathbb{R}^d$.

- הוכיחו כי אלגוריתם $kMeans$ מתכנס ע"י כך שתראו שכל צעד עדכון מקטין את סכום העיוותים של כל הדגימות.
- איך ישתנה האלגוריתם מסעיף א' אם היינו רוצים למזער את מרחק L_1 ? כתבו פסאודו קוד עבור מקרה זה.
- תזכורת: מרחק L_1 בין דגימה לבין הצנטרואיד שלה הוא $L_1 = \|x - c\|_1 = \sum_{j=1}^d |x_j - c_j|$ כאשר $|x|$ הערך המוחלט של x .

פתרון:

א. יהיו $x_1, \dots, x_n \in \mathbb{R}^d$ דגימות. נגדיר את האלגוריתם באופן הבא:

$K\text{-means}(S = \{x_i\}_{i=1}^n)$:

א. אתחל k צנטרואידים באופן שרירותי: $c_1, \dots, c_k \in \mathbb{R}^d$.

ב. חזור עד שקיימת איטרציה שבה כל הדגימות נותרו באותו קלסטר ולא השתנו:

- חשב לכל נקודה i את

$$\text{Cluster}(x_i) = \arg \min_{j=1, \dots, k} \|x_i - c_j\|$$

- הגדר את הקלסטרים

$$\forall 1 \leq i \leq k : \text{Cluster}_i = \{x \in S | \text{Cluster}(x) = i\}$$

- הגדר לכל קלסטר $1 \leq i \leq k$:

$$c_i = \frac{1}{|\text{Cluster}_i|} \sum_{x' \in \text{Cluster}_i} x'$$

ג. החזר את הקלסטרים $c_1, \dots, c_k$.

סעיף ב'.

נסמן את פונקציית המטרה של האלגוריתם

$$J(\mu, r) = \sum_{i=1}^n \sum_{j=1}^K r_{ij} \|x_i - \mu_j\|^2$$

באשר $r \in \{0, 1\}^{n \times K}$ היא מטריצה בינארית באשר $r_{ij} = 1$ אם $\mu_j = \arg \min_{j=1, \dots, K} \|x_i - \mu_j\|^2$ ו $\mu = (\mu_1, \dots, \mu_K)$ הוא אוסף המרכזים. נרצה להוכיח כי בכל איטרציה מתקיים

$$J(\mu^{t+1}, r^{t+1}) \leq J(\mu^t, r^t)$$

כיוון שמש' הצירופים האפשריים הוא סופי K^n , ונוכיח שלא יתכן שנחזור ללופים קודמים ואנחנו בכל שלב נקטין את השגיאה, נוכיח את ההתכנסות. ההוכחה תהיה מורכבת משני חלקים

$$(1) J(\mu^t, r^{t+1}) \leq J(\mu^t, r^t)$$

$$(2) J(\mu^{t+1}, r^{t+1}) \leq J(\mu^t, r^{t+1})$$

קל לראות ששילוב השניים יביא את הדרוש.

ראשית, נשים לב כי (1) נכון כיוון שבכל איטרציה של האלגוריתם אנו מעדכנים

$$r_{ij} = 1 \iff j = \arg \min_{k=1, \dots, K} \|x_i - \mu_k\|^2$$

כיוון שבכל שלב של עדכון שכזה יכולנו רק להוריד את הערך הכולל של הפונקציה כי בחרנו ב j עבורו מינימלי, נקבל את (1). כעת, נוכיח את (2). לשם כך, נרצה לגזור את פונקציית המטרה כאשר $J(\mu^t, r^{t+1})$. נוכיח שאנו מקבלים בדיוק את צעד העדכון (הממוצע) ולכן מתמטית נקבל את שלב (2) ונסיים. ובכן,

$$J(\mu^t, r^{t+1}) = \sum_{i=1}^n \sum_{j=1}^K r_{ij}^{(t+1)} \|x_i - \mu_j^{(t)}\|^2$$

נגזור לפי רכיב μ_j כלשהו. ובכן, נשים לב כי באשר $r_{ij} = 0$ אלו יתאפסו לנו בפונקציית המטרה. לכן נתבונן רק כאשר $r_{ij}^{(t+1)} = 1$. כלומר, המחלקה ה j היא הרכיב שלו. נקבל

$$\sum_{i=1}^n r_{ij}^{(t+1)} \|x_i - \mu_j^{(t)}\|^2$$

נגזור ביטוי זה. ובכן,

$$\|x_i - \mu_j^{(t)}\|^2 \rightarrow': 2(\mu_j^{(t)} - x_i)$$

לכן נקבל:

$$\sum_{i=1}^n r_{ij}^{(t+1)} \cdot 2(\mu_j^{(t)} - x_i) = 0$$

$$2 \sum_{i=1}^n r_{ij}^{(t+1)} \mu_j^{(t)} - 2 \sum_{i=1}^n r_{ij}^{(t+1)} x_i = 0$$

$$\mu_j^{(t)} = \frac{\sum_{i=1}^n r_{ij}^{(t+1)} x_i}{\sum_{i=1}^n r_{ij}^{(t+1)}}$$

ובכן, זה בדיוק הממוצע של חברי הקבוצה. לכן הוכחנו את הדרוש.

סעיף ג'

באשר נרצה למזער את מרחק L_1 , נשים לב כי נרצה במקום הממוצע לבחור את החציון באותה קבוצה. כפי שראינו בהרצאה, על מנת למזער את $|x - c|$ עבור הקלסטרים יש לבחור בכל שלב את החציון להיות, וכך נמזער את פונקציית המטרה. נקבל את הפסודו הבא:

K-medians ($S = \{x_i\}_{i=1}^n$)

א. אתחל k צנטרואידים באופן שרירותי: $c_1, \dots, c_k \in \mathbb{R}^d$.

ב. חזור עד שקיימת איטרציה שבה כל הדגימות נותרו באותו קלסטר ולא השתנו:

- חשב לכל נקודה i את

$$\text{Cluster}(x_i) = \arg \min_{j=1, \dots, k} |x_i - c_j|_1$$

- הגדר את הקלסטרים

$$\forall 1 \leq i \leq k : \text{Cluster}_i = \{x \in S | \text{Cluster}(x) = i\}$$

- הגדר לכל קלסטר $1 \leq i \leq k$:

$$c_i = \text{medians}(\text{Cluster}_i)$$

ג. החזר את הקלסטרים $c_1, \dots, c_k$

3 מועד ב' 2023

שאלה 1.

א. הגדירו את בעיית האופטימיזציה של גרגסיה לוגיסטית, הגדירו את כל המשתנים ואת פונקציית המחיר. הסבירו את הרציונל מאחורי פונקציית המחיר.

ב. כתבו אלגוריתם אופטימיזציה מסוג SGD לבעיית הרגרסיה הלוגיסטית. יש לפשט את הגרדיאנט כדי לקבל צעד עדכון פשוט של המשקולות של המודל. כיצד בפועל תבחרו את גודל צעד העדכון (קצב הלמידה)?

ג. סטודנטים יעו להשתמש בגישה מקסימום aposteriori במקום גישה נראות מרבית ולהשתמש בפריון גאוסיאני עבור וקטור המשקולות w כדקלמן. עבור הרכיב i בוקטור, $P_0(w_i) = N(0, 1)$. ההתפלגות של וקטור המשקולות כולו היא מכפלת ההתפלגויות $\text{Pr}(w) = \prod_i P_0(w_i)$.

כתבו את בעיית האופטימיזציה עם פונקציית ה-Loss החדשה. גזרו צעד עדכון חדש למשקולות מסוג SGD , הסבירו כיצד תשפיע הוספת הפריון על הפתרון שימצא עבור w .

פתרון:

א. יהיו $\{(x_i, y_i)\}_{i=1}^n$ דטה-סט של נתונים כך שלכל $i: x_i \in \mathbb{R}^d$ וכן $y_i \in \{+1, -1\}$. המטרה שלנו היא לחזות וקטור w כך שינבא הסתברות בצורה נכונה. כלומר, להחזיר וקטור w כך שיתקיים

$$\Pr[y = 1 | x_i] = \sigma(w^T x_i)$$

פונקציית ההפסד במקרה זה הינה

$$\mathcal{L}(w) = \prod_{y_i=1} \Pr[y = 1 | x_i] \prod_{y_i=0} \Pr[y = 0 | x_i]$$

הרציונל מאחורי פונקציה זו היא למקסם את נראות הנתונים. למעשה משתמשים בגישה ML - ורוצים למקסם את הסיכוי שראינו את הדטה. נענה כבר על ב' יחד ונפתח את פונקציית ההפסד. באופן שקול:

$$= \prod_{i=1}^n \Pr[y = 1 | x_i]^{y_i} \Pr[y = 0 | x_i]^{1-y_i}$$

נפעיל $\log$ ונקבל:

$$\log \left(\prod_{i=1}^n \Pr[y = 1 | x_i]^{y_i} \Pr[y = 0 | x_i]^{1-y_i} \right) = \sum_{i=1}^n y_i \log(\Pr[y = 1 | x_i]) + (1 - y_i) \cdot \log(\Pr[y = 0 | x_i])$$

נרצה לעבוד בבעיית אופטימיזציה, לכן נסתכל על NLL . כלומר, הפונקצייה אותה נרצה למזער היא:

$$-\sum_{i=1}^n y_i \log(\Pr[y=1|x_i]) + (1-y_i) \cdot \log(\Pr[y=0|x_i])$$

כעת נפתח זאת.

$$-\sum_{i=1}^n y_i \log(\sigma(w^T x_i)) + (1-y_i) \log(1 - \sigma(w^T x_i))$$

כעת נוכל לגזור. נסמן $\sigma_i = \sigma(w^T x_i)$. נקבל:

$$\begin{aligned} -\sum_{i=1}^n y_i \cdot \frac{1}{\sigma_i} \cdot \sigma_i(1-\sigma_i) \cdot x_i + (1-y_i) \cdot \frac{1}{1-\sigma_i} \cdot \sigma_i \cdot (1-\sigma_i) \cdot (-x_i) = \\ -\sum_{i=1}^n y_i(1-\sigma_i)x_i - (1-y_i)\sigma_i x_i \\ = -\sum_{i=1}^n (y_i(1-\sigma_i) - (1-y_i)\sigma_i)x_i = \\ -\sum_{i=1}^n (y_i - y_i\sigma_i - \sigma_i + y_i\sigma_i)x_i = \\ -\sum_{i=1}^n (y_i - \sigma(w^T x_i))x_i = \sum_{i=1}^n (\sigma(w^T x_i) - y_i)x_i \end{aligned}$$

מכאן, צעד העדכון של המודל הינו:

$$w = w - \eta \cdot \sum_{i=1}^n (\sigma(w^T x_i) - y_i)x_i = w + \eta \sum_{i=1}^n (y_i - \sigma(w^T x_i))x_i$$

לכן, כאשר נכתוב אלג' בסגנון SGD נבחר בכל פעם דוגמה בודדת ונעדכן w כעת נכתוב פסודו.

1. $RLogistic(\{(x_i, y_i)\}_{i=1}^n)$

א. אתחל וקטור משקולות אקראי w .

ב. בצע עד להתכנסות:

- בחר דוגמה אקראית מהדטה (x_i, y_i) .

- בצע $w = w + \eta(y_i - \sigma(w^T x_i))x_i$

ג'. כעת, משתמשים ב MAP . במקרה זה, הרי שנקבל כי פונקציית הנראות היא

$$\prod_{i=1}^n \Pr[y=1|x_i]^{y_i} \Pr[y=0|x_i]^{1-y_i} \cdot \Pr(w)$$

לאחר הפעלת $\log$, נקבל כי זה פשוט הגרסה הקודמת פחות $\log(\Pr(w))$. לכן נתמקד בחישובו.

$$\Pr(w) = \prod_{i=1}^n P_0(w_i) = \prod_{i=1}^n \frac{1}{\sigma \cdot \sqrt{2\pi}} \exp\left(\frac{-1}{2} \cdot \left(\frac{x - \mu}{\sigma}\right)^2\right) =$$

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} w_i^2\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp^{-\frac{1}{2} \sum_{i=1}^n w_i^2}$$

לכן,

$$\log(\Pr(w)) = \log\left(\frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp^{-\frac{1}{2} \sum_{i=1}^n w_i^2}\right) = \ln\left(\frac{1}{(2\pi)^{\frac{n}{2}}}\right) - \frac{1}{2} \sum_{i=1}^n w_i^2$$

הרי האיבר השמאלי מתבטל ממילא. הנגזרת לפי הרכיב i בכל פעם היא בדיוק $-w_i$. לכן $-\frac{1}{2} \cdot 2w_i = -w_i$. לכן סה"כ נקבל כי

$$\nabla_w \log(\Pr(w)) = -w$$

לא נשכח שאנחנו מוסיפים מינוס לפני, לכן סה"כ נקבל תוספת של w לגזירה קודם. לכן סה"כ צעד העדכון יהיה

$$w = w - \eta \cdot \left(\sum_{i=1}^n (\sigma(w^T x_i) - y_i) x_i + w \right)$$

נוכל גם לסדר יותר אם נתעקש. נקבל

$$w = w - \eta w - \eta \sum_{i=1}^n (\sigma(w^T x_i) - y_i) x_i$$

$$w = (1 - \eta)w + \eta \sum_{i=1}^n (y_i - \sigma(w^T x_i)) x_i$$

למעשה, הוספת Prior השפיעה בכך שכעת מקדם הדעיכה שלנו מקטין בכל פעם את w הקודם. למעשה זה שקול לביצוע רגולזציה.

שאלה 2.

א. נתון מסווג בינארי מסוג SVM עבור המקרה שניתן להפרדה לינארית (ללא משתני Slack). יהי K קרנל שמקיים $K(x, z) = \phi(x)\phi(z)$. רשמו את כלל החיזוי לדגימה x תוך שימוש בקרנל K . רשום את הכלל תוך שימוש ב- ϕ . הסבירו את ההבדלים מבחינת סיבוכיות זמן חישוב ומבחינת סיבוכיות מס' הדגימות.

ב. נתונה רשת בת שתי שכבות עבור בעיית סיווג בינארי של דגימה חדשה x . בהינתן סט אימון $x_1, \dots, x_n$ כך ש- $y_i \in \{1, -1\}$ וכן $x_i \in \mathbb{R}^d$, בשכבה הראשונה יש n יחידות והפלט של היחידה i הוא $y_i K(x, x_i)$ כאשר K הוא קרנל. בשכבה השנייה יש משקולות נלמדות $\alpha_1, \dots, \alpha_n$ ויחידת הפלט מפעילה פונקציית Sign על הסכום המשוקלל של הקלטות שלה. הראה כי רשת זו שקולה למסווג מסוג SVM עם קרנל K .

ג. בחרו קרנל K ואלגוריתם לבחירת ערכים למשקולות $\alpha_1, \dots, \alpha_n$ כך שהרשת תהיה שקולה להפעלת אלגוריתם מסוג שכן קרוב ביותר ל- $1 - NN$ פתרון:

א. בהינתן קלט דטה $\{x_1, \dots, x_n\}$ כך ש- $x_i \in \mathbb{R}^d$ וכן $d \in \mathbb{N}$ וכן $\{y_1, \dots, y_n\}$ באשר $y_i \in \{+1, -1\}$ לכל i . בהינתן הפרמטר w , בלי הקרנל מתקיים

$$\hat{y} = \text{Sign} \left(\sum_{i=1}^n \alpha_i y_i \phi(x)^T \phi(x_i) \right)$$

סיבוכיות הזמן ריבועית ב- D , או מחשבים את $\phi(x)^T \phi(x_i)$ בזמן $O(D^2)$ לכל נק' בדטה. עם הקרנל מתקיים

$$\hat{y} = \text{Sign} \left(\sum_{i=1}^n \alpha_i y_i K(x, x_i) \right)$$

אך כיוון ש- $K(x, x_i)$ חשיבה בזמן $O(d)$ או $O(d^2)$.

ב. השכבה הראשונה של הרשת למעשה פולטת לכל i את $y_i K(x, x_i)$. זו מחוברת למשקולות סקלרית שנלמדת α_i . לכן כיוון שהן משוקללות כל יחידה i כזו תורמת $\alpha_i y_i K(x, x_i)$. הסכום הכולל הינו $\sum_{i=1}^n \alpha_i y_i K(x, x_i)$. בסיום, נתון כי מופעל Sign על רשת זו. לכן תוצאת הפלט של הרשת היא

$$\text{Sign} \left(\sum_{i=1}^n \alpha_i y_i K(x, x_i) \right)$$

זה בדיוק מסווג מסוג SVM עם קרנל K .

ג'. אנו מעוניינים לבחור פונקציית קרנל ואלג' לבחירת $\alpha_1, \dots, \alpha_n$ כך שכשנכניס לרשת את x כלשהו, נרצה שהוא יחזיר את התווית של השכן הקרוב ביותר ל- x . כפי שראינו בהרצאה, קרנל ה- RBF מודד מרחק בין קרובים. נזכר כי הוא מוגדר להיות

$$K(x, x_i) = \exp\left(-\frac{\|x - x_i\|^2}{2\sigma^2}\right)$$

נקח $\sigma^2 > 0$ כלשהו, ונבחין כי כאשר הם הכי קרובים, הוא יתן את הערך הגדול ביותר. לכן נשתמש בקרנל זה שהוגדר בהרצאה. כמו כן, נגדיר את האלגוריתם לבחירה באופן הבא:

$$j = \arg \max_{i=1, \dots, n} K(x, x_i)$$

אזי נגדיר:

$$\alpha_j = 1$$

ולכל $i \neq j$ נגדיר $\alpha_i = 0$.

שאלה 3.

שאלה זו עוסקת ברשת MLP עם קשריות מלאה עם שכבת חבוייה אחת ובה k יחידות חבויות וניורון פלט יחיד. נסמן את המשקולות בשכבה הראשונה ב- $w_1 \in \mathbb{R}^{d \times k}$, ואת המשקולות בשכבה השנייה ב- $w_2 \in \mathbb{R}^k$. יהי $x \in \mathbb{R}^d$ קלט לרשת. תהי g_1 פונקציית האקטיביציה של השכבות החבויות. יחידת הפלט היא לינארית (אין לה פונקציית אקטיביציה לא לינארית). תהי $\ell(x, y, w_1, w_2)$ פונקציית המחיר.

א. רשמו את הנוסחה שמתארת את ה-Forward pass, הפלט של הרשת בהינתן $x \in \mathbb{R}^d$.
ב. עבור פונקציית מחיר ריבועית (MSE) חשבו את הנגזרות $\frac{d\ell}{dw_2}$, $\frac{d\ell}{dw_1}$ באמצעות כלל השרשרת. רשמו צעד עדכון למשקולות עבור אלגוריתם מסוג SGD .

ג. כעת לכל קלט x משוייכים שני פלטים $y_1 \in \mathbb{R}$ ו- $y_2 \in \{-1, +1\}$. תארו רשת מסוג MLP עם שכבת חבוייה אחת ושתי יחידות פלט עבור בעיה זו. תארו פונקציות מחיר מתאימות וכתבו כלל לעדכון המשקולות. פתרון:

א. כל קלט מתחיל בשכבה הראשונה ולמעשה מוכפל ב- W_1 (מטריצה) ומתקבל $W_1 x$. משם, הוא עובר דרך פונקציית אקטיביציה $g_1(W_1 x)$ ומוכפל במשקולות w_2 ומתקבל $g_1(W_1 x) \cdot w_2$. נעיר כי נספוג את Bias או שנתעלם ממנו כי לא אמרו מפורשות בשאלה.
ב. עבור פונקציית מחיר ריבועית מתקבל

$$\ell(x, y_1, w_1, w_2) = \frac{1}{2}(\hat{y} - y)^2$$

באשר $\hat{y} = g_1(W_1 x) \cdot w_2$. נתחיל:

$$\frac{d\ell}{dw_2} = \frac{d\ell}{d\hat{y}} \cdot \frac{d\hat{y}}{dw_2} = 2 \cdot \frac{1}{2} \cdot (\hat{y} - y) \cdot g_1(W_1 x) = (\hat{y} - y) \cdot g_1(W_1 x)$$

$$\frac{d\ell}{dw_1} = \frac{d\ell}{d\hat{y}} \cdot \frac{d\hat{y}}{dg_1} \cdot \frac{dg_1}{dw_1} = (\hat{y} - y) \cdot w_2 \cdot \frac{dg_1}{dw_1}$$

מכאן כללי העדכון:

$$W_1 = W_1 - \eta \cdot (\hat{y} - y) \cdot w_2 \cdot \frac{dg_1}{dw_1}$$

$$W_2 = W_2 - \eta(\hat{y} - y) \cdot g_1(W_1 x)$$

ג'. נתאר את הרשת הבאה:

קודם כל מסלול ראשון עובר דרך משקולות רציפות ללא פונקציית אקטיביציה כלל, מסלול שני דרך סיגמואיד שיחזה ± 1 . נשתמש שוב ב- MSE עבור הרצף Hinge Loss עבור הבינארי. מכאן כמו קודם רק מתווסף החלק של Hinge.

שאלה 4

א. כתבו פסאודו קוד עבור אלגוריתם PCA להורדת מימד עבור n דגימות $x_1, \dots, x_n \in \mathbb{R}^d$ הממופות אל מרחב ממימד $\mathbb{R}^r$ כך ש $d > r > 0$.
 ב. סט נתונים $x_1, \dots, x_n \in \mathbb{R}^d$ ממופה לינארית אל תת מרחב $\mathbb{R}^r$. כאשר $d > r > 0$. יהי מטריצה $V \in \mathbb{R}^{d \times r}$ שמטריצה r עמודותיה הן בסיס אורתונורמלי של תת המרחב $\mathbb{R}^r$. בהינתן דגימה x , נסמן את ההטלה שלה אל תת המרחב ב Vz . הוכח כי הנקודה z שמביאה למינימום את שגיאת השחזור הריבועית $\|Vz - x\|^2$ מקיימת $z = V^T x$. כלומר x מוטל אל $VV^T x$.
 ג. נתון סט נתונים מתוייג $\{x_1, \dots, x_n\} \in \mathbb{R}^d$ ו $\{y_1, \dots, y_n\} \in \{+1, -1\}$. כאשר המימד d גבוה מאוד. מבקשים לאמן מפריד לינארי עם פרמטרים $w \in \mathbb{R}^d$ על מנת לסווג את הנתונים. היות והמימד d גבוה, יש חשש ל Overfitting והועלתה הצעה להטיל את הנתונים למימד נמוך r ע"י PCA ואז לאמן מסווג עם פרמטרים $w \in \mathbb{R}^r$ על הדוגמאות במימד הנמוך. הסבירו באילו מקרים התהליך הזה צפוי לשפר את יכולת הסיווג של המודל ובאילו מקרים עשוי לפגוע בה.

פתרון:

א. נגדיר את הפסודוקוד הבא.

$$\text{PCA}(\{x_i\}_{i=1}^n)$$

א. חשב את הממוצע $\mu = \frac{1}{n} \sum_{i=1}^n x_i$ ולכל נקודה הגדר $\tilde{x}_i = x_i - \mu$

ב. הגדר את המטריצה $\text{Cov}(X) = \frac{1}{n} X^T X$ באשר X מטריצה שמחזיקה את הדגימות בשורותיה.

ב. לכסן אורתוגונלית את $\text{Cov}(X)$. סמן בהתאמה את הע"ע הגדולים ביותר לפי סדר $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ ובהתאמה את הוקטורים העצמיים התואמים להם $u_1, \dots, u_d$.

ג. תהי $U \in \mathbb{R}^{r \times d}$ מטריצה שעמודותיה הם הוקטורים העצמיים $u_1, \dots, u_r$ לפי הסדר.

ד. לכל $1 \leq i \leq n$ הגדר $\tilde{x}_i = U^T x_i$

ה. החזר $(\tilde{x}_1, \dots, \tilde{x}_n)$.

ב'. נרצה הוכיח כי

$$\arg \min_z \|Vz - x\|^2 = V^T x$$

ובכן, יהי B בסיס או"נ של $\mathbb{R}^r$ נסמנו $B = \{v_1, \dots, v_r\}$. כעת נסדר את הביטוי.

$$\|Vz - x\|^2 = (Vz - x)^T (Vz - x) = (z^T V^T - x^T)(Vz - x)$$

$$= z^T V^T Vz - z^T V^T x - x^T Vz + x^T x$$

הביטוי $x^T x$ הוא קבוע, לכן ניתן לומר כי

$$\arg \min_z z^T V^T Vz - z^T V^T x - x^T Vz + x^T x = \arg \min_z z^T V^T Vz - z^T V^T x - x^T Vz$$

כעת, נשים לב כי $V^T V = I$ וכן השניים הימניים אלו סקלרים, ושווים זה לזה (ע"י טרנספוז) ולכן ניתן לומר כי נרצה

$$= \arg \min_z z^T z - 2x^T Vz$$

כעת נגזור ביטוי זה לפי z . נקבל משמאל את $2z$ ומימין נשים לב כי $x^T V = (V^T x)^T$. נסמן $u = V^T x$ אזי

$$-2u^T z$$

זה נגזר כ $-2u = -2V^T x$. לכן נקבל:

$$2z - 2v^T X = 0$$

$$z = v^T X$$

כנדרש.

ג'. נשים לב כי תהליך PCA יוצר שגיאה כלשהי. נחלק למקרים.
 - מקרה ראשון: יכול לשפר. כאשר:

1. רוצים לשפר את היעילות.
2. מונעים Overfitting כי אם d גדול קל לו יותר לשנן דטה של האימון.
3. מפחיתים רעש, כיוון שהוא מתמקד בכיוון השונות המקסימלי PCA אם הרעש מתאפיין בשונות נמוכה PCA יעף אותו.
- מקרה שני: יכול להזיק. כאשר:
1. איבוד המידע קריטי - אם המידע הקריטי שמפריד בין מחלקות הסיווג נמצא בכיוון שיש בו שונות נמוכה, ה PCA יזרוק אותו ויכולת ההפרדה של המסווג תהרס.
2. PCA לא מתאים למשימות לא לינאריות.

4 מועד א' 2024

שאלה 1

בשאלה זו נתעסקת בלמידת PAC.

- א. הוכיחו כי אם $0 < \varepsilon_1 \leq \varepsilon_2 < 1$ אזי $N(\varepsilon_1, \delta) \geq N(\varepsilon_2, \delta)$ לכל $\delta \in (0, 1)$.
 - ב. הוכיחו כי אם $0 < \delta_1 \leq \delta_2 < 1$ אזי $N(\varepsilon_1, \delta) \geq N(\varepsilon_2, \delta)$ לכל $\varepsilon \in (0, 1)$.
 - ג. יהי X מרחב בדיד ותהי $\mathcal{H}_{\text{singelton}}$ מחלקת היפותזות, יתכן אינסופית המכילה את כל ההיפותזות שממפות לכל היותר נקודה אחת ב X 15 ואת כל שאר הנקודות ממפה ל0.
- בנוסף, נניח שמדובר במקרה Realizable, כלומר קיימת מחלקה $h \in \mathcal{H}_{\text{singelton}}$ שמשווגת נכון את כל הנקודות $x \in X$. נתון האלגוריתם הבא שמממש את חוק הERM עבור $\mathcal{H}_{\text{singelton}}$: אם סט האימון מכיל את הנקודה (x_i, y_i) כאשר $y_i = 1$ האלגוריתם מחזיר את ההיפותזה:

$$h(x) := \begin{cases} 1 & x = x_i \\ 0 & x \neq x_i \end{cases}$$

- אחרת, האלגוריתם מחזיר את ההיפותזה $h(x) = 0$ לכל $x \in \mathcal{X}$.
- הוכיחו כי $\mathcal{H}_{\text{singelton}}$ היא PAC Learnable.
- רמז: בחרו $\varepsilon, \delta \in (0, 1)$ והתפלגות $\mathcal{D}$. נסה להוכיח שבמקרה הריאזיבלי יתכנו 3 מקרים:
- לכל $x \in X$ מתקיים כי $(x, 1)$ בעל הסתברות 0 תחת ההתפלגות $\mathcal{D}$.
 - יש נקודה יחידה x עבורה $(x, 1)$ עם הסתברות קטנה ε תחת התפלגות $\mathcal{D}$.
 - יש נקודה יחידה x עבורה $(x, 1)$ עם הסתברות גדולה ε תחת התפלגות $\mathcal{D}$.
- בכל אחד מהמקרים, מצאו הסתברות עבור דוגמה 'רעה' עבור מדגם של n דוגמאות. ובסוף, מצאו n עבורו הסתברות זו נמוכה מ δ . פתרון:
- א. **הוכחה:** נניח שקיים אלגוריתם A ופונקציה $N(\varepsilon, \delta)$ כך שכאשר מפעילים את A על מדגם בגודל $n \geq N(\varepsilon, \delta)$ של דיגמות iid מהתפלגות $\mathcal{D}$ האלגו' מחזיר היפותזה $h \in \mathcal{H}$ המקיימת $\Pr[Err_{\mathcal{D}}(h) < \varepsilon] > 1 - \delta$. כעת, יהיו $0 < \varepsilon_1 \leq \varepsilon_2 < 1$. יהי $\delta \in (0, 1)$. אזי, נתבונן ב $N(\varepsilon_1, \delta)$. אזי, מתקיים כי לכל $n \geq N(\varepsilon_1, \delta)$ מתקיים

$$\Pr[Err_{\mathcal{D}}(h) < \varepsilon_1] > 1 - \delta$$

וכן נתבונן ב $N(\varepsilon_2, \delta)$. אזי מתקיים לכל גודל מדגם $n \geq N(\varepsilon_2, \delta)$:

$$\Pr[Err_{\mathcal{D}}(h) < \varepsilon_2] > 1 - \delta$$

נשים לב כי מתקיים $\varepsilon_1 < \varepsilon_2$. אינטואיטיבית, משמעות הדבר כי האלגוריתם השני יכול יותר "לטעות". (לכן "ברור" שאם הוא יכול לטעות יותר, N שלו יהיה קטן יותר. בכל מקרה - ברור זו לא הוכחה). נשים לב כי מתקיים אם $\varepsilon_1 \leq \varepsilon_2$ $Err_{\mathcal{D}}(h) < \varepsilon_1$ כלומר אם קטן מ ε_1 הוא קטן גם מ ε_2 . לכן:

לכל $n \geq N(\varepsilon_1, \delta)$ מתקיים:

$$1 - \delta < \Pr[Err_{\mathcal{D}}(h) < \varepsilon_1] \leq \Pr[Err_{\mathcal{D}}(h) < \varepsilon_2]$$

בפרט, לכל $n \geq N(\varepsilon_1, \delta)$ מתקיים $1 - \delta \leq \Pr[Err_{\mathcal{D}}(h) < \varepsilon_2]$ ולכן החסם $N(\varepsilon_2, \delta) \leq N(\varepsilon_1, \delta)$, כלומר הוא חסום בחסם זה. כנדרש.

הערה. ההוכחה הייתה כמעט מובנית מאליו, אך הייתה ארוכה בשל הפורמליות. ב'. הוכחה:

נניח שקיים אלגוריתם A ופונקציה $N(\varepsilon, \delta)$ כך שכאשר מפעילים את A על מדגם בגודל $n \geq N(\varepsilon, \delta)$ של דגימות iid מהתפלגות D האלגוריתם מחזיר היפותזה $h \in \mathcal{H}$ המקיימת $\Pr[Err_D(h) < \varepsilon] > 1 - \delta$.
 כעת, יהיו $0 < \delta_1 \leq \delta_2 < 1$ ויהי $\varepsilon \in (0, 1)$.
 נתבונן ב- $N(\varepsilon, \delta_1)$. אזי מתקיים כי לכל $n \geq N(\varepsilon, \delta_1)$:

$$\Pr[Err_D(h) < \varepsilon] > 1 - \delta_1$$

בדומה, לכל $n \geq N(\varepsilon, \delta_2)$ מתקיים:

$$\Pr[Err_D(h) < \varepsilon] > 1 - \delta_2$$

נשים לב כי $\delta_1 \leq \delta_2$ ולכן $-\delta_1 \geq -\delta_2$ וכן $1 - \delta_1 \geq 1 - \delta_2$.
 לכן, יהי $n \geq N(\varepsilon, \delta_1)$ אזי מתקיים:

$$\Pr[Err_D(h) < \varepsilon] > 1 - \delta_1 \geq 1 - \delta_2$$

כלומר, לכל $n \geq N(\varepsilon, \delta_1)$ מתקיים:

$$\Pr[Err_D(h) < \varepsilon] > 1 - \delta_2$$

ולכן החסם על $N(\varepsilon, \delta_2)$ הוא לכל היותר $N(\varepsilon, \delta_1)$ כלומר $N(\varepsilon, \delta_2) \leq N(\varepsilon, \delta_1)$.
 ג'. הוכחה: נוכיח כי $\mathcal{H}_{\text{singelton}}$ היא PAC-Learnable. נעקוב אחרי הרמז.
 יהי $\varepsilon, \delta \in (0, 1)$. כלשהם והתפלגות $\mathcal{D}$.

אנו יודעים כי מדובר במקרה הריאזיבלי, לכן קיימת היפותזה נסמנה $h^* \in \mathcal{H}_{\text{singelton}}$ המסווגת נכון את כל הנקודות. נחלק למקרים:
 - מקרה ראשון: אנו יודעים כי לכל x מתקיים כי $(x, 1)$ בעל הסתברות 0. משמעות הדבר אם כן, שבהכרח כל הנקודות יסווגו נכון - שכן לפי הגדרת אלגוריתם ERM , נקבל כי הוא ינבא $h(x) = 0$ לכל $x \in \mathcal{X}$ ולכן לכל נקודה החיזוי יהיה נכון. מכאן שההסתברות במקרה זה לדוגמה רעה בודדת היא אפס, שכן כולם מסווגים נכון, ועבור מדגם של n דוגמאות - גם כן: אפס.
 - מקרה שני: קיימת בדיוק נקודה אחת המקיימת שההסתברות שיוחזר 1 עבורה תחת $\mathcal{D}$ היא לכל היותר אפסילון.
 במקרה זה, אם נפספס אותה הרי שנטעה בסיכוי לכל היותר אפסילון ונחזיר $h(x) = 0$ לכל הנקודות במדגם כולל אותה. אבל, במקרה זה השגיאה של ההיפותזה חסומה גם היא ב- ε . לכן במקרה זה השגיאה של ההיפותזה לא עוברת את אפסילון וזהו לא מקרה בעייתי לנו.
 - מקרה אחרון: הוא הבעייתי. כאן קיימת נקודה אחת בודדה עבורה היא מחזירה 1 בהסתברות לפחות ε . נראה כי במקרה זה על מדגם של n דגימות ב"ת

$$\Pr(Err(A) > \varepsilon) = \Pr[\forall x_i \text{ s.t } x_i = bad]$$

$$= \prod_{i=1}^n \Pr[x_i \text{ bad}] \leq (1 - \varepsilon)^n$$

שכן המעבר הזה נכון כי $\Pr[Correct] \geq \varepsilon$. לכן:

$$\leq e^{-\varepsilon n} \leq \delta \iff -\varepsilon n \leq \ln(\delta) \iff n \geq \frac{1}{\varepsilon} \ln\left(\frac{1}{\delta}\right)$$

לכן, לכל $n \geq \frac{1}{\varepsilon} \ln\left(\frac{1}{\delta}\right)$ נקבל כי $\Pr[Err(A) \leq \varepsilon] \leq \delta$ ואכן החסם הנ"ל פולינומי ב- $\frac{1}{\varepsilon}, \frac{1}{\delta}$ ולכן הוכחנו כי $\mathcal{H}_{\text{Singelton}}$ היא PAC-Learnable, כנדרש.

שאלה 2

נתון סט דוגמאות $\{(x_i, y_i)\}_{i=1}^n$ אשר עבורו $x_i \in \mathbb{R}^d$ וכן $y_i \in \mathbb{R}$. נסמן ב- $X \in \mathbb{R}^{n \times d}$ את מטריצת המדגם שהשורה i שלה היא x_i^T ונסמן $y = (y_1, \dots, y_n)^T$. ניתן להניח בה"כ כי הקורדינטה הראשונה של כל x_i היא 1.
 א. הגדירו באופן פורמלי את בעיית הרגרסיה לינארית כבעיית אופטימיזציה, בפרט נסחו את פונקציית המטרה כפונקציה של וקטור פרמטרים $w \in \mathbb{R}^d$.
 ב. תהי $L(w)$ פונקציית המטרה מסעיף א'. הוכיחו כי הגרדיאנט שלה הוא $\nabla L(w) = \frac{2}{n} X^T (Xw - y) = \frac{2}{n} \sum_{i=1}^n x_i (w^T x_i - y_i)$. בחרו אחת מנוסחאות הגרדיאנט לעיל והוכיחו שהיא שווה לגרדיאנט של $L(w)$.

ג. נתון סט עם n, d כך שהנתונים לא נכנסים כולם בזיכרון. תאר אלגוריתם מסוג SGD לאופטימיזציה של בעיית הרגרסיה הלינארית.
 ד. נניח כי התגיות y_i נוצרו בהינתן הקלט x_i באופן הבא: $y_i = w^T x_i + \varepsilon_i$ כאשר $w \in \mathbb{R}^d$ הוא וקטור פרמטרים לא ידוע, ε_i הוא רכיב רעש שנדגם מהתפלגות נורמלית סטנדרטית $N(0, \sigma^2)$ עם פונקציית צפיפות:

$$f(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

כך ש $\varepsilon_1, \dots, \varepsilon_n$ נדגמים באופן ב"ת.
 הציגו את הדגימות y_i כנדגמות מהתפלגות של משתנה מקרי נורמלי Y וציין את התוחלת והשונות שלו ואת התלות שלו ב w .
 הראו כי בהינתן סט נתונים $\{(x_i, y_i)\}_{i=1}^n$ הבעיה של מציאת אומד נראות מרבית MLE עבור w שקולה לבעיית מינימיזציה של MSE (Least Square) כפי שנלמדה בכיתה.
 פתרון:

א. נגדיר את בעיית הרגרסיה הלינארית באופן הבא:
 קלט: דטה-סט בגודל n המורכב מזוגות סדורים $\{(x_i, y_i)\}_{i=1}^n$ כך שלכל $i \in [n]$ $x_i \in \mathbb{R}^d$ וכן $y_i \in \mathbb{R}$
 המטרה: למצוא וקטור משקולות $w \in \mathbb{R}^{d+1}$ (רכיב ראשון בו הוא b) כך שיחזה בצורה הטובה ביותר את המודל $f(x_i) = w^T x_i$. לשם כך, אנו רוצים להתבונן על פונקציית MSE להפסד, המודדת את סך ההפסדים שלנו (המרחקים בין החיזוי לערך האמיתי). נגדיר כבעיית אופטימיזציה:

$$\min_{w \in \mathbb{R}^{d+1}} \frac{1}{n} \sum_{i=1}^n (y_i - w^T x_i)^2 = \min_{w \in \mathbb{R}^d} \frac{1}{n} (Xw - y)^T (Xw - y)$$

ב. כעת נגזור ולמען התרגול נגזור את שתי הנוסחאות. הקלה יותר, השמאלית כמובן. הנגזרת לפי w הינה:

$$\frac{d\mathcal{L}(w)}{dw} = \frac{1}{n} \sum_{i=1}^n 2 \cdot (y_i - w^T x_i) \cdot (-x_i) = \frac{2}{n} \sum_{i=1}^n (x_i) \cdot (w^T x_i - y_i)$$

נגזור גם את השנייה. ובכן, נפתח קודם:

$$\mathcal{L}(w) = (w^T X^T - y^T)(Xw - y) = w^T X^T Xw - w^T X^T y - y^T Xw + y^T y = w^T X^T Xw - 2y^T Xw + y^T y$$

$$\frac{d\mathcal{L}(w)}{dw} = \frac{1}{n} \left(2X^T Xw - 2X^T y \right) = \frac{2}{n} X^T (Xw - y)$$

ג. כיוון שהנתונים לא נכנסים בזיכרון המחשב, בכל פעם נרצה לבחור דוגמית אחת ולעדכן את המדגם באמצעותה. נראה כי לפי סעיף קודם כלל העדכון עברה לבד יהיה

$$w_{t+1} = w_t - \eta \cdot (2x_i \cdot (w^T x_i - y_i)) = w_t + \eta x_i \cdot 2(y_i - w^T x_i)$$

מכאן נגדיר את הפסודו קוד הבא.

$$LG(S_n = \{(x_i, y_i)\}_{i=1}^n \subseteq \mathbb{R}^d \times \mathbb{R}, \eta > 0)$$

א. אתחל וקטור משקלים $w \in \mathbb{R}^{d+1}$ באופן אקראי.

ב. בצע עד להתכנסות (המודל לא משתפר):

- בחר דוגמה אקראית מהדטה $(x_i, y_i) \in S_n$

- חשב את הגרדיאנט $\nabla_w = x_i \cdot (2w^T x_i - y_i)$

- עדכן: $w = w + 2\eta x_i \cdot (y_i - w^T x_i) = w - \eta \nabla_w$

ג. בסיום, החזר את w .

סעיף ד'.

נשים לב כי נתון ש $\varepsilon_i \sim N(0, \sigma^2)$. מכאן, נראה כי $y_i = w^T x_i + \varepsilon_i$ ולכן באופן שקול $\varepsilon_i = y_i - w^T x_i$. נשים לב כי נרצה לטעון שמתקיים $y_i \sim N(w^T x_i, \sigma^2)$. מדוע זה נכון? נשים לב כי $w^T x_i$ הינו קבוע. מה שקורה כאן הוא ש y_i נוצר ע"י ערך אמיתי בתוספת טעות. הערך האמיתי הנ"ל הוא קבוע. במקום ε_i פשוט מתקיים $y_i - w^T x_i \sim N(0, \sigma^2)$.
 אך ראינו בהרצאה כי אם משתנה גאוסיאן גם לאחר הוספת קבוע ($c = w^T x_i$) הוא נשאר גאוסיאן. התוחלת במקרה זה הינה:

$$\mathbb{E}[\varepsilon_i] = \mathbb{E}[y_i - w^T x_i] = \mathbb{E}[y_i] - w^T x_i$$

וכיוון ש $\mathbb{E}[\varepsilon_i] = 0$ נקבל כי $\mathbb{E}[y_i] = w^T x_i$ מכאן,

$$\sigma^2 = \text{Var}(\varepsilon_i) = \text{Var}(y_i - w^T x_i) = \text{Var}(y_i)$$

כי השונות לא מושפעת מהוספת קבוע. לכן נקבל כי

$$\forall i : y_i \sim N(w^T x_i, \sigma^2)$$

לכן:

$$\Pr(y_i|w) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{y_i - w^T x_i}{\sigma}\right)^2\right)$$

כעת, נתבונן בבעיית מציאת אומדן MLE עבור w . במקרה זה:

$$w^* = \arg \max_w \Pr(y|w) = \arg \max_w \prod_{i=1}^n \Pr(y_i|w) = \arg \max_w \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \cdot \exp\left(-\frac{1}{2}\left(\frac{y_i - w^T x_i}{\sigma}\right)^2\right) =$$

$$\arg \max_w \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^n \exp^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - w^T x_i)^2} \propto \arg \max_w \log\left(\left(\frac{1}{\sigma\sqrt{2\pi}}\right)^n \exp^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - w^T x_i)^2}\right)$$

$$= \arg \max_w \left(n \cdot \ln\left(\frac{1}{\sigma\sqrt{2\pi}}\right) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - w^T x_i)^2\right)$$

$$= \arg \max_w \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - w^T x_i)^2\right) = \arg \min_w \left(\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - w^T x_i)^2\right)$$

נשים לב כי החלפנו בין $\max$ ל $\min$ בגלל המינוס. ובכן זה שקול למעור:

$$\propto \arg \min_w \left(\frac{1}{2} \sum_{i=1}^n (y_i - w^T x_i)^2\right)$$

כיוון ש σ^2 הוא סה"כ קבוע. ואכן הוכחנו כי שקול לבעיית מינימיזציה של Least Square, כנדרש.

שאלה 3

תזכורת: עבור משתנה מקרי X שמתפלג ברנולי עם פרמטר p , פונקציית ההתפלגות שלו הינה $\Pr(X = x; p) = p^x (1-p)^{1-x}$ עבור $x \in \{0, 1\}$.
א. יהי X משתנה מקרי בינארי שנדגם מתוך תערובת של k התפלגויות ברנולי, כל אחת עם הפרמטר שלה. כתבו את פונקציית ההתפלגות של X בהתבסס על המשקלים של רכיבי התערובת $\pi_1, \dots, \pi_k$ והפרמטרים של התפלגויות ברנולי $p_1, \dots, p_k$.
ב. בהינתן הדוגמאות $x_1, \dots, x_n$ מתוך X כתבו את נוסחת Log-likelihood של הפרמטר

$$\theta = (\pi_1, \dots, \pi_k, p_1, \dots, p_k)$$

הנוסחה צריכה לכלול בין היתר את המשתנה החבוי הבינארי $Z_{i,j}$ שמייצג האם דוגמה i הגיעה מהתפלגות j .
ג. גזרו את נוסחאות העדכון של צעד E באלגוריתם EM עבור תערובת ברנולי. בפרט, כתבו את נוסחת Posterior של המשתנה החבוי $p_\theta(Z_{i,j} = 1|x_i)$.
ד. זכרו שאלגוריתם EM ממקסם את Evidence lower Boundn

$$\mathcal{L}(q, \theta) = \sum_z q(z) \log\left(\frac{p_\theta(x, z)}{q(z)}\right) \leq \log p_\theta(x)$$

רשמו טיעון לא פורמלי לכך שאלגוריתם EM מתכנס לאופטימום מקומי של פונקציית הנראות.

פתרון:

א. לפי נוסחת ההסתברות השלמה מתקיים כי

$$\Pr(X) = \sum_{k=1}^K \Pr(z = k|X) \Pr(z = k) = \sum_{k=1}^K \pi_k \cdot \Pr(z = k|x)$$

נראה כי:

$$\Pr(z = k|x) = p_k^x (1 - p_k)^{1-x}$$

לכן:

$$\Pr(X) = \sum_{k=1}^K \pi_k \cdot p_k^X \cdot (1 - p_k)^{1-X}$$

ב'. נראה ראשית כי נוסחת ההפסד:

$$\mathcal{L}(\theta) = \prod_{i=1}^n \Pr(x_i)$$

לאחר Log-likelihood נקבל:

$$\mathcal{L}(\theta) = \sum_{i=1}^n \log(\Pr(x_i))$$

לפי הסעיף הקודם נקבל

$$\Pr(x_i) = \sum_{k=1}^K \pi_k \cdot p_k^{x_i} \cdot (1 - p_k)^{1-x_i}$$

לכן קיבלנו סה"כ

$$\mathcal{L}(\theta) = \sum_{i=1}^n \log \left(\sum_{k=1}^K \pi_k \cdot p_k^{x_i} \cdot (1 - p_k)^{1-x_i} \right)$$

אבל זה לא מה שביקשו. נשים לב שנרצה לשנות את פונקציית הנראות. נגדיר משתנים חבויים בינאריים $Z_{i,k} \in \{0, 1\}$ שמייצגים 1 - הדגימה i אכן הגיעה מהתפלגות j ואחרת 0. נראה כי נוכל לכתוב

$$\Pr(X, Z|\theta) = \prod_{i=1}^n \prod_{j=1}^K (\pi_j \cdot p_j^{x_i} (1 - p_j)^{1-x_i})^{Z_{ij}}$$

שכן, אם איבר זה נכלל (אכן הדגימה i הגיעה מהתפלגות j) אזי ערכו יחושב ואחרת לא. נפעיל כעת Log ונקבל

$$\begin{aligned} & \sum_{i=1}^n \sum_{j=1}^K Z_{ij} \log(\pi_j \cdot p_j^{x_i} (1 - p_j)^{1-x_i}) \\ &= \sum_{i=1}^n \sum_{j=1}^K Z_{ij} (\log(\pi_j) + x_i \log(p_j) + (1 - x_i) \log(1 - p_j)) \end{aligned}$$

ג. לפי חוק בייס מתקיים

$$\Pr(Z_{i,j} = 1|x_i) = \frac{\Pr(x_i|Z_{i,j} = 1) \cdot \Pr(Z_{i,j} = 1)}{\Pr(X_i)}$$

$$\Pr(x_i) = \sum_{k=1}^K \pi_k \cdot p_k^{x_i} \cdot (1 - p_k)^{1-x_i}$$

כעת,

$$\Pr(Z_{i,j} = 1) = \Pr(z_i = j) = \pi_j$$

כמו כן, $\Pr(x_i | Z_{ij} = 1)$ משמעות הדבר שהדגימה x_i הגיעה ממחלקה j ולכן

$$\Pr(x_i | Z_{ij} = 1) = p_j^{x_i} (1 - p_j)^{1-x_i}$$

לכן נקבל:

$$\Pr(Z_{i,j} = 1 | x_i) = \frac{p_j^{x_i} (1 - p_j)^{1-x_i} \cdot \pi_j}{\sum_{k=1}^K \pi_k \cdot p_k^{x_i} \cdot (1 - p_k)^{1-x_i}}$$

ד'. לא בחומר של הסמסטר.

5 מועד ב' 2024

שאלה 1

נתונות n דגימות $x_1, \dots, x_n \in \mathbb{R}^d$. נסמן ב- $X \in \mathbb{R}^{n \times d}$ את מטריצת הדגימות כך שהשורה ה- i ית היא הדגימה ה- i ית x_i^T .

א. הגדירו באופן פורמלי את בעיית PCA ואת הפתרון שלה $V \in \mathbb{R}^{d \times r}$ עבור $1 \leq r \leq d$.

ב. הוכיחו כי בעיית PCA במימד אחד ($r = 1$) שקולה למקסום השונות של ההטלות של הדגימות המקוריות על הציר העיקרי הראשון. כלומר, הדגימות $x_1, \dots, x_n$ מוטלות כך:

$$a_i = V^T x_i \quad \forall 1 \leq i \leq n$$

ג. נניח כי מכפילים את כל הדגימות בקבוע $c \neq 0$. כלומר $x_i = cx_i$. לכל $1 \leq r \leq d$ כיצד ה-Principal directions ישתנו ביחס לפתרון PCA על הדגימות המקוריות? הוכיחו.

ד. נתון כי $\sum_{i=1}^n x_i = 0$. נניח כי מסובבים כל דגימה ע"י מטריצה אורתונורמלית U מסדר $d \times d$ ($U^T U = I_{d \times d}$). כלומר, $x_i = U x_i$. באופן שקול, $X_{\text{rotated}} = X U^T$.

לכל $1 \leq r < d$ בטאו את פתרון בעיית PCA על גבי המדגם המסובב באמצעות הפתרון לבעיית PCA עבור המדגם המקורי ובאמצעות U .

רמז: בטאו את Sample covariance Matrix של המידע המסובב $\text{Cov}(X_{\text{rotated}})$ באמצעות $\text{Cov}(X) = X^T X$ של המידע המקורי ומטריצת הסיבוב U . לכל וקטור עצמי v של $\text{Cov}(X)$ התבוננו בוקטור Uv .

פתרון:

א. נגדיר את הבעיה באופן הבא: בהינתן אוסף דגימות $\{x_i\}_{i=1}^n$ כך שלכל $i \in [n]$ $x_i \in \mathbb{R}^d$ המטרה שלנו היא למצוא מימד $r < d$ ולהגדיר פונקציה $f: \mathbb{R}^d \rightarrow \mathbb{R}^r$ כך שהנתונים שלנו יעוותו כמה שפחות. באופן פורמלי, תהי X מטריצה מסדר $n \times d$ כך ש- $R_i(X) = x_i^T$ לכל $1 \leq i \leq n$. תהי V מטריצה אורתוגונלית ששורותיה הם וקטורים באורך r , כלומר $V \in \mathbb{R}^{d \times r}$ כך ש- $V^T V = I$. לכל נטילו באופן הבא: $V^T x_i \in \mathbb{R}^{r \times 1}$. המטרה שלנו היא למצוא V כ"ל כך ששגיאת השחזור תהיה מינימלית. כלומר,

$$\arg \min_{V \in \mathbb{R}^{d \times r} \text{ s.t. } V^T V = I} \sum_{i=1}^n \|V^T x_i - x_i\|_2^2$$

הפתרון לבעיה זו מתקבל ע"י לכסון המטריצה $\text{Cov}(X)$, וסימון הע"ע שלה $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ עם הו"ע התואמים $u_1, \dots, u_d$. והגדרת V באופן הבא:

$$\forall 1 \leq i \leq r : R_i(V) = u_i^T$$

כלומר, שורותיה הם הוקטורים העצמיים המתאימים ל- r הערכים העצמיים הגדולים ביותר של המטריצה $\text{Cov}(X)$.
ב. נתבונן בבעיית מקסום השונות של ההטלות:

$$\arg \max_{V: a=V^T x} \sum_{j=1}^r \text{var}(a_j)$$

כיוון ש- $r = 1$ עלינו להתבונן על הפתרון לבעיה

$$\arg \max_{V: a=V^T x} \text{var}(a)$$

נשים לב כי:

$$\text{var}(a) = \frac{1}{n} \sum_{i=1}^n (a_i - \bar{a})^2 \stackrel{\bar{a}=0}{=} \frac{1}{n} \sum_{i=1}^n a_i^2$$

כעת, למעשה רוצים להתבונן ב

$$\arg \max_{a=V^T x} \frac{1}{n} \sum_{i=1}^n a_i^2$$

כעת נתבונן בבעיה המקורית. שם אנו רוצים

$$\arg \min_{V^T V=I} \sum_i \|x'_i - x_i\|^2 \text{ s.t. } x'_i = V V^T x_i$$

נראה כי

$$\|x'_i - x_i\|^2 = \|x'_i\|^2 + \|x_i\|^2 - 2x_i'^T x_i$$

הרי ש $\|x_i\|^2 = \text{Const}$ וכן $x'_i = V V^T x_i = V a_i$ לכן $\|a_i\|^2 = \|x'_i\|^2 = \|V a_i\|^2 = a_i^T V^T V a_i = a_i^T a_i = \|a_i\|^2$ וכן:

$$-2x_i'^T x_i = -2(V V^T x_i)^T x_i = -2x_i^T V V^T x_i$$

נשים לב $a_i = V^T x_i$ ולכן $a_i^T = x_i^T V$ ונקבל שזה שווה ל $-2a_i^T a_i = -2\|a_i\|^2$. סה"כ קיבלנו

$$\arg \min_{V^T V=I} \sum_i \|a_i\|^2 - 2\|a_i\|^2 + \text{Const} =$$

$$\arg \min_{V^T V=I} - \sum_{i=1}^n \|a_i\|^2 \equiv \arg \max_{V^T V=I} \sum_{i=1}^n a_i^2$$

שכן $\|a_i\|^2 = a_i^2$ אצלנו, זה הפך למקסימום בגלל המינוס ושקול למזער ללא הקבוע. ג'. נתבונן על המטריצה $\text{Cov}(X)$ החדשה לאחר ההכפלה. הרי שמתקיים כי:

$$\text{Cov}(X) = \frac{1}{n} \sum_{i=1}^n x_i x_i^T$$

(במטריצה המקורית). נסמן את החדשה ב A ונקבל כי

$$\text{Cov}(A) = \frac{1}{n} \sum_{i=1}^n a_i a_i^T = \frac{1}{n} \sum_{i=1}^n (c x_i)(c x_i)^T = c^2 \cdot \frac{1}{n} \sum_{i=1}^n x_i x_i^T = c^2 \text{Cov}(X)$$

מכאן, קיים ל c^2 פירוק ספקטרלי נסמנו U מטריצה ו D אלכסונית אזי

$$\text{Cov}(A) = c^2 U D U^T$$

נגדיר מטריצה $D' = c^2 D$ ונקבל $\text{Cov}(A) = U D' U^T$. משמעות הדבר כי הערכים העצמיים כעת כל אחת מהם גדל פי c^2 . עם זאת, הוקטורים העצמיים (הרי לוקחים את r הגדולים ביותר) לא ישתנו בכלל ולכן התשובה היא שה $\text{Principle Directions}$ לא ישתנו כלל. ד'. נסמן את הוקטורים החדשים שהתקבלו ב $y_1, \dots, y_n$ כך $y_i = U x_i \in \mathbb{R}^d$. נרצה להגדיר את המטריצה Y באופן דומה לזו ש X הוגדרה בתחילה (שורות כוקטורים) רק עם ערכי y_i . נתבונן ב $\text{Cov}(Y)$. ראשית, הממוצע של השורות נשמר אפס שכן:

$$\sum_{i=1}^n y_i = \sum_{i=1}^n U x_i = U \sum_{i=1}^n x_i = U \cdot 0 = 0$$

לפי הגדרה,

$$\begin{aligned}\text{Cov}(Y) &= \frac{1}{n} \sum_{i=1}^n y_i y_i^T = \frac{1}{n} \sum_{i=1}^n (Ux_i)(Ux_i)^T = \frac{1}{n} \sum_{i=1}^n Ux_i x_i^T U^T = U \cdot \left(\frac{1}{n} \sum_{i=1}^n x_i x_i^T \right) \cdot U^T \\ &= UCov(X)U^T\end{aligned}$$

כעת, יהי ADA^T הפירוק הספקטרי של $\text{Cov}(X)$ [שהוקטורים העצמיים $a_1, \dots, a_r$ הם הפתרון המקורי לבעיה]. אזי נציבו ונקבל

$$\text{Cov}(Y) = UADA^T U^T = (UA)D(UA)^T$$

נטען כי UA היא מטריצה אורתוגונלית. שכן:

$$(UA)^T(UA) = A^T U^T U A =_{U^T U = I} A^T I A = A^T A =_{A^T A = I} I$$

ובכן, קיבלנו פירוק ספקטרי של $\text{Cov}(Y)$. כעת, מיהם הוקטורים העצמיים הרכיבים העצמיים? למעשה אלו ה- r וקטורים הראשונים העצמיים הגדולים ביותר - אלו מופיעים ב- UA . מכאן שאם הרכיבים המקוריים הם $v_1, \dots, v_r$ אז החדשים הם $Uv_1, \dots, Uv_r$. אלו הרכיבים העיקריים החדשים שיניב PCA ביחס לפתרון הקודם.

שאלה 2

הערה: המונח "קללת המימד" מתייחס לכך שמש' הדגימות הדרוש כדי לייצג באופן נאמן נפח במימד גבוה הוא בדרך כלל אקספוננציאלי ביחס למימד הנפח.

רפאל נדאל רוצה לחזות את תוצאות משחקי הטניס העתידיים שלו בהתבסס על משחקים קודמים.

כל משחק נמדד במספר תכונות

מיומנות היריב (O : ערך סמלי בין 1 ל-10).

סוג המגרש (C : דשא, חימר, קשה)

סוג המשחק (G : זוגות או יחידים)

מזג האוויר ביום המשחק (W : חם, קר)

שעת היום (T : יום, לילה).

נדאל מעוניין להעריך את ההסתברות לנצחון בהתחשב בכל קונפיגורציה של התכונות (o, c, g, w, t) כלומר

$$\Pr(y = \text{win} | O = o, C = c, G = g, W = w, T = t)$$

א. סטודנט הציע למדל את $\Pr(y = \text{win} | O = o, C = c, G = g, W = w, T = t)$ באמצעות טבלה, שכל תא מתאים לקונפיגורציה מסוימת של (o, c, g, w, t) וערך התא מחושב ע"י ספירת אחוזי הנצחונות מתוך כל המשחקים התואמים את הקונפיגורציה של התא. תארו את הקשר בין מספר התכונות לבין מס' הדגימות הנדרש עבור מודל זה כדי להיות מדויק. אין צורך להוכיח התכנסות באופן פורמלי. הסבירו כיצד יחס זה קשור לקללת המימד.

ב. כייצד הנחת Naive Bayes יכולה לסייע לנדאל להמנע מקללת המימד? תנו דוגמה קונקרטית למצב בו ההנחה אינה מתקיימת.

ג. רשמו פסאודו קוד לאלגוריתם Naive Bayes להערכת ההסתברויות המותנות לנצחון של נדאל $\Pr(y = \text{win} | O = o, C = c, G = g, W = w, T = t)$ בהינתן אוסף תכונות ותוצאות של משחקים קודמים.

פתרון:

א. למעשה על מנת שהמודל יהיה מדויק יש לקחת מס' דגימות שתואם למס' המצבים האפשריים. באופן כללי אם O יש o אפשרויות לדגימה, ל- C יש c וכו' נקבל כי מס' האפשרויות ה- $ocgwT$. אצלנו נקבל שמספר האפשרויות ה- $ocgwT$.

$$10 \cdot 3 \cdot 2 \cdot 2 \cdot 2 = 10 \cdot 3 \cdot 2^3 = 240$$

נשים לב שמימד הנפח הוא 5 (5 תכונות) ומס' הדגימות שנדרש במקרה זה הוא 240, אכן גדול בצורה אקספוננציאלית ביחס ל-5 (קטן מ- 5^4) ובכל מקרה גדול משמעותית מ-5 - לכן במקרה זה גודל הטבלה של נדאל תהיה 240, זה מאוד גדול ומדגים את קללת המימד בדיוק. ב. נשים לב שלפי הנחת Naive Bayes מניחים כי

$$\Pr(c_i) \cdot \prod_{j=1}^d \Pr(x_j | c_i)$$

כלומר בהינתן מחלקות $\{c_1, \dots, c_k\}$ מסוימות, אנו רוצים לחשב את $Pr(c|x) = \frac{Pr(x|c) \cdot Pr(c)}{Pr(x)} \propto Pr(x|c)Pr(c)$ באופן שקול זה ללא המכנה שקבוע. נשים לב שהנחת Naive Bayes גורסת כי מתקיים $Pr(x|c) = \prod_{i=1}^d Pr(x_i|c)$ כלומר, מניחים כי התכונות x של הקלט לא תלויות זו בזו בהינתן y . במקרה של נדאל הגבר יתקיים

$$Pr(y = win|O = o, C = c, G = g, W = w, T = t) = \frac{Pr(O = o, C = c, G = g, W = w, T = t|y = win) \cdot Pr(y = win)}{Pr(O = o, C = c, G = g, W = w, T = t)}$$

$$\propto Pr(O = o, C = c, G = g, W = w, T = t|y = win) \cdot Pr(y = win)$$

תחת הנחת Naive Bayes מתקיים

$$= Pr(y = win) \cdot \prod_{\text{Feature}_i \in \{O, C, G, W, T\}} Pr(\text{Feature}_i|y = win)$$

כלומר, כעת נדאל ממש לא צריך 240 דגימות. כיוון שישנה הנחת אי תלות בין המחלקות למאורע $y = win$ ההסתברות הזו ניתנת למכפלה של 5 הסתברויות וזהו הכל.

עם זאת, יתכנו מצבים רבים בהם ההנחה של נאיב בייס לא מתקיימת. לדוגמה:

- ככל ששעת היום היא לילה - מזג האוויר יותר קר.
- ככל ששעת היום היא יום - מזג האוויר יותר חם.
- ככל שמיומנות היריב גבוהה יותר, הוא יעדיף לשחק ביחידים.
- ואפשרויות רבות. הרעיון: יש קשר בין המחלקות (המאפיינים של דוגמה מסוימת של דטה).
- ג. יהי כקלט D אוסף אימון של משחקים קודמים, נסמנו

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$$

כאשר לכל דגימה i :

$$x_i = (o_i, c_i, g_i, w_i, t_i)$$

$$y_i \in \{\text{Win}, \text{Loss}\}$$

נכתוב כעת את הפסודו קוד הבא (לאימון) הדטה, בסוף הרי מתקיים לאחר האימון כי

$$\hat{y} = \arg \max_{c \in \{\text{Win}, \text{Loss}\}} Pr(y = c) \prod_{\text{Feature}_i \in \{O, C, G, W, T\}} Pr(\text{Feature}_i|y = win)$$

כעת נכתוב את הפסודו.

$$\text{Naive Bayes}(\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n)$$

א. חשב Priors:

- חשב

$$Pr(\text{win}) = \frac{|\{x_i|y_i = \text{Win}\}|}{n}$$

$$Pr(\text{Loss}) = \frac{|\{x_i|y_i = \text{Loss}\}|}{n}$$

ב. לכל $j = 1, \dots, 5$ (באשר מספרנו את התכונות) ולכל אפשרות v של הפיצ'ר חשב את:

$$Pr(\text{Feature}_j = v|y = win) = \frac{|\{x_i|x_i^{(j)} = v \wedge y = win\}|}{|\{x_i|y_i = win\}|}$$

$$Pr(\text{Feature}_i = v|y = Loss) = \frac{|\{x_i|x_i^{(j)} = v \wedge y = loss\}|}{|\{x_i|y_i = loss\}|}$$

שאלה 3

א. הגדירו באופן פורמלי את בעיית הסיווג עם שוליים מקסימליים, הוכיחו כי בעיה זו שקולה לבעיית מזעור הריבוע של נורמת L_2 של וקטור המשקולות w תחת אילוצים.

ב. תיארנו בכיתה אלגוריתם מסוג SGD למציאת מפריד לינארי לבעיית סיווג בלינארי. רשמו את נוסחת עדכון המשקולות (צעד הגרדיאנט) באלגוריתם הזה, הסבירו כיצד ישתנה צעד הגרדיאנט אם נרצה למצוא מפריד שגם מביא למינימום את נורמת L_2 של וקטור המשקולות w ? רמז: יש להוסיף רגולרזציה לפונקציית המטרה.

ג. בעיית SVM שהוצגה בכיתה עבור סט אימון שניתן להפרדה לינארית משתמשת באילוצים מהצורה $y_i(w^T x_i - b) \geq 1$. כעת נניח שנחליף את הקבוע 1 עם קבוע שרירותי וחיובי אחר $c > 0$. כעת האילוצים יהיו מהצורה $y_i(w^T x_i - b) \geq c$. הוכיחו כי המימוש המפריד האופטימלי לא משתנה.

רמז: מצאו את הקשר בין הפתרון האופטימלי w, b של הבעיה החדשה לבין הפתרון האופטימלי של הבעיה המקורית. מותר להניח $b = 0$.
 ד. כעת אנחנו רוצים ללמוד אלגוריתם דירוג שבהינתן שתי דגימות $x_i^{(1)}, x_i^{(2)} \in \mathbb{R}^d$ מחליט מי מהשתיים "טובה יותר". בהינתן סט אימון של דגימות מדורגות, כאשר כל דגימה מורכבת מהזוג $(x_i^{(1)}, x_i^{(2)})$ כאשר $x_i^{(1)}$ מדורגת גבוה יותר מאשר $x_i^{(2)}$ לכל $i \in [n]$. המטרה היא ללמוד וקטור משקולות $w \in \mathbb{R}^d$ עבור דירוג כך שנדרג נכונה דוגמאות חדשות - $w^T x_i^{(test1)} > w^T x_i^{(test2)}$. הגדירו באופן פורמלי את הבעיה הנ"ל כבעיית למידה עם שוליים מקסימליים ונסחו אותה כבעיית אופטימיזציה עם אילוצים. כמו כן, הציעו אלגוריתם אופטימיזציה לבעיה בסגנון האלגוריתם מסעיף ב' ורשמו פסודו עבורו.

פתרון:

א. בהינתן אוסף דטה $\{(x_i, y_i)\}_{i=1}^n$ כאשר לכל $i \in [n]$ $x_i \in \mathbb{R}^d$ וכן $y_i \in \{+1, -1\}$ המטרה תהיה למצוא וקטור משקולות $w \in \mathbb{R}^d$ כך שסיווג נכון את הנתונים. בהינתן וקטור כנ"ל ונק' חיתוך $b \in \mathbb{R}$ תהי $w^T x - b = 0$ משוואת הישר המרכז. משוואות הישרים במרחק 1 (לאחר Scaling trick) מהם הם $w^T x - b = 1$ ו- $w^T x - b = -1$. המרחק של נקודה שנמצאת על אחד הישרים האלו מהישר שלנו הינה

$$\frac{|w^T x - b|}{\|w\|} = \frac{1}{\|w\|}$$

ולכן, השוליים מוגדרים להיות באורך $\frac{1}{\|w\|}$ והמדרכה פי 2 מזה. המטרה שלנו היא למקסם את השוליים כלומר מציאת וקטור משקולות w כך ש:

$$\max_{w \in \mathbb{R}^d} \frac{1}{\|w\|} \text{ s.t } \forall i : y_i(w^T x_i - b) \geq 1$$

תחת האילוצים שלנו.

נראה כי מתקיים:

$$\propto \min_{w \in \mathbb{R}^d} \|w\| \text{ s.t } \forall i : y_i(w^T x_i - b) \geq 1 \propto \min_{w \in \mathbb{R}^d} \frac{1}{2} \|w\|^2 \text{ s.t } \forall i : y_i(w^T x_i - b) \geq 1$$

ולכן הוכחנו את הדרוש.

ב. ראינו בכיתה את האלגוריתם שמשמש ב-Hinge Loss. נזכר כי היא מוגדרת באופן הבא:

$$\ell(x_i, y_i, w, b) := \begin{cases} 0 & y_i w^T x_i \geq 0 \\ -y_i w^T x_i & o.w \end{cases}$$

לכן נגזרתה מקיימת: כאשר $y_i w^T x_i \geq 0$ נקבל 0 ואחרת $-y_i x_i$. מכאן נקבל את צעד הגרדיאנט:

- כאשר אין שגיאה: לא מעדכנים.

- כאשר יש שגיאה: $w_{t+1} = w_t - \eta \nabla_w \ell = w_t - \eta(-y_i x_i) = w_t + \eta y_i x_i$ וזהו צעד עדכון המשקולות. נוכל לכתובו גם באופן פורמלי יותר:

SGD-Classification($\{(x_i, y_i)\}_{i=1}^n$)

א. אתחל וקטור משקולות $w \in \mathbb{R}^d$ באופן אקראי.

ב. בצע עד שכל הדגימות נכונות:

- בחר דוגמה אקראית מהדטה (x_i, y_i) .

- אם הmargin שלה חיובי, כלומר $y_i w^T x_i > 0$ אזי עבור לאיטרציה הבאה.

- אחרת, עדכן $w = w + \eta y_i x_i$.

ג. בסיום, החזר את w .

כעת, אם רוצים למצוא מפריד שגם יביא למינימום את נורמת L_2 של וקטור המשקולות, נשנה את פונקציית ההפסד להיות

$$\ell(x_i, y_i, w, b) := \begin{cases} \frac{1}{2} \lambda \|w\|^2 & y_i w^T x_i \geq 0 \\ \frac{1}{2} \lambda \|w\|^2 - y_i w^T x_i & o.w \end{cases}$$

כאשר $\lambda > 0$ קבוע חיובי. בהתאמה הגרדיאנט יהיה

$$\ell'(x_i, y_i, w, b) := \begin{cases} \lambda w & y_i w^T x \geq 0 \\ \lambda w - y_i x_i & o.w \end{cases}$$

צעד הגרדיאנט במקרה זה ישתנה באופן הבא:

$$\begin{aligned} \text{כאשר Margin חיובי עדיין נבצע עדכון ויתקיים } w &= w - \eta(\lambda w) = (1 - \eta\lambda)w \\ \text{כאשר Margin שלילי נקבל } w &= w - \eta(\lambda w - y_i x_i) = (1 - \eta\lambda)w + \eta y_i x_i \end{aligned}$$

ג'. נציב ישר $b = 0$ ונתבונן בבעיית האופטימיזציה החדשה

$$\min_{w \in \mathbb{R}^d} \frac{1}{2} \|w\|^2 \quad \text{s.t. } \forall i : y_i (w^T x_i) \geq c$$

נוכיח שאם w^* הוא פתרון אופטימלי של הבעיה המקורית, אזי cw^* הוא פתרון אופטימלי של הבעיה החדשה. אם נראה זאת אזי המימוש המפריד האופטימלי לא משתנה (הוא מוכפל בקבוע), בכל מקרה כל נקודה שמקיימת את $w^T x = 0$ תקיים גם $cw^T x = 0$ והמימוש לא ישתנה. כעת, נוכיח ש: 1. cw^* הוא פתרון חוקי תחת האילוצים 2. הוא פתרון אופטימלי.

ראשית, יהי w^* הפתרון האופטימלי של הבעיה המקורית, אזי, לכל i מתקיים $y_i ((w^*)^T x_i) \geq 1$. נכפול את המשוואה בשני הצדדים ב- c ונקבל $y_i ((cw^*)^T x_i) \geq c$ (סקלר יכול להכנס ל- T ולא ישנה). ולכן האילוצים של הבעיה החדשה מתקיימים כלומר אם נסמן $u = cw^*$ נקבל לכל i כי $y_i u^T x_i \geq c$ כנדרש.

שנית, נניח בשלילה כי cw^* איננו הפתרון האופטימלי עבור הבעיה. משמעות הדבר כי קיים וקטור משקולות w' שעונה על האילוצים ומקיים

$$\frac{1}{2} \|w'\|^2 < \frac{1}{2} \|cw^*\|^2$$

נכפיל ב-2 ונראה כי $\|cw^*\|^2 = c^2 \|w^*\|^2$ ונקבל $\|w'\|^2 < c^2 \|w^*\|^2$. אם נסדר נקבל כי $\frac{1}{c^2} \|w'\|^2 < \|w^*\|^2$ ואם נכניס אז $\|\frac{1}{c} w'\|^2 < \|w^*\|^2$ ולכן גם $\|\frac{1}{c} w'\|^2 < \|w^*\|^2$. נטען כי $u' = \frac{1}{c} w'$ הוא פתרון חוקי לבעיה הקודמת (ואם נוכיח זאת נקבל סתירה כי הוא קטן יותר מערך המטרה של w^*). ובכן מתקיים כי w' עונה על האילוצים לכן לכל i : $y_i ((w')^T x_i) \geq c$. נחלק ב- $c > 0$ את שני הצדדים ונקבל

$$y_i \left(\frac{1}{c} w'\right)^T x_i \geq 1$$

כלומר אכן $u' = \frac{1}{c} w'$ פתרון חוקי לבעיה המקורית בסתירה לכך ש- w^* אופטימלי. לכן, cw^* הוא פתרון אופטימלי לבעיה החדשה.

ד'. לכל דגימה i נשים לב שנרצה שיתקיים $w^T (x_i^{(1)} - x_i^{(2)}) > 0$

לכן לפי Scaling-Trick נגדיר את הבעיה באופן הבא:

המטרה היא למצוא וקטור משקולות $w \in \mathbb{R}^d$ כך שבהינתן משוואת הישר $w^T (x^{(1)} - x^{(2)}) = 0$, ומשוואת הישר במדרכה $w^T (x^{(1)} - x^{(2)}) = 1$ וכן $w^T (x^{(1)} - x^{(2)}) = -1$ מוציא את הוקטור w שממקסם את השוליים שערכם

$$\frac{\|w^T (x^{(1)} - x^{(2)})\|}{\|w\|} = \frac{1}{\|w\|}$$

לכן נגדיר את הבעיה באופן הבא:

$$\max_{w \in \mathbb{R}^d} \frac{1}{\|w\|} \quad \text{s.t. } \forall i \in [n] : w^T (x_i^{(1)} - x_i^{(2)}) \geq 1$$

לכל דגימה x_i נגדיר את הדגימה $y_i = x_i^{(1)} - x_i^{(2)}$ ונרצה:

$$\max_{w \in \mathbb{R}^d} \frac{1}{\|w\|} \quad \text{s.t. } \forall i \in [n] : w^T y_i \geq 1$$

ובכן זו בדיוק בעיית מקסום השוליים כאשר $b = 0$ והוכחנו בסעיף א' ששקולה לבעיה הבאה

$$\min_{w \in \mathbb{R}^d} \frac{1}{2} \|w\|^2 \quad \text{s.t. } \forall i \in [n] : w^T y_i \geq 1$$

נציע את האלגוריתם הבא לאופטימיזציה. ראשית, נגדיר פונקציית הפסד להיות Hinge Loss עם Margin (של 1) ורגוליזציה. נקבל

$$\ell(x_i, y_i, w, b) := \begin{cases} \frac{1}{2}\lambda \|w\|^2 & y_i w^T x \geq 1 \\ \frac{1}{2}\lambda \|w\|^2 - w^T y_i & o.w \end{cases}$$

כאשר $\lambda > 0$ קבוע חיובי. בהתאמה הגרדיאנט יהיה

$$\ell'(x_i, y_i, w, b) := \begin{cases} \lambda w & y_i w^T x \geq 1 \\ \lambda w - y_i & o.w \end{cases}$$

ונציג את האלגוריתם הבא:

:Rank-Classification($\{(x_i^{(1)}, x_i^{(2)})\}_{i=1}^n$)

א. אתחל וקטור משקולות $w \in \mathbb{R}^d$ באופן אקראי.

ב. לכל $i \in [n]$ הגדר $y_i = x_i^{(1)} - x_i^{(2)}$.

ב. בצע עד שכל הדגימות נכונות:

- בחר דוגמה אקראית מהדטה y_i .

- אם Margin של חיובי, כלומר $w^T y_i \geq 1$ אזי עדכן $w = (1 - \eta\lambda)w$

- אחרת, עדכן $w = (1 - \eta\lambda)w + \eta y_i$.

ג. בסיום, החזר את w .

6 שאלות ממועדי ג'

מועד ג' 2024 - Kmeans

א. נסחו את אלגוריתם K-means כתהליך מינימיזציה של פונקציית מטרה. הגדירו פונקציית מטרה המורכבת משני תהליכי מינימיזציה ותארו את אלגוריתם K-means כתהליך מינימיזציה מתחלף. השתמשו בתוצאה זו כדי להוכיח שמובטח שהאלגוריתם מתכנס.

ב. אלגוריתם K-means הופעל על סט דגימות $\{x_i\}_{i=1}^n \in \mathbb{R}^d$ עבור $k = 2$. נסמן את מרכזי האשכולות הסופיים (הצנטרואידים) μ_1, μ_2 ונסווג כל נקודה על בסיס המרחק שלה מהמרכז הקרוב אליה.

כלומר, $y_i = 1$ אם $\|x_i - \mu_1\|^2 \leq \|x_i - \mu_2\|^2$ ו-1 אחרת.

הוכיחו שגבול ההפרדה שנוצר ע"י K-means במקרה זה הוא לינארי, כלומר קיימים $w \in \mathbb{R}^d$ ו- $b \in \mathbb{R}$ כך שלכל $i \in [n]$ מתקיים $y_i(w^T x_i - b) \geq 1$.

0

פתרון:

א. בהינתן אוסף דטה כקלט $\{x_1, \dots, x_n\}$ כך שלכל $i \in [n]$ מתקיים כי $x_i \in \mathbb{R}^d$ נגדיר את אלגוריתם K-means באופן הבא. ראשית ננסח פסודו קוד:

:Kmeans($\{x_i\}_{i=1}^n, K$)

א. אתחל $\mu_1, \dots, \mu_k$ באופן אקראי צנטרואידים.

ב. עד שהמודל מפסיק להשתפר (לכל נקודה i מתקיים $\text{Cluster}^{(t-1)}(x_i) = \text{Cluster}^{(t)}(x_i)$) בצע:

ג. חשב לכל נקודה i את $\text{Clutser}^{(t)}(x_i) = \arg \min_j \|x_i - \mu_j\|_2^2$

ד. הגדר לכל $1 \leq i \leq k$ $C_i = \{x_j | \text{Cluster}(x_j)^{(t)} = i\}$

ה. לכל $i \in [k]$ חשב: $\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$

ו. בסיום, החזר את $\mu_1, \dots, \mu_k$.

נגדיר כעת את פונקציית המטרה באופן הבא:

$$\min_{\mu=(\mu_1, \dots, \mu_k)} \sum_{i=1}^n \min_{j \in \{1, \dots, k\}} \|x_i - \mu_j\|_2^2$$

אכן מורכבת משני תהליכי מינימיזציה. נגדיר את פונקציית ההפסד:

$$J(\mu, r) = \sum_{i=1}^n \sum_{j=1}^K r_{ij} \|x_i - \mu_j\|_2^2$$

באשר $r \in \{0, 1\}^{n \times K}$ היא מטריצה בינארית כך ש- $r_{ij} = 1$ אם הנקודה i משויכת לאשכול j . וכן $\mu = (\mu_1, \dots, \mu_k)$ אוסף צנטרואידים. נרצה להוכיח שהאלגוריתם מתכנס. אם כן,

עבור איטרציה t נרצה להוכיח את הקשר הבא:

$$J(\mu^{(t+1)}, r^{(t+1)}) \leq_{(1)} J(\mu^{(t)}, r^{(t+1)}) \leq_{(2)} J(\mu^{(t)}, r^{(t)})$$

בפרט אי השוויון של שמאל וימין יתן את התכנסות האלגוריתם (כי לא נכנס למעגלים ומס' האפשרויות סופי). נתחיל מלהוכיח את (2). ובכן, בהינתן שמקבעים את המרכזים $\mu^{(t)}$, האלגוריתם מחליט לשייך את נקודה i לאשכול j אמ"מ

$$j = \arg \min_{k \in \{1, \dots, K\}} \|x_i - \mu_k\|_2^2$$

לכן, בהכרח לאחר עדכון מטריצת השיוכים $r^{(t+1)}$ נקבל כי הערך של פונקציית המטרה יכל רק לרדת ולכן נקבל את (2). כעת נוכיח את (1). ובכן, נקבע את $r^{(t+1)}$ ונתבונן על הנגזרת של פונקציית העלות לפי מרכז k .

$$\frac{dJ}{d\mu_k} \left(\sum_{i=1}^n \sum_{j=1}^K r_{ij} \|x_i - \mu_j\|_2^2 \right)$$

כל המקרים בהם $j \neq k$ מתאפסים ונקבל:

$$\frac{dJ}{d\mu_k} \left(\sum_{i=1}^n r_{ik} \|x_i - \mu_k\|_2^2 \right) = \sum_{i=1}^n r_{ik} \cdot \frac{d(\|x_i - \mu_k\|_2^2)}{d\mu_k} = \sum_{i=1}^n r_{ik} \cdot 2 \cdot (\mu_k - x_i) = 0$$

$$\mu_k \cdot \sum_{i=1}^n r_{ik} - \sum_{i=1}^n r_{ik} x_i = 0$$

$$\mu_k = \frac{\sum_{i=1}^n r_{ik} x_i}{\sum_{i=1}^n r_{ik}}$$

ובכן זה בדיוק ממוצע הנקודות ששויכו לאשכול k , לכן קיבלנו בדיוק את שלב העדכון של האלגוריתם ביחס למרכזים $\mu^{(t)}, \mu^{(t+1)}$ ולכן נקבל את (1). סה"כ קיבלנו את הדרוש.

ב'. ובכן פשוט נפתח את אי השוויון. נראה כי נקודה מסווגת כחיובית אם קרובה יותר ל μ_1 כלומר:

$$\|x_i - \mu_1\|^2 \leq \|x_i - \mu_2\|^2$$

$$(x_i - \mu_1)^T (x_i - \mu_1) \leq (x_i - \mu_2)^T (x_i - \mu_2)$$

$$(x_i^T - \mu_1^T)(x_i - \mu_1) \leq (x_i^T - \mu_2^T)(x_i - \mu_2)$$

$$x_i^T x_i - x_i^T \mu_1 - \mu_1^T x_i + \mu_1^T \mu_1 \leq x_i^T x_i - x_i^T \mu_2 - \mu_2^T x_i + \mu_2^T \mu_2$$

$$\mu_1^T \mu_1 - 2\mu_1^T x_i \leq \mu_2^T \mu_2 - 2\mu_2^T x_i$$

$$0 \leq (\mu_2^T \mu_2 - \mu_1^T \mu_1) + (2\mu_1^T - 2\mu_2^T)x_i$$

נמשיך לסדר.

$$\frac{1}{2}(\mu_2^T \mu_2 - \mu_1^T \mu_1) + (\mu_1^T - \mu_2^T)x_i \geq 0$$

נרצה כי $w^T = \mu_1^T - \mu_2^T$ ולכן נגדיר $w = (\mu_1 - \mu_2)$ וכן $b = \frac{1}{2}(\mu_1^T \mu_1 - \mu_2^T \mu_2)$ וקיבלנו

$$w^T x_i - b \geq 0$$

כאשר y_i מסווג ל-1. אם y_i מסווג ל-1 פשוט אי השוויון הראשון מתהפך, וכך גם שאר האלגברה והיינו מקבלים $w^T x_i - b \leq 0$ לכן סה"כ לכל i מתקיים

$$y_i(w^T x_i - b) \geq 0$$

ולכן אכן מסווג לינארי.

מועד ג' 2025 - רגרסיה לינארית

ברצוננו לפתור בעיית רגרסיה לינארית. נתון דטה-סט $\{(x_i, y_i)\}_{i=1}^n$ כאשר לכל $x_i \in \mathbb{R}^d$ מתוּיג לדוגמה $y_i \in \mathbb{R}$. תהי $X \in \mathbb{R}^{n \times d}$ Sample Metrix שהשורה ה- i שלה היא x_i ויהי $y = (y_i)_{i=1}^n \in \mathbb{R}^n$ וקטור התייגים. א. הגדירו באופן פורמלי את בעיית הרגרסיה הלינארית כבעיית אופטימיזציה, בפרט ציינו את Optimization objective כפונקציה של וקטור פרמטרים $w \in \mathbb{R}^d$.

ב. נסמן את הפונקציה מסעיף א' ע"י $L(w)$. בכיתה הוכחנו כי הגרדיאנט שלה הינו $\nabla L(w) = \frac{2}{n} X^T (Xw - y)$. תחת ההנחה כי $X^T X$ מטריצה הפיכה, הוכיחו כי $w^* = (X^T X)^{-1} X^T y$ הוא פתרון אופטימלי יחיד לבעיית הרגרסיה. כמו כן, תנו גרסה מפורטת של הפתרון האופטימלי עבור המקרה שבו Sample Metrix היא אורתונורמלית.

ג. נניח כי אנחנו ממזערים את $L(w)$ ע"י GD עם מקדם למידה $\eta > 0$ ואתחול w_0 של הפרמטרים של המודל ומקבלים את העדכונים $w_1, \dots, w_t$ לצעדי הגרדיאנט $1, \dots, t$.

יהי w^* הפתרון האופטימלי לבעיית הרגרסיה. הוכיחו כי $w_t - w^* = (I - \frac{2}{n} \eta X^T X)^t (w_0 - w^*)$ כאשר $I \in \mathbb{R}^{d \times d}$ היא מטריצת היחידה. רמז: כתבו את w_t כתלות ב- w_{t-1} והשתמשו בעובדה כי $X^T y = (X^T X) w^*$.

ד. התבוננו במקרה החד ממדי, בו $x_i \in \mathbb{R}$ וקטור n -מימדי. הוכיחו שתנאי מספיק והכרחי להתכנסות $w_t \rightarrow w^*$ כאשר $t \rightarrow \infty$ הוא $0 < \eta < \frac{n}{\|X\|^2}$.

פתרון:

א. בהינתן קלט $\{(x_i, y_i)\}_{i=1}^n$ כך שלכל $i \in [n]$ מתקיים $x_i \in \mathbb{R}^d$ וכן $y_i \in \mathbb{R}$, מטרת הרגרסיה לינארית היא למצוא פונקציה $f(x_i) = w^T x_i + b$ באשר $w \in \mathbb{R}^d, b \in \mathbb{R}$ שממזערת את השגיאה הריבועית (MSE). באופן פורמלי,

$$w^* = \arg \min_w \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2 = \arg \min_w \frac{1}{n} (Xw - y)^T (Xw - y)$$

כלומר הפונקציה המדוברת הינה

$$L(w) = \frac{1}{n} (Xw - y)^T (Xw - y)$$

ב. ובכן, נוכיח ראשית שמדובר בפתרון יחיד, ע"י ששווה את הנגזרת לאפס. הרי:

$$\nabla L(w) = \frac{2}{n} \cdot (X^T Xw - X^T y) = 0 \implies X^T Xw = X^T y$$

נתון כי מדובר במטריצה הפיכה, לכן קיימת הופכית $(X^T X)^{-1}$ ע"י הכפלה משמאל נקבל:

$$w = (X^T X)^{-1} X^T y$$

לכן מדובר בפתרון יחיד.

כשמדובר במטריצה אורתונורמלית נקבל כי $X^T X = I$ ולכן $(X^T X)^{-1} = I$ ולכן $w = IX^T y = X^T y$ ולכן $\hat{w} = (X^T X)^{-1} X^T y$ נשים לב כי אם נוכיח שוקטור השגיאה שנית, נוכיח שמדובר בפתרון אופטימלי. לשם כך, נסמן ב- $\hat{y} = X\hat{w}$ באשר $\hat{y} = X\hat{w}$ באשר $\hat{y} = X\hat{w}$ נשים לב כי אם נוכיח שוקטור השגיאה $y - \hat{y}$ מאונך ל- $\hat{y}$, נקבל שמדובר בפתרון אופטימלי. מדוע? שכן $\hat{w}$ הוא צ"ל של המרחב X . הנקודה הכי קרובה (ולכן אופטימלי) לוקטור השגיאה y הוא האנך ביניהם. כעת,

$$\langle y - \hat{y}, \hat{y} \rangle = (y - \hat{y})^T \hat{y} = y^T X \hat{w} - \hat{y}^T \hat{y}$$

נפתח את $\hat{y}^T \hat{y}$.

$$\hat{y}^T \hat{y} = (X\hat{w})^T (X\hat{w}) = (\hat{w})^T X^T X \hat{w} = ((X^T X)^{-1} X^T y)^T (X^T X) \hat{w} = y^T X (X^T X)^{-1} (X^T X) \hat{w} = y^T X \hat{w}$$

לכן

$$\langle y - \hat{y}, \hat{y} \rangle = y^T X \hat{w} - y^T X \hat{w} = 0$$

כנדרש.

ג'. ובכן נראה שלפי כלל עדכון GD הרי

$$w_t = w_{t-1} - \eta \nabla L(w) = w_{t-1} - \eta \cdot \left(\frac{2}{n} X^T (X w_{t-1} - y) \right) =$$

$$w_t = w_{t-1} - \eta \cdot \frac{2}{n} X^T X w_{t-1} + \eta \frac{2}{n} X^T y$$

נשים לב כי $(X^T X) w^* = (X^T X) (X^T X)^{-1} X^T y = X^T y$ ולכן:

$$w_t = w_{t-1} - \eta \cdot \frac{2}{n} X^T X w_{t-1} + \eta \frac{2}{n} (X^T X) w^*$$

נסדר מימין ומשמאל

$$w_t = (I - \frac{2}{n} \eta X^T X) w_{t-1} + \eta \frac{2}{n} (X^T X) w^*$$

נחסר משני הצדדים w^* ונקבל:

$$w_t - w^* = (I - \frac{2}{n} \eta X^T X) w_{t-1} + \eta \frac{2}{n} (X^T X) w^* - w^*$$

$$w_t - w^* = (I - \frac{2}{n} \eta X^T X) w_{t-1} + (I - \frac{2}{n} \eta X^T X) w^*$$

$$w_t - w^* = (I - \frac{2}{n} \eta X^T X) (w_{t-1} - w^*)$$

כעת נמשיך לפתוח את זה:

$$w_t - w^* = (I - \frac{2}{n} \eta X^T X) ((I - \frac{2}{n} \eta X^T X) w_{t-2} - w^*) + w^* - w^*$$

$$w_t - w^* = (I - \frac{2}{n} \eta X^T X)^2 (w_{t-2} - w^*)$$

באופן דומה נוכל להמשיך באופן איטרטיבי וה w^* מצטמם בכל שלב ו $I - \frac{2}{n} \eta X^T X$ מוכפל שוב ונקבל:

$$w_t - w^* = (I - \frac{2}{n} \eta X^T X)^t (w_0 - w^*)$$

כנדרש.

ד': לפי הסעיף הקודם ותחת ההנחה כי $X \in \mathbb{R}^n$ נסמנו מעתה x , נקבל

$$w_t - w^* = \left(I - \frac{2}{n}\eta x^t x\right)^t (w_0 - w^*)$$

הרי שמתקיים $w_t \rightarrow w^*$ ובאופן שקול אם $(w_t - w^*) \rightarrow 0$. נשאיף את הביטוי לאנסוף. נקבל

$$\lim_{t \rightarrow \infty} \left(\left(I - \frac{2}{n}\eta x^t x\right)^t (w_0 - w^*) \right) = 0$$

מתי זה קורה? ובכן זה תלוי! נרצה כי $(I - \frac{2}{n}\eta x^t x)^t \rightarrow 0$. מתי זה קורה? כאשר $x^t \rightarrow 0$ אם $t \rightarrow \infty$ זה אמ"מ $|x| \leq 1$ לפי אינפי.1. אצלנו, נראה כי:

$$I - \frac{2}{n}\eta x^t x = 1 - \frac{2}{n}\eta \|x\|^2$$

נדרוש:

$$|1 - \frac{2}{n}\eta \|x\|^2| < 1$$

לכן:

$$-1 < 1 - \frac{2}{n}\eta \|x\|^2 < 1$$

מכיוון ראשון, $\eta > 0 \iff -\frac{2}{n}\eta \|x\|^2 < 0 \iff 1 - \frac{2}{n}\eta \|x\|^2 < 1$ (שכן כל השאר שם חיוביים). מכיוון שני,

$$-1 < 1 - \frac{2}{n}\eta \|x\|^2 \iff 2 > \frac{2}{n}\eta \|x\|^2 \iff 1 > \frac{1}{n}\eta \|x\|^2 \iff \frac{n}{\|x\|^2} > \eta$$

כלומר סה"כ כאשר

$$\eta \in (0, \frac{n}{\|x\|^2})$$

כנדרש.

מועד ג' 2024 - פרספטרון ובעיית הזוגיות

בכיתה הגדרנו את בעיית הזוגיות (Parity Problem): בהינתן רצף של d ביטים $x \in \{0,1\}^d$ עלינו להחליט האם מס' ה-1ים זוגי (ואז נתייג $y = -1$) או אי זוגי (ואז נתייג $y = +1$). נתון לנו סט אימון מתויג עם n דוגמאות $\{(x_i, y_i)\}_{i=1}^n$ של רצפי d ביטים מתויגים כאלו.

1. כתוב פסאודו קוד עבור אלגוריתם Kernel-Preceptron. הגדר את כל המשתנים בזהירות.
2. עבור רצפים באורך $d = 2$, וסט נתונים המכסה את כל 4 הרצפים הקיימים, הוכח שאלגוריתם Preceptron (הלינארי) לא יתכנס ע"י כך שתראה שלא קיימת קבוצת משקולות והטיות $w \in \mathbb{R}^2, b \in \mathbb{R}$ שמסווגת נכון את כל נקודות הנתונים.
3. תאר מיפוי תכונות ϕ (Feature map) כך שאלגוריתם Preceptron יתכנס ויסווג נכון את הנתונים $\{(\phi(x_i), y_i)\}_{i=1}^n$ לכל d אפשרי.
4. הוכח שעבור בעיית הזוגיות, אלגוריתם ה- $k - NN$ (עבור ערך k בודד או יותר) לא יסווג נכון דוגמת מבחן שאינה מופיעה בסט האימון, אם יש לה שכן עם מרחק (אוקלידי) קטן או שווה ל-1. רמז: חשוב כמה ביטים שונים בין דוגמת המבחן לבין השכן הקרוב ביותר שלה.

פתרון:

א. בהינתן אוסף דטה-סט $\{(x_i, y_i)\}_{i=1}^n$ כך שלכל $i \in [n]$ $x_i \in \mathbb{R}^d$ וכן $y_i \in \{+1, -1\}$ נגדיר את האלגוריתם באופן הבא. נשים לב כי בהינתן הפתרון הדואלי ניתן לכתוב את w^* כצ"ל של x ו- y . כלומר,

$$w = \sum_{i=1}^n \alpha_i y_i x_i$$

כלומר, בעת שמבצעים עדכון

$$\text{Sign}(w^T \phi(x_j)) = \text{Sign}\left(\sum_{i=1}^n \alpha_i y_i \phi(x_i) \cdot \phi(x_j)\right) = \text{Sign}\left(\sum_{i=1}^n \alpha_i y_i K(x_i, x_j)\right)$$

בהינתן ההבנה הזו נכתוב את הפסודו קוד הבא:

Kernel-Preceptron($\{(x_i, y_i)\}_{i=1}^n$)

א. אתחל $\alpha_1, \dots, \alpha_n \rightarrow 0$

ב. בצע עד להתכנסות ($\hat{y}_i = y_i$ לכל i):

ג. לכל $1 \leq i \leq n$:

- חזה $\hat{y}_i = \text{Sign} \left(\sum_{j=1}^n \alpha_j y_j K(x_j, x_i) \right)$

- אם $\hat{y}_i \neq y_i$: $\alpha_i = \alpha_i + 1$

ד. בסיום, השב $\alpha_1, \dots, \alpha_n$

ב'. יהי הדטה-סט המתאים

$$S = \{((0, 0), -1), ((1, 1), -1), ((0, 1), 1), ((1, 0), 1)\}$$

נניח בשלילה שקיים וקטור משקולות $w \in \mathbb{R}^2$ וסקלר $b \in \mathbb{R}$ שמסווגים נכון את הדטה. כלומר, לכל i : $y_i(w^T x_i - b) \geq 0$

נסמן $w = (w_1, w_2)$. נעבור נקודה נקודה בדטה.

- עבור הראשונה (קוראים משמאל), נקבל $0 \geq (w_1 \cdot 0 + w_2 \cdot 0 - b) \cdot (-1)$ כלומר $b \geq 0$

- עבור השלישית $0 \geq w_2 - b$

- עבור הרביעית $0 \geq w_1 - b$

נתבונן בנקודה השנייה. היא אמורה להיות מסווגת כשלילית. אבל,

$$w_1 + w_2 = (w_1 - b) + (w_2 - b) \geq 0$$

כלומר,

$$w_1 + w_2 - 2b \geq 0$$

אך, $b \geq 0$. לכן,

$$w_1 + w_2 - b \geq w_1 + w_2 - 2b \geq 0$$

כלומר, $w_1 + w_2 - b \geq 0$. אז בדיוק המשוואה המתאימה לנקודה השנייה $(1, 1)$. אך זו אמורה להיות מסווגת כשלילית. לכן, בהכרח נקבל

סתירה. לא קיים וקטור משקולות וסקלר b שמפרידים את הדטה, כנדרש.

ג'. נשים לב לאבחנה הבאה. בדינו וקטור $x \in \{0, 1\}^d$. אנו מעוניינים:

- אם מס' האחדות זוגי, להחזיר -1 .

- אם מס' האחדות אי זוגי, להחזיר 1 .

נסמן את הוקטור ב $x = (x_1, \dots, x_d)$. אם נסכום את מס' הביטים, ונבצע $\text{mod } 2$ נשים לב:

אם קיבלנו אחד - משמעות הדבר כי הערך שקיבלנו הינו אי זוגי במקור. לכן, מס' האחדות הינו אי זוגי. לכן במקרה זה נרצה להחזיר 1 (מה

שקיבלנו).

אם קיבלנו 0 : משמעות הדבר שהערך שקיבלנו הינו זוגי במקור. לכן, נרצה לתייג -1 . כיצד נתגבר על הפער הנ"ל? הרי צריך להחזיר במיפוי

במקרה זה -1 . נגדיר זאת כפונקציית אינדיקטור. נגדיר כעת את המיפוי הבא לכל d : $\phi(x) : \mathbb{R}^d \rightarrow \mathbb{R}$ ע"י:

$$\phi(x) := \left(\sum_{i=1}^d x_i \right) \bmod 2 - 1 \cdot \mathbb{I} \left[\left(\sum_{i=1}^d x_i \right) \bmod 2 = 0 \right]$$

ברור מדוע המיפוי עובד לפי ההסבר לעיל, ולכן כעת הפרספטרון כן יתכנס ויסווג נכון את הדטה $\{(\phi(x_i), y_i)\}_{i=1}^n$. שכן, כעת $\phi(x_i)$ מחזיק

עבורו את התשובה על זוגיות האחדות. לכן פשוט עבור $b = 0$ ו $w = 1$ נקבל כי $\phi(x_i) = w^T \phi(x_i) + b = 1 \cdot \phi(x_i) = \phi(x_i)$.

ד. נוכיח שאלגוריתם kNN עבור $k = 1$ לא יסווג נכון דוגמת מבחן שאינה מופיעה בסט האימון אם יש לה שכן עם מרחק אוקלידי קטן שווה

1.

נשים לב, אלגוריתם kNN בוחר את השכן הקרוב ביותר לדוגמה. תהי דוגמה x_i כזו. אלגוריתם $1NN$ מסווג לפי השכן הקרוב ביותר נסמנו

x_j כלומר

$$j = \arg \min_{k \in [n]} \|x_i - x_k\|$$

נתון כי אותו השכן, מקיים כי $\|x_i - x_k\| \leq 1$. הרי כי: כיוון שנתון שהמרחק הנ"ל הוא לכל היותר 1 , נטען כי הוא בהכרח לפחות 1 .

שכן, כל שכן x_k לא יכול להיות x_i בעצמו, לכן הוא שונה ממנו לפחות בביט אחד. כיוון שנתון שהמרחק קטן שווה 1 , בהכרח ביט אחד שונה

בלבד מפריד בין x_i ל x_k . אלגוריתם kNN במקרה זה יסווג את x_i כתשובה של x_k , אך בהכרח מס' האחדות של x_i שונה ממס' האחדות של x_k

במקרה זה - כי המרחק ביניהם בדיוק 1 . למעשה, האלגוריתם היה מסווג במקרה זה נכון אם היה מחזיר בדיוק את התשובה ההפוכה לזה של x_k .

בכל מקרה, הוכחנו את הנדרש.

מועד ג' 2024 - Backpropagation

נרצה לסווג תמונות RGB בהם ג'ירפה יכולה להופיע (1) או לא להופיע (0) בעזרת רשת ניורונים עמוקה. אנו בונים רשת עם הארכיטקטורה הבאה:

$$z_1^{(i)} = W_1 x^{(i)} + b_1$$

$$a_1^{(i)} = \text{ReLU}(z_1^{(i)})$$

$$z_2^{(i)} = W_2 a_1^{(i)} + b_2$$

$$\hat{y}^{(i)} = \sigma(z_2^{(i)})$$

$$L^{(i)} = ay^{(i)} \cdot \log(\hat{y}^{(i)}) + \beta \cdot (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$$

פונקציית המטרה שלנו היא $J = \frac{-1}{m} \sum_{i=1}^m L^{(i)}$ המימדים הם:

$$y^{(i)}, \hat{y}^{(i)} \in \mathbb{R}, x^{(i)} \in \mathbb{R}^{D_x}, W_1 \in \mathbb{R}^{D_{a1} \times D_x}, W_2 \in \mathbb{R}^{1 \times D_{a1}}$$

בנוסף, תמונת RGB משוטחת לוקטורים בגודל D_x לפני שמזינים אותה לרשת.

א. מהם המימדים של b_1, b_2 ?

ב. בהינתן העובדה שהדטה-סט מכיל 200 תמונות עם ג'ירפה ו-2000 בלי, הביאו ערכים טובים ל- α, β .

ניתן להניח כי בעולם האמיתי, מס' התמונות בכל מחלקה שווה.

רמז: נרצה כי Loss יהיה ממושקל בהתאם למצב האמיתי.

ג. מצאו את כללי העדכון לכל הפרמטרים בבעיה, הניחו כי אנחנו משתמשים ב- GD .

ד. אנו מחליטים להוסיף רגולרזציה L_2 עם מקדם $\lambda > 0$ לפונקציית המטרה הנוכחית שלנו. כתבו את פונקציית העלות החדשה ואת כלל העדכון החדש עבור W_1 . האם תשובתכם לסעיף ב' תשתנה במקרה זה?

פתרון:

א. נתחיל מ- b_1 . נשים לב כי $z_1^{(i)} = W_1 x^{(i)} + b_1$ וכן $x^{(i)} \in \mathbb{R}^{D_x}$ וכן $W_1 \in \mathbb{R}^{D_{a1} \times D_x}$. לכן $W_1 x^{(i)} \in \mathbb{R}^{D_{a1}}$ וכך גם:

$$b_1 \in \mathbb{R}^{D_{a1}}$$

כעת גם $a_1^{(i)} \in \mathbb{R}^{D_{a1}}$. מכאן $W_2 \in \mathbb{R}^{1 \times D_{a1}}$ ולכן $W_2 a_1^{(i)} \in \mathbb{R}$ ולכן $b_2 \in \mathbb{R}$.

ב. בדטה סט יש 2200 תמונות. אנו רוצים שה- Loss יהיה ממושקל בהתאם. במצב האמיתי של העולם, נתון שמש' הדגימות עם ובלי ג'ירפה זהה. לכן נרצה כי:

$$\alpha = \frac{\frac{1}{2}}{\frac{200}{2200}} = \frac{2200}{400} = 5.5$$

$$\beta = \frac{\frac{1}{2}}{\frac{2000}{2200}} = \frac{2200}{4000} = \frac{11}{20} = 0.55$$

ג. עלינו לגזור כללי עדכון ביחס ללוס עבור W_1, W_2, b_1, b_2 . נתחיל:

$$\frac{dL^{(i)}}{db_2} = \frac{dL^{(i)}}{d\hat{y}^{(i)}} \cdot \frac{d\hat{y}^{(i)}}{dz_2^{(i)}} \cdot \frac{dz_2^{(i)}}{db_2} = \left(\frac{ay^{(i)}}{\hat{y}^{(i)}} - \beta \cdot (1 - y^{(i)}) \cdot \frac{1}{1 - \hat{y}^{(i)}} \right) \cdot \sigma(z_2^{(i)}) \cdot (1 - \sigma(z_2^{(i)})) \cdot 1$$

מכאן:

$$\frac{dL}{db_2} = -\frac{1}{m} \sum_{i=1}^m \left(\frac{ay^{(i)}}{\hat{y}^{(i)}} - \beta \cdot (1 - y^{(i)}) \cdot \frac{1}{1 - \hat{y}^{(i)}} \right) \cdot \sigma(z_2^{(i)}) \cdot (1 - \sigma(z_2^{(i)}))$$

לכן:

$$b_2 = b_2 + \frac{\eta}{m} \sum_{i=1}^m \left(\frac{ay^{(i)}}{\hat{y}^{(i)}} - \beta \cdot (1 - y^{(i)}) \cdot \frac{1}{1 - \hat{y}^{(i)}} \right) \cdot \sigma(z_2^{(i)}) \cdot (1 - \sigma(z_2^{(i)}))$$

אבל נשים לב כי $\hat{y}^{(i)} = \sigma(z_2^{(i)})$ לכן דברים מצטמצמים ונקבל:

$$b_2 = b_2 + \frac{\eta}{m} \sum_{i=1}^m \left(ay^{(i)}(1 - \hat{y}^{(i)}) - \beta \cdot (1 - y^{(i)}) \cdot \hat{y}^{(i)} \right)$$

נתקדם:

$$\frac{dL}{dW_2}^{(i)} = \frac{dL}{d\hat{y}^{(i)}} \cdot \frac{d\hat{y}^{(i)}}{dz_2^{(i)}} \cdot \frac{dz_2^{(i)}}{dW_2} = \left(\frac{ay^{(i)}}{\hat{y}^{(i)}} - \beta \cdot (1 - y^{(i)}) \cdot \frac{1}{1 - \hat{y}^{(i)}} \right) \cdot \sigma(z_2^{(i)}) \cdot (1 - \sigma(z_2^{(i)})) \cdot a_1^{(i)}$$

$$W_2 = W_2 + \frac{\eta}{m} \sum_{i=1}^m \left(ay^{(i)}(1 - \hat{y}^{(i)}) - \beta \cdot (1 - y^{(i)}) \cdot \hat{y}^{(i)} \right) a_1^{(i)}$$

ונמשיך בדרכנו:

$$\frac{dL}{db_1}^{(i)} = \frac{dL}{d\hat{y}^{(i)}} \cdot \frac{d\hat{y}^{(i)}}{dz_2^{(i)}} \cdot \frac{dz_2^{(i)}}{da_1^{(i)}} \cdot \frac{da_1^{(i)}}{dz_1^{(i)}} \cdot \frac{dz_1^{(i)}}{db_1} = \frac{ay^{(i)}}{\hat{y}^{(i)}} - \beta \cdot (1 - y^{(i)}) \cdot \frac{1}{1 - \hat{y}^{(i)}} \cdot W_2 \cdot \frac{\vartheta ReLu(z_1^{(i)})}{\vartheta z_1^{(i)}} \cdot 1$$

(הערה: נשאיר את הנגזרת של $ReLU$ ככה, לפי הנחיות המתרגלים). מכאן:

$$b_1 = b_1 + \frac{\eta}{m} \sum_{i=1}^m \left(ay^{(i)}(1 - \hat{y}^{(i)}) - \beta \cdot (1 - y^{(i)}) \cdot \hat{y}^{(i)} \right) \cdot W_2 \frac{\vartheta ReLu(z_1^{(i)})}{\vartheta z_1^{(i)}}$$

וכן לסיום:

$$\frac{dL}{dW_1}^{(i)} = \frac{dL}{d\hat{y}^{(i)}} \cdot \frac{d\hat{y}^{(i)}}{dz_2^{(i)}} \cdot \frac{dz_2^{(i)}}{da_1^{(i)}} \cdot \frac{da_1^{(i)}}{dz_1^{(i)}} \cdot \frac{dz_1^{(i)}}{dW_1} = \frac{ay^{(i)}}{\hat{y}^{(i)}} - \beta \cdot (1 - y^{(i)}) \cdot \frac{1}{1 - \hat{y}^{(i)}} \cdot W_2 \cdot \frac{\vartheta ReLu(z_1^{(i)})}{\vartheta z_1^{(i)}} \cdot x^{(i)}$$

$$W_1 = W_1 + \frac{\eta}{m} \sum_{i=1}^m \left(ay^{(i)}(1 - \hat{y}^{(i)}) - \beta \cdot (1 - y^{(i)}) \cdot \hat{y}^{(i)} \right) \cdot W_2 \frac{\vartheta ReLu(z_1^{(i)})}{\vartheta z_1^{(i)}} x_i^{(i)}$$

ד'.

במקרה זה נסמן את הפונקציה הקודמת ב- L ונקבל שהפונקציה החדשה הינה

$$L = L + \lambda (||W_1||^2 + ||W_2||^2 + ||b_1||^2 + ||b_2||^2)$$

הגזירה תהיה כמו קודם רק שיצטרף גם $2W_1$.

7 מבחן 2025 מועד א'

שאלה 1

בשאלה זו נמצא חסמים לערך של הפרמטר במודל רגרסיה לוגיסטית, עבור איחוד של שני דטה-סט. נסתכל על אימון מודלי רגרסיה לוגיסטית עבור שני דטה-סט עם תיוגים בינאריים:

$$D_1 = \{(x_i^{(1)}, y_i^{(1)})\}_{i=1}^n, D_2 = \{(x_i^{(2)}, y_i^{(2)})\}_{i=1}^n$$

באשר $y_i^{(1)}, y_i^{(2)} \in \{0, 1\}$ וכן $x_i^{(2)}, x_i^{(1)} \in \mathbb{R}_{\geq 0}$ לשם הפשטות, נניח כי הדטה-סט זרים.

א. יש לפתח את Loss בבעיית הרגרסיה הלוגיסטית, כלומר NLL תחת ההנחה שהוא מופעל על הדטה-סט הראשון.
ב. יש להשתמש בכלל השרשרת על מנת למצוא את הגרדיאנט של Loss ולהוכיח שהוא שווה ל:

$$\nabla Err_{D_1}(w) = - \sum_{i=1}^n x_i^{(1)} (y_i^{(1)} - \sigma(wx_i^{(1)}))$$

ג. יש להראות כי הגרדיאנט של השגיאה הוא מונוטוני עולה כפונקציה של w . כלומר אם $w^1 > w^2$ אזי $\nabla Err_{D_1}(w^1) > \nabla Err_{D_2}(w^2)$.
ד. יהי $w^{(1)}$ הפתרון לבעיית הרגרסיה הלוגיסטית המתקבל מאימון על D_1 ויהי $w^{(2)}$ הפתרון המתקבל מאימון על D_2 . יהי w^* הפתרון

המתקבל מאימון על $D_1 \cup D_2$.

i. יש להראות כי $\nabla Err_{D_1 \cup D_2}(w^*) = \nabla Err_{D_1}(w^*) + \nabla Err_{D_2}(w^*)$
ii. יש להראות כי אם $w^* < \min(w^{(1)}, w^{(2)})$ אזי $\nabla Err_{D_1 \cup D_2}(w^*) < 0$
iii. יש להראות כי אם $w^* > \max(w^{(1)}, w^{(2)})$ אזי $\nabla Err_{D_1 \cup D_2}(w^*) > 0$
לאורך כל הסעיף מתקיים כמובן $\min(w^{(1)}, w^{(2)}) \leq w^* \leq \max(w^{(1)}, w^{(2)})$.
פתרון:

א. ובכן, נתבונן על Log-Likelihood. לפני כן נפתח את ההפסד. נקבל:

$$L(w) = \prod_{y_i^{(1)}=1} \Pr[y_i^{(1)} = 1 | x_i^{(1)}] \prod_{y_i^{(1)}=0} \Pr[y_i^{(1)} = 0 | x_i^{(1)}]$$

$$L(w) = \prod_{i=1}^n \Pr[y = 1 | x_i^{(1)}]^{y_i^{(1)}} \Pr[y = 0 | x_i^{(1)}]^{1-y_i^{(1)}}$$

כעת נתבונן על NLL . נקבל:

$$L(w) = - \sum_{i=1}^n y_i^{(1)} \log(\Pr[y = 1 | x_i^{(1)}]) + (1 - y_i^{(1)}) \cdot \log(\Pr[y = 0 | x_i^{(1)}])$$

ב. כעת, נפתח לפי כלל השרשרת. נטפל בכל איבר בודד כלומר נגזור את

$$y_i^{(1)} \log(\Pr[y = 1 | x_i^{(1)}]) + (1 - y_i^{(1)}) \cdot \log(\Pr[y = 0 | x_i^{(1)}])$$

ואז בגלל שזה סכום נקבל – על סכום של הגזירות. ובכן: לפני כן נזכר כי: $\Pr[y_i^{(1)} = 1 | x_i^{(1)}] = \sigma(w^T x_i^{(1)})$. נסמן $\sigma_i = \sigma(w^T x_i^{(1)})$. מכאן נקבל:

$$y_i^{(1)} \cdot \frac{1}{\sigma_i} \cdot \sigma_i (1 - \sigma_i) x_i^{(1)} + (1 - y_i^{(1)}) \cdot \frac{1}{1 - \sigma_i} \cdot (-1) \cdot \sigma_i \cdot (1 - \sigma_i) x_i^{(1)}$$

$$y_i \cdot (1 - \sigma_i) x_i^{(1)} - (1 - y_i^{(1)}) \cdot \sigma_i x_i^{(1)} =$$

$$(y_i - y_i^{(1)} \sigma_i - \sigma_i + y_i^{(1)} \sigma_i) x_i^{(1)}$$

$$(y_i - \sigma(w^T x_i^{(1)}))x_i^{(1)}$$

לכן סה"כ קיבלנו כי הגרדיאנט הינו:

$$\nabla Err_{D_1}(w) = - \sum_{i=1}^n x_i^{(1)} \cdot (y_i - \sigma(w^T x_i^{(1)}))$$

ג'. נוכיח שגרדיאנט השגיאה מונוטוני. נרצה להוכיח כי מתקיים עבור $w_1 > w_2$ כי

$$x_i^{(1)} \cdot (y_i - \sigma(w_1^T x_i^{(1)})) < x_i^{(1)} \cdot (y_i - \sigma(w_2^T x_i^{(1)}))$$

ובכן: כיוון ש σ (סיגמואיד) היא פונקציה מונוטונית, נקבל כי $\sigma(w_1^T x_i^{(1)}) > \sigma(w_2^T x_i^{(1)})$. לכן,

$$-\sigma(w_1^T x_i^{(1)}) < -\sigma(w_2^T x_i^{(1)}) \implies y_i - \sigma(w_1^T x_i^{(1)}) < y_i - \sigma(w_2^T x_i^{(1)})$$

וזה גורר (כי $x_i^{(1)} \geq 0$) כי $x_i^{(1)} \cdot (y_i - \sigma(w_1^T x_i^{(1)})) < x_i^{(1)} \cdot (y_i - \sigma(w_2^T x_i^{(1)}))$ מכאן,

$$\sum_{i=1}^n x_i^{(1)} \cdot (y_i - \sigma(w_1^T x_i^{(1)})) < \sum_{i=1}^n x_i^{(1)} \cdot (y_i - \sigma(w_2^T x_i^{(1)}))$$

וע"י הכפלה ב-1 נקבל:

$$-\sum_{i=1}^n x_i^{(1)} \cdot (y_i - \sigma(w_1^T x_i^{(1)})) > -\sum_{i=1}^n x_i^{(1)} \cdot (y_i - \sigma(w_2^T x_i^{(1)}))$$

$$\nabla Err_{D_1}(w_1) > \nabla Err_{D_1}(w_2)$$

כלומר גרדיאנט השגיאה מונוטוני, כנדרש.

ד'. ובכן, יהי $w^{(1)}$ הפתרון לבעיית הרגרסיה הלוגיסטית המתקבל מאימון על D_1 ויהי $w^{(2)}$ הפתרון המתקבל מאימון על D_2 . יהי w^* הפתרון המתקבל מאימון על $D_1 \cup D_2$. נכתוב את Loss על $D_1 \cup D_2$. הרי הוא

$$L(w) = \prod_{y_i^{(1)}=1} \Pr[y_i^{(1)}=1|x_i^{(1)}] \prod_{y_i^{(1)}=0} \Pr[y_i^{(1)}=0|x_i^{(1)}] \prod_{y_i^{(2)}=1} \Pr[y_i^{(2)}=1|x_i^{(2)}] \prod_{y_i^{(2)}=0} \Pr[y_i^{(2)}=0|x_i^{(2)}]$$

לאחר הפעלת NLL נקבל למעשה:

$$L(w) = \sum_{i=1}^n y_i^{(1)} \log(\Pr[y_i^{(1)}=1|x_i^{(1)}]) + (1 - y_i^{(1)}) \cdot \log(\Pr[y_i^{(1)}=0|x_i^{(1)}]) +$$

$$y_i^{(2)} \log(\Pr[y_i^{(2)}=1|x_i^{(2)}]) + (1 - y_i^{(2)}) \cdot \log(\Pr[y_i^{(2)}=0|x_i^{(2)}])$$

בעצם זה בדיוק הגרסה הקודמת, כאשר נגזור (לא נעשה זאת שוב, זה בדיוק כמו סעיף ב') נקבל:

$$\nabla Err_{D_1 \cup D_2}(w) = - \sum_{i=1}^n x_i^{(1)} \cdot (y_i - \sigma(w^T x_i^{(1)})) + x_i^{(2)} \cdot (y_i - \sigma(w^T x_i^{(2)})) =$$

$$- \sum_{i=1}^n x_i^{(1)} (y_i - \sigma(w^T x_i^{(1)})) - \sum_{i=1}^n x_i^{(2)} \cdot (y_i - \sigma(w^T x_i^{(2)})) = \nabla Err_{D_1}(w) + \nabla Err_{D_2}(w)$$

בפרט, הנגזרת תמיד שווה לסכום הנגזרות, לכן בפרט כשנציב את w^* נקבל:

$$\nabla Err_{D_1 \cup D_2}(w^*) = \nabla Err_{D_1}(w^*) + \nabla Err_{D_2}(w^*)$$

ii. נניח כי $w^* < \min(w^{(1)}, w^{(2)})$. נרצה להוכיח כי $\nabla Err_{D_1 \cup D_2}(w^*) < 0$. ובכן לפי סעיף קודם מתקיים

$$\nabla Err_{D_1 \cup D_2}(w^*) = \nabla Err_{D_1}(w^*) + \nabla Err_{D_2}(w^*)$$

מכאן, בהכרח מתקיים $w^* < w^{(1)}, w^* < w^{(2)}$ (כי קטן מהמינימלי שבהם). לכן מתקיים מסעיף ג' שבו ראינו כי הגרדיאנט מונוטוני כי:

$$\nabla Err_{D_1}(w^*) < \nabla Err_{D_1}(w^{(1)}) = 0$$

שכן זה שווה 0 כי זה הפתרון האופטימלי שבפרט מאפס את הגרדיאנט כולו. באופן דומה נקבל

$$\nabla Err_{D_2}(w^*) < \nabla Err_{D_2}(w^{(2)}) = 0$$

לכן סה"כ נקבל

$$\nabla Err_{D_1 \cup D_2}(w^*) = \nabla Err_{D_1}(w^*) + \nabla Err_{D_2}(w^*) < 0 + 0 = 0$$

כנדרש.

iii. בעצם זה מאוד דומה לסעיף הקודם. כעת מתקיים $w^* > \max(w^{(1)}, w^{(2)})$ ובפרט גדול משניהם. לכן, לפי סעיף ג' ומונוטוניות נקבל

$$\nabla Err_{D_1}(w^*) > \nabla Err_{D_1}(w^{(1)}) = 0$$

שכן זה שווה 0 כי זה הפתרון האופטימלי שבפרט מאפס את הגרדיאנט כולו. באופן דומה נקבל

$$\nabla Err_{D_2}(w^*) > \nabla Err_{D_2}(w^{(2)}) = 0$$

לכן סה"כ נקבל

$$\nabla Err_{D_1 \cup D_2}(w^*) = \nabla Err_{D_1}(w^*) + \nabla Err_{D_2}(w^*) > 0 + 0 = 0$$

שאלה 2

בשאלה זו נראה כי Naive Bayes עם שונות זהה לכל המחלקות הוא מפריד לינארי. יהיו $x = (x_1, \dots, x_d) \in \mathbb{R}^d$ ו $Y \in \{0, 1\}$. נסמן את Priors כ

$$\Pr[Y = 0] = \pi_0 = 1 - \pi_1, \Pr[Y = 1] = \pi_1$$

עבור כל מחלקה $c \in \{0, 1\}$ ופיצ'ר $j \in \{1, \dots, d\}$ נניח כי

$$\Pr[x_j | Y = c] = \mathcal{N}(\mu_{c,j}, \sigma_j^2)$$

כלומר, לכל מחלקה $\mu_{c,j}$ הדגימות מתפלגות נורמלית עם ממוצע של המחלקה ושונות זהה לכל המחלקות. שונות זו יכולה להיות שונה עבור פיצ'רים שונים. בנוסף נניח אי תלות מותנית של הפיצ'רים בהינתן המחלקה.

א. כתבו את Conditional log-likelihood כלומר, $\text{Log}(\Pr(x|Y=c))$ כתלות ב $x_j, \mu_{0,j}, \mu_{1,j}, \sigma_j^2$.

ב. מצאו את Log-Posterior-ratio כלומר $\log\left(\frac{\Pr(Y=1|x)}{\Pr(Y=0|x)}\right)$. בטאו תשובתכם כפונקציה של $x_j, \mu_{0,j}, \mu_{1,j}, \sigma_j^2$.

ג. בהתבסס על הסעיפים הקודמים, הוכיחו כי מודל Naive Bayes במקרה זה הוא מפריד לינארי. בטאו את Decision Boundary בצורה מפורשת כתלות בפרמטרים של המודל, ודאו כי אתם מגדירים את כלל ההחלטה בצורה מפורשת והצדיקו פורמלית את תשובתכם. פתרון:

א. למעשה נראה כי

$$\begin{aligned} \Pr[x|Y=c] &= \text{Independent} \prod_{j=1}^d \Pr[x_j|Y=c] = \prod_{j=1}^d \mathcal{N}(\mu_{c,j}, \sigma_j^2) \\ &= \prod_{j=1}^d \frac{1}{\sqrt{2\pi} \cdot \sigma_j} \cdot \exp\left(-\frac{1}{2} \left(\frac{x_j - \mu_{c,j}}{\sigma_j}\right)^2\right) \end{aligned}$$

מכאן:

$$\begin{aligned} \log(\Pr[x|Y=c]) &= \log\left(\prod_{j=1}^d \frac{1}{\sqrt{2\pi} \cdot \sigma_j} \cdot \exp\left(-\frac{1}{2} \left(\frac{x_j - \mu_{c,j}}{\sigma_j}\right)^2\right)\right) = \\ &= \sum_{j=1}^d \log\left(\frac{1}{\sqrt{2\pi} \cdot \sigma_j}\right) - \frac{1}{2} \left(\frac{x_j - \mu_{c,j}}{\sigma_j}\right)^2 \end{aligned}$$

ב.

לפי חוק ביס נראה כי

$$\frac{\Pr(Y=1|x)}{\Pr(Y=0|x)} = \frac{\frac{\Pr(x|Y=1)\Pr(Y=1)}{\Pr(x)}}{\frac{\Pr(x|Y=0)\Pr(Y=0)}{\Pr(x)}} = \frac{\Pr(x|Y=1)\Pr(Y=1)}{\Pr(x|Y=0)\Pr(Y=0)} = \frac{\Pr(x|Y=1)}{\Pr(x|Y=0)} \cdot \frac{\pi_1}{\pi_0}$$

מכאן:

$$\log\left(\frac{\Pr(Y=1|x)}{\Pr(Y=0|x)}\right) = \log\left(\frac{\Pr(x|Y=1)}{\Pr(x|Y=0)} \cdot \frac{\pi_1}{\pi_0}\right) = \log(\Pr(x|Y=1)) - \log(\Pr(x|Y=0)) + \log\left(\frac{\pi_1}{\pi_0}\right)$$

הרי לפי סעיף קודם: $\log(\Pr(x|Y=c)) = \sum_{j=1}^d \log\left(\frac{1}{\sqrt{2\pi} \cdot \sigma_j}\right) - \frac{1}{2} \left(\frac{x_j - \mu_{c,j}}{\sigma_j}\right)^2$ מכאן נקבל:

$$\log(\Pr(x|Y=1)) - \log(\Pr(x|Y=0)) =$$

$$\left(\sum_{j=1}^d \log\left(\frac{1}{\sqrt{2\pi} \cdot \sigma_j}\right) - \frac{1}{2} \left(\frac{x_j - \mu_{1,j}}{\sigma_j}\right)^2\right) - \left(\sum_{j=1}^d \log\left(\frac{1}{\sqrt{2\pi} \cdot \sigma_j}\right) - \frac{1}{2} \left(\frac{x_j - \mu_{0,j}}{\sigma_j}\right)^2\right)$$

$$= \sum_{j=1}^d \frac{1}{2} \left(\frac{x_j - \mu_{0,j}}{\sigma_j}\right)^2 - \frac{1}{2} \left(\frac{x_j - \mu_{1,j}}{\sigma_j}\right)^2 =$$

$$\frac{1}{2} \cdot \sum_{j=1}^d \frac{(x_j - \mu_{0,j})^2 - (x_j - \mu_{1,j})^2}{\sigma_j^2}$$

$$= \frac{1}{2} \cdot \sum_{j=1}^d \frac{x_j^2 - 2x_j\mu_{0,j} + \mu_{0,j}^2 - x_j^2 - \mu_{1,j}^2 + 2x_j\mu_{1,j}}{\sigma_j^2} =$$

$$\frac{1}{2} \sum_{j=1}^d \frac{\mu_{0,j}^2 - \mu_{1,j}^2 + 2x_j(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2}$$

לכן סה"כ נקבל

$$\log\left(\frac{\pi_1}{\pi_0}\right) + \frac{1}{2} \sum_{j=1}^d \frac{\mu_{0,j}^2 - \mu_{1,j}^2 + 2x_j(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2}$$

ג. לפי הגדרה, מתקיים כי מודל Naive-Bayes יסווג את הדוגמה x כאחד אם ורק אם $\Pr(Y = 1|x) > \Pr(Y = 0|x)$. זה שקול לכך ש

$$\frac{\Pr(Y = 1|x)}{\Pr(Y = 0|x)} > 1 \iff \log\left(\frac{\Pr(Y = 1|x)}{\Pr(Y = 0|x)}\right) > 0$$

כיוון Loge מונוטונית עולה. מכאן, למעשה לפי הסעיף הקודם יסווג כאחד אמ"מ

$$\log\left(\frac{\pi_1}{\pi_0}\right) + \frac{1}{2} \sum_{j=1}^d \frac{\mu_{0,j}^2 - \mu_{1,j}^2 + 2x_j(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2} > 0$$

כעת אנחנו נסדר את הביטוי על מנת שיהיה מהצורה $w^T x + b > 0$ ובכך נתמקד ב-

$$\frac{1}{2} \sum_{j=1}^d \frac{\mu_{0,j}^2 - \mu_{1,j}^2 + 2x_j(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2} =$$

$$\frac{1}{2} \sum_{j=1}^d \frac{\mu_{0,j}^2 - \mu_{1,j}^2}{\sigma_j^2} + \sum_{j=1}^d \frac{(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2} x_j$$

סה"כ אם

$$\log\left(\frac{\pi_1}{\pi_0}\right) + \frac{1}{2} \sum_{j=1}^d \frac{\mu_{0,j}^2 - \mu_{1,j}^2}{\sigma_j^2} + \sum_{j=1}^d \frac{(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2} x_j > 0$$

נסמן $b = \log\left(\frac{\pi_1}{\pi_0}\right) + \frac{1}{2} \sum_{j=1}^d \frac{\mu_{0,j}^2 - \mu_{1,j}^2}{\sigma_j^2}$. נשים לב שזהו קבוע. מכאן:

$$\sum_{j=1}^d \frac{(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2} x_j + b > 0$$

כעת, נגדיר לכל $j \in [d]$ את $\beta_j = \frac{(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2}$. נשים לב כי

$$\sum_{j=1}^d \beta_j x_j + b > 0$$

נבחין כי ה- $\sum$ זו מכפלה פנימית. נגדיר את הוקטור $w = (\beta_1, \beta_2, \dots, \beta_d)^T$. אזי,

$$w^T x + b > 0$$

סה"כ עבור

$$b = \log\left(\frac{\pi_1}{\pi_0}\right) + \frac{1}{2} \sum_{j=1}^d \frac{\mu_{0,j}^2 - \mu_{1,j}^2}{\sigma_j^2}$$

$$w = \left(\left\{ \frac{(\mu_{1,j} - \mu_{0,j})}{\sigma_j^2} \right\}_{j=1}^d \right)^T$$

קיבלנו שמדובר במפריד לינארי.

שאלה 3

בשאלה זו ננתח את השקילות בין אלגוריתם K-means לבין EM. יהיו $x_1, \dots, x_n \in \mathbb{R}^d$ דוגמאות בלתי תלויות ובעלות התפלגות זהה iid , שנוצרו ממודל תערובת גאוסיאנית (GMM) עם פרמטרים

$$\theta = (\pi_k, \Sigma_k, \mu_k; k = 1, \dots, K)$$

בכיתה ראינו כי פונקציית Likelihood של GMM היא:

$$L(\theta) = p_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \sum_{k=1}^K \pi_k \mathcal{N}(x_i; \mu_k, \Sigma_k)$$

באשר

$$\mathcal{N}(x_i; \mu_k, \Sigma_k) = \frac{1}{\sqrt{(2\pi)^d \det(\Sigma_k)}} \exp\left(-\frac{1}{2}(x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k)\right)$$

א. כעת נוסיף משתנים בינאריים חבויים $z_i = (z_{i,1}, \dots, z_{i,K})$ שמצביעים על השייך לאשכולות. כתבו את פונקציית Likelihood המלאה: $p_\theta(x_1, \dots, x_n)$.
 ב. הראו במפורש, בעזרת חוק בייס, שניתן לכתוב את Posterior כך:

$$q(z_{i,k} = 1) = p_\theta(z_{i,k} = 1 | x_i) = \frac{\pi_k \mathcal{N}(x_i; \mu_k, \Sigma_k)}{\sum_{\ell} \pi_\ell \mathcal{N}(x_i; \mu_\ell, \Sigma_\ell)}$$

מנקודה זו ואילך הניחו כי $\pi_k = \frac{1}{K}$ וכן $\Sigma_k = \sigma I$ עבור כל k .
 לכל דוגמה x_i , נניח כי קיימת מחלקה בודדת k_i^* שה Mean שלה הכי קרוב ל x_i . כלומר, $k_i^* = \arg \min_k \|x_i - \mu_k\|$.
 כתבו במפורש את Posterior עבור הגבול בו $\sigma \rightarrow 0$ והראו כי ההסתברויות הן בינאריות (כלומר, 1 עבור המחלקה k_i^* ו 0 עבור כל מחלקה אחרת).
 ג. כתבו את אלגוריתם K-means. במקרה בסוף סעיף ב' כאשר $\sigma \rightarrow 0$ תקבעו את התנאי עבורו E-step מסעיף ב' שקול לשלב הראשון באלגוריתם K-means. תחת תנאי זה, הראו כי E-step (סעיף ב') שקול לשלב הראשון באלגוריתם K-means.
 ד. זכרו כי הנוסחה M-step

$$\mu_k^{(new)} = \frac{\sum_{i=1}^n q(z_{i,k} = 1) x_i}{\sum_{i=1}^n q(z_{i,k} = 1)}$$

עבור המקרה שבסוף סעיף ב', וכאשר $\sigma \rightarrow 0$ הראו כי שלב M שקול לשלב השני באלגוריתם K-means.
 הסיקו כי אלגוריתם EM מבצע את אותם שלבים כמו אלגוריתם K-means.

פתרון:

א. נשים לב כי ראינו בהרצאה כי

$$L(\theta) = p_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \sum_{k=1}^K \pi_k \mathcal{N}(x_i; \mu_k, \Sigma_k)$$

כעת, יהיו $z_i = (z_{i,1}, \dots, z_{i,K})$ אוסף משתנים חבויים (לכל $1 \leq i \leq n$). למעשה לכל $i \in [n]$ ו $j \in [K]$ מתקיים כי $z_{ij} = 1$ אם ורק אם הדוגמה i משויכת לאשכול j . בנוסף לכל i $\sum_{j=1}^K z_{ij} = 1$ כמובן. כעת, נשים לב כי לפי הגדרה

$$L(\theta) = p_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \Pr(x_i)$$

נשים לב - בהינתן x_i , לפי נוסחת ההסתברות השלמה אכן ניתן לכתוב מצד אחד

$$\Pr(x_i) = \sum_{k=1}^K \pi_k \cdot \mathcal{N}(x_i; \mu_k, \Sigma_k)$$

אך מצד שני, בהינתן שאנו יודעים את המחלקה הנ"ל Z_{ij} . הרי שערך זה יתאפס לכל j שאיננו המחלקה. לכן ניתן לכתוב זאת באופן הבא:

$$\Pr(x_i) = \pi_{k^*} \cdot \mathcal{N}(x_i; \mu_{k^*}, \Sigma_{k^*}) = \prod_{k=1}^K (\pi_k \cdot \mathcal{N}(x_i; \mu_k, \Sigma_k))^{Z_{i,k}}$$

ולכן סה"כ

$$L(\theta) = \prod_{i=1}^n \prod_{k=1}^K (\pi_k \cdot \mathcal{N}(x_i; \mu_k, \Sigma_k))^{z_{i,k}}$$

ב'. נראה כי לפי חוק בייס מתקיים:

$$q(z_{i,k} = 1) = p_\theta(z_{i,k} = 1|x_i) = \frac{\Pr(x_i|z_{i,k} = 1) \cdot \Pr(z_{i,k} = 1)}{\Pr(x_i)}$$

כפי שראינו קודם לפי נוסחת ההסתברות השלמה

$$\Pr(x_i) = \sum_{k=1}^K \pi_k \cdot \mathcal{N}(x_i; \mu_k, \Sigma_k)$$

וכן $\Pr(z_{i,k} = 1) = \pi_k$ וכן $\Pr(x_i|z_{i,k} = 1) = \mathcal{N}(x_i; \mu_k, \Sigma_k)$ כפי שהוגדר בתחילה לכן נקבל סה"כ

$$q(z_{i,k} = 1) = p_\theta(z_{i,k} = 1|x_i) = \frac{\mathcal{N}(x_i; \mu_k, \Sigma_k) \cdot \pi_k}{\Pr(x_i) = \sum_{j=1}^K \pi_j \cdot \mathcal{N}(x_i; \mu_j, \Sigma_j)}$$

כעת, אנו מניחים כי $\pi_k = \frac{1}{K}$ וכן $\Sigma_k = \sigma I$ עבור כל k .
נרצה להתבונן ב- $\mathcal{N}(x_i; \mu_j, \Sigma_j)$ לפי הנוסחה בתחילה

$$\mathcal{N}(x_i; \mu_j, \Sigma_j) = \frac{1}{\sqrt{(2\pi)^d \det(\Sigma_j)}} \exp\left(-\frac{1}{2}(x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j)\right)$$

נסדרו. ובכן מתקיים כי $\Sigma_k^{-1} = (\sigma I)^{-1} = \frac{1}{\sigma} I$ וכן $\det(\Sigma_j) = \det(\sigma I) = \sigma^d$. מכאן: נפתח ונקבל

$$\mathcal{N}(x_i; \mu_j, \Sigma_j) = \frac{1}{\sqrt{(2\pi\sigma)^d}} \exp\left(-\frac{1}{2\sigma}(x_i - \mu_j)^T (x_i - \mu_j)\right)$$

ובכן Posterior הינו:

$$\Pr(z_{i,k} = 1) = \frac{\mathcal{N}(x_i; \mu_k, \Sigma_k) \cdot \pi_k}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(x_i; \mu_j, \Sigma_j)} = \pi_k = \frac{1}{K} \forall k$$

$$\Pr(z_{i,k} = 1) = \frac{\mathcal{N}(x_i; \mu_k, \Sigma_k)}{\sum_{j=1}^K \mathcal{N}(x_i; \mu_j, \Sigma_j)}$$

נחלק למקרים. נניח ראשית שאנו מתבוננים על המחלקה k הנכונה. כלומר, k הכי קרוב ל- x_i . נרצה להוכיח כי במקרה זה $\Pr(z_{i,k} = 1)$. ובכן, בכל מקרה נחלק את המונה הן במונה והן במכנה. כלומר:

$$\Pr(z_{i,k} = 1) = \frac{1}{1 + \sum_{j \neq k} \frac{\mathcal{N}(x_i; \mu_j, \Sigma_j)}{\mathcal{N}(x_i; \mu_k, \Sigma_k)}}$$

ננתח את האיבר הבודד:

$$\frac{\mathcal{N}(x_i; \mu_j, \Sigma_j)}{\mathcal{N}(x_i; \mu_k, \Sigma_k)} = \frac{\frac{1}{\sqrt{(2\pi\sigma)^d}} \exp\left(-\frac{1}{2\sigma}(x_i - \mu_j)^T (x_i - \mu_j)\right)}{\frac{1}{\sqrt{(2\pi\sigma)^d}} \exp\left(-\frac{1}{2\sigma}(x_i - \mu_k)^T (x_i - \mu_k)\right)} = \frac{\exp\left(-\frac{1}{2\sigma} \|x_i - \mu_j\|^2\right)}{\exp\left(-\frac{1}{2\sigma} \|x_i - \mu_k\|^2\right)} =$$

$$\frac{\mathcal{N}(x_i; \mu_j, \Sigma_j)}{\mathcal{N}(x_i; \mu_k, \Sigma_k)} = \exp\left(\frac{1}{2\sigma} \cdot (\|x_i - \mu_k\|^2 - \|x_i - \mu_j\|^2)\right)$$

ננתח

$$\lim_{\sigma \rightarrow 0} \exp \left(\frac{1}{2\sigma} \cdot (||x_i - \mu_k||^2 - ||x_i - \mu_j||^2) \right)$$

נשים לב כי כאשר k הנ"ל אכן הדוגמה האמיתית, הרי שמתקיים $||x_i - \mu_k|| < ||x_i - \mu_j||$ ולכן:

$$||x_i - \mu_k||^2 - ||x_i - \mu_j||^2 < 0$$

מכאן נקבל כי ערך זה קטן מאפס, לכן:

$$\lim_{\sigma \rightarrow 0} \exp \left(\frac{1}{2\sigma} \cdot (||x_i - \mu_k||^2 - ||x_i - \mu_j||^2) \right) \rightarrow \exp(-\infty) = 0$$

כאשר k הנ"ל הוא לא הדוגמה האמיתית, במקרה זה היחס בניהם ישאף ל- ∞ . מכאן נקבל:

$$\Pr(z_{i,k} = 1) = \frac{1}{1 + \sum_{j \neq k} \frac{\mathcal{N}(x_i; \mu_j, \Sigma_j)}{\mathcal{N}(x_i, \mu_k, \Sigma_k)}} \rightarrow \begin{cases} \frac{1}{1 + \sum 0} & k = k^* \\ \frac{1}{1 + \sum \infty} & o.w \end{cases} \rightarrow \begin{cases} 1 & k = k^* \\ 0 & o.w \end{cases}$$

כנדרש.

ג'. נתחיל מכתובת הפסודו של K-means. ובכן:

K-means($\{x_i\}_{i=1}^n \in \mathbb{R}^d, K \in \mathbb{N}$)

א. בחר באופן אקראי צנטרואידים $\mu_1, \dots, \mu_K$.

ב. בצע עד להתכנסות (עד שלכל $i \in [n]$ מתקיים $(x_i) = \text{cluster}^{(t+1)}(x_i)$)

- חשב לכל $i \in [n]$ את הצנטרואיד הקרוב ביותר אליו:

$$\text{cluster}^{(t)}(x_i) = \arg \min_j ||x_i - \mu_j||^2$$

- לכל $i \in [k]$ הגדר:

$$c_i = \{x_j | \text{cluster}^{(t)}(x_j) = i\}$$

- לכל $i \in [k]$ הגדר:

$$\mu_i = \frac{1}{|c_i|} \sum_{x \in c_i} x$$

ג. בסיום, החזר $(\mu_1, \dots, \mu_K)$

ובכן, התנאי עבורו E-step מסעיף ב' שקול לשלב הראשון (אצלנו זה חישוב הקלאסטרס) באלגוריתם הוא התנאי הבא:

- לכל i קיים k_i^* אשר הוא הכי קרוב אליו יחיד!

תחת התנאי הזה קיבלנו בסעיף הקודם כי E-step מקיים:

$$\Pr(z_{i,k} = 1) = \frac{1}{1 + \sum_{j \neq k} \frac{\mathcal{N}(x_i; \mu_j, \Sigma_j)}{\mathcal{N}(x_i, \mu_k, \Sigma_k)}} = \begin{cases} 1 & k = k^* \\ 0 & o.w \end{cases} \rightarrow \begin{cases} 1 & k = k^* \\ 0 & o.w \end{cases}$$

כלומר, הוא מקיים כי הוא נדרש לחשב בכל שלב את המרחקים $||x_i - \mu_k||^2 - ||x_i - \mu_j||^2$ ולמצוא את זה שהכי קרוב לדוגמה x_i . כיוון שלפי התנאי הוא יחיד, יתקיים כי ההסתברות עבורו שואפת ל-1 ואחרת אפס (בינארית).

ד. ובכן, השלב השני באלגוריתם K-means הינו הגדרת המרכזים. לכל $k \in [K]$ מגדירים

$$\mu_k^{(t)} = \frac{1}{|c_i|} \cdot \sum_{x \in c_i} x$$

נשים לב כי לפי סעיף ב', מתקיים באופן קשיח כי $q(z_{i,k} = 1) = 1 \vee 0$. כלומר, הסתברות בינארית. לכן נוסחת M-step שהרי הינה:

$$\mu_k^{(new)} = \frac{\sum_{i=1}^n q(z_{i,k} = 1) x_i}{\sum_{i=1}^n q(z_{i,k} = 1)}$$

מצמטמצת לתנאי של חלוקת הממוצע. שכן נקבל כי עבור אלו ש $q(z_{i,k} = 1)$ אלו אותם x_i השייכים לקלאסטר k , ונקבל:

$$\mu_k^{(t)} = \frac{\sum_{i=1}^n q(z_{i,k} = 1) x_i}{\sum_{i=1}^n q(z_{i,k} = 1)} = \frac{\sum_{x \in c_k} x}{|c_k|}$$

לכן סה"כ זה בדיוק השלב השני ב-K-means.

אם כן, הוכחנו בסעיף ג' כי השלב הראשון של EM (E) הוא שקול לשלב הראשון של K-means וכעת הוכחנו שקילות על השלב השני, לכן סה"כ הם מבצעים אותם שלבים. כנדרש.

8 מבחן 2025 מועד ב

שאלה 1

בשאלה זו נבחן הבדלים בין מודלים לינאריים שונים.

א. הגדירו בצורה פורמלית את בעיית הרגרסיה הלינארית עם פונקציית מטרה MSE עבור קלט d מימדים. ציינו את התנאי שבו לרגרסיה לינארית קיים פתרון אופטימלי יחיד, תחת תנאי זה ספקו את הפתרון האופטימלי הסגור (אין צורך להראות איך מגיעים אליו).

ב. בהינתן אוסף של זוגות קלטים $x_i = (x_{i,1}, x_{i,2}) \in \mathbb{R}^2$ והפלטות התואמים $y_i \in \mathbb{R}$, כלומר $S_n = \{(x_i, y_i)\}_{i=1}^n$ אנו מציעים את המודל הבא:

$$\hat{y}_i = w_1^2 x_{i,1} + w_2^2 x_{i,2}$$

עבור $w_1, w_2 \in \mathbb{R}$. מצאו את סט הערכים האופטימליים של w_1 עבור MSE ועבור w_2 נתון.

ג. כעת יהיו $x_i \in \mathbb{R}$ ו $y_i \in \mathbb{R}$ ונניח שיש גישה לכמות בלתי מוגבלת של מידע. אנו מציעים את זוג המודלים הבאים:

$$\text{Model A: } y = w^2 x, w \in \mathbb{R}$$

$$\text{Model B: } y = wx, w \in \mathbb{R}$$

תחת אילו תנאים (של הנתונים) מודל A יהיה עדיף על מודל B? תחת אילו תנאים B יהיה עדיף? ד. עבור הנתונים של סעיף ג', אנו מציעים כעת להחליף את מודל A במודל חדש:

$$\text{Model C: } y = w_1^2 x + w_2 x$$

עבור $w_1, w_2 \in \mathbb{R}$.

כמה סטים של פרמטרים אופטימליים יש לכל אחד מהמודלים B ו C? שנמצאו באמצעות GD, לשני הפתרונות יש שגיאת אימון 0 ב MSE . כמה סביר שלמודל C תהיה שגיאת

הכללה טובה יותר ביחס למודל B? תזכורת: עבור התפלגות $\mathcal{D}$, אוסף פרמטרים w , ופונקציית הפסד ℓ שגיאת ההכללה מוגדרת להיות:

$$Err(w) = \mathbb{E}_{(x,y) \in \mathcal{D}} [\ell(h_w; x, y)]$$

פתרון:

א. בהינתן דטה-סט $\{(x_i, y_i)\}_{i=1}^n$ כך שלכל $i \in [n]$ מתקיים $x_i \in \mathbb{R}^d, y_i \in \mathbb{R}$ בעית הרגרסיה מוגדרת להיות חיזוי וקטור משקולות $w \in \mathbb{R}^{d+1}$ (כך שהשורה הראשונה בו היא סקלר b) כך שנחזה פונקציה $f(x_i) = w^T x_i$. נגדיר מטריצה $X \in \mathbb{R}^{n \times d+1}$ כך שלכל $i \in [n]$:

$$R_i(X) = x_i^T$$

יהי $y = (y_1, \dots, y_n)^T \in \mathbb{R}^n$. נגדיר את הבעיה כבעיית האופטימיזציה הבאה:

$$\min_{w \in \mathbb{R}^{d+1}} \frac{1}{n} (Xw - y)^T (Xw - y)$$

לרגרסיה קיים פתרון אופטימלי יחיד אמ"מ $X^T X$ היא מטריצה הפיכה. תחת תנאי זה, הפתרון הסגור כפי שראינו בהרצאה הינו $\hat{w} = (X^T X)^{-1} X^T y$.

ב'. נתבונן בפונקציית ההפסד (MSE). הלוא היא

$$f(w_1) = \frac{1}{2} \sum_{i=1}^n (\hat{y}_i - y_i)^2 = \frac{1}{2} \sum_{i=1}^n (w_1^2 x_{i,1} + w_2^2 x_{i,2} - y_i)^2$$

נגזור את הביטוי לפי w_1 (נתון כי יש להתייחס ל w_2 כקבוע). מכאן,

$$\frac{df(w_1)}{dw_1} = \frac{1}{2} \sum_{i=1}^n 2 \cdot (w_1^2 x_{i,1} + w_2^2 x_{i,2} - y_i) \cdot 2w_1 x_{i,1}$$

$$\implies 2 \sum_{i=1}^n w_1^3 x_{i,1}^2 + w_1 w_2^2 x_{i,1} x_{i,2} - y_i w_1 x_{i,1} = 0$$

$$w_1^3 \sum_{i=1}^n x_{i,1}^2 + w_1 w_2^2 \sum_{i=1}^n x_{i,1} x_{i,2} - w_1 \sum_{i=1}^n y_i x_{i,1} = 0$$

$$w_1^2 \sum_{i=1}^n x_{i,1}^2 = \sum_{i=1}^n x_{i,1} y_i - w_2^2 \sum_{i=1}^n x_{i,1} x_{i,2}$$

$$w_1 \in \left(\pm \sqrt{\frac{\sum_{i=1}^n x_{i,1} y_i - w_2^2 \sum_{i=1}^n x_{i,1} x_{i,2}}{\sum_{i=1}^n x_{i,1}^2}} \right)$$

ג. נשים לב כי מודל A מקיים שהמקדם שלו תמיד יהיה חיובי, כלומר כאשר אכן יש קשר חיובי בין y ל x , תמיד, נעדיף להשתמש במודל A שמתאר יחס חיובי בין השניים. לעומת זאת, כאשר הקשר בין y ל x לא בהכרח חיובי, המודל הזה בעייתי לנו שכן הוא בהכרח יטעה. במקרה זה נעדיף להשתמש במודל B .
ד. נתחיל ממודל B . נתבונן על MSE . ובכן לפי:

$$f(w) = \sum_{i=1}^n (w x_i - y_i)^2$$

נגזור ונקבל

$$f(w) = 2 \sum_{i=1}^n (w x_i - y_i) x_i = 0 \implies w \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i y_i = 0 \implies w = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

כלומר, סט פרמטרים אופטימלי יחיד.
נעבור למודל C . שוב לפי MSE נקבל:

$$f(w) = \sum_{i=1}^n (w_1^2 x_i + w_2 x_i - y_i)^2$$

כאן נשים לב שיש לנו 2 פרמטרים. לכן נגזור בכל פעם לפי אחד אחר, ולשני נתייחס לקבוע. סה"כ נקבל זוג משוואות ונראה מה נוצר מהן.
נגזור לפי w_1 נקבל

$$f'(w) = 2 \sum_{i=1}^n 2 \cdot w_1 x_i (w_1^2 x_i + w_2 x_i - y_i) = 0 \implies w_1 \sum_{i=1}^n x_i (w_1^2 x_i + w_2 x_i - y_i) = 0$$

כעת, גזירה לפי הפרמטר השני w_2 מניב:

$$f'(w) = 2 \cdot \sum_{i=1}^n x_i \cdot (w_1^2 x_i + w_2 x_i - y_i) = 0 \implies \sum_{i=1}^n x_i (w_1^2 x_i + w_2 x_i - y_i) = 0$$

נשים לב כי ישנן 2 אפשרויות ממשוואה ראשונה. ראשונה, היא כי $w_1 = 0$. אז נקבל:

$$\sum_{i=1}^n x_i \cdot (w_2 x_i - y_i) = 0$$

$$w_2 \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i y_i = 0 \implies w_2 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

כלומר אוסף $(w_1 = 0, w_2 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2})$.

מקרה שני - הוא כזה שבו $\sum_{i=1}^n x_i (w_1^2 x_i + w_2 x_i - y_i) = 0$. במצב זה $w_1 \cdot 0 = 0$ תמיד. לכן, נשים לב שאם נפתור את המשוואה השנייה נקבל:

$$w_1^2 \sum_{i=1}^n x_i^2 + w_2 \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i y_i = 0$$

$$w_2 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} - w_1^2$$

במקרה זה, לכל בחירה של w_1 נוכל לחשב את w_2 המתאים הנגזר מקשר זה. לכן, ישנם אנסוף סטים אופטימליים של פרמטרים.

ה. לא סביר. נראה כי מודל C מקיים $y = (w_1^2 + w_2)x$. יכול לסמל כל פרמטר סקלרי שהוא, באופן דומה למודל B עם $y = wx$. לכן, כיוון ששניהם השיגו 0 בשגיאת האימון, שניהם שקולים זה לזה ושגיאת ההכללה שלהם תהיה זהה.

שאלה 2

א. הגדירו באופן פורמלי את Soft-SVM (ללא Bias) כבעיית אופטימיזציה. בפרט, תן הסבר לכל משתנה. מה התפקיד של Tradeoff hyperparameter $C \in \mathbb{R}$ המסומן ב?

ב. נניח שהדוגמאות אורתונורמליות. כלומר $x_i^T x_j = 0$ ו-1 שווה $x_i^T x_j$ שווה 1 אם $i = j$ ו-0 אחרת. הוכיחו כי סט האימון $\{(x_i, y_i)\}_{i=1}^n$ הוא פריד לינארית. בפרט, הוכיחו כי המסווג הלינארי המושג ע"י

$$w = \sum_{j: y_j = +1} x_j - \sum_{j: y_j = -1} x_j$$

מפריד את המידע.

ג. סעיף זה אינו קשור לסעיף הקודם.

נניח כי המידע פריד לינארית. יהי $w^* \in \mathbb{R}^d$ הפתרון לגרסת Hard-SVM כך ש $\|w^*\|^2 > 0$. הוכיחו כי הפתרון של גרסת Soft-SVM מפריד לגמרי את המידע כאשר $C = \|w^*\|^2$. כלומר, יש שגיאת אפס תחת ה-Loss $0 - 1$. רמז: התבוננו בפתרון האופטימלי של גרסת Soft-SVM, בעזרת האופטימליות של פתרון זה תשוו בין ערכו תחת פונקציית המטרה של Soft-SVM לערך שמתקבל ע"י הפתרון האופטימלי של Hard-SVM תחת פונקציית המטרה של Soft-SVM.

פתרון:

א.

נגדיר את בעיית האופטימיזציה של Soft-SVM באופן הבא:

בהינתן דטה-סט: $\{(x_i, y_i)\}_{i=1}^n$ כך שלכל $i \in [n]$ מתקיים $x_i \in \mathbb{R}^d$ וכן $y_i \in \{-1, +1\}$. בהינתן $C \in \mathbb{R}$ נגדיר:

$$\min_{w \in \mathbb{R}^d, \xi_1, \dots, \xi_n} \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi_i \text{ s.t. } \forall i: \xi_i \geq 1 - y_i w^T x_i \wedge \xi_i \geq 0$$

באשר תפקיד ההיפר פרמטר C הינו להיות "הבורר" שקובע כמה אנחנו אוכפים את האילוצים. נבחין כי כל אילוף מקורי של Hard-SVM הינו $y_i w^T x_i \geq 1$. לכאן כאן אנחנו מרשים את ההפרה הזו, באמצעות משתני Slack ξ_i , שחיוביים ממש. תפקיד ההיפר פרמטר הוא לקבוע כמה נאכוף את האילוצים, אם הוא יהיה גדול אנחנו נאכוף אותם מאוד, ולא נרשה הפרות כלומר נתנהג בדומה ל-HARD-SVM. אם יהיה קטן יותר, נאפשר הפרות.

ב. נראה 2 פתרונות, זהים אך שונים בכיוון המחשבה שלהם.

יהיו הדוגמאות $\{(x_i, y_i)\}_{i=1}^n$ ויהי $B = \{x_1, \dots, x_n\}$ בסיס אורתונורמלי של הדטה. אזי, נקח $w = \sum_{i=1}^n \alpha_i x_i$ צ"ל של איברי הדטה. נרצה שיתקיים לכל דוגמה כי $y_i w^T x_i \geq 0$. ובכן:

$$w^T x_i = \left(\sum_{j=1}^n \alpha_j x_j \right)^T x_i = \sum_{j=1}^n \alpha_j x_j^T x_i = \sum_{j=1}^n \alpha_j \langle x_j, x_i \rangle$$

נשים לב כי לכל $j \neq i$ ביטוי זה מתאפס. לכן נקבל שערכו: $\alpha_i \|x_i\|^2$. כלומר,

$$y_i w^T x_i = y_i \alpha_i \|x_i\|^2$$

נרצה שביטוי זה יהיה גדול מאפס תמיד. לכן נגדיר $\alpha_i = y_i$. כעת יתקיים:

$$y_i w^T x_i = y_i^2 \|x_i\|^2 \geq 0$$

לכל i . כלומר, המסווג $w = \sum_{i=1}^n y_i x_i$ מסווג נכון את הדטה. כנדרש. פתרון ב'. למעשה, מדובר בפתרון כמעט סימטרי אך שעושה ישירות שימוש ברמז. נשים לב כי:

$$w = \sum_{j: y_j = +1} x_j - \sum_{j: y_j = -1} x_j = \sum_{i=1}^n x_i y_i$$

מכאן,

$$y_i w^T x_i = y_i \left(\sum_{j=1}^n x_j y_j \right)^T x_i = y_i \sum_{j=1}^n y_j x_j^T x_i = y_i \cdot y_i \cdot \|x_i\|^2 > 0$$

ושוב, שיקולים לפי דוגמה קודמת וכו'.

ג'. ובכן, תהי פונקציית המטרה של Hard-SVM

$$\min_{w \in \mathbb{R}^d} \frac{1}{2} \|w\|^2 \text{ s.t } \forall i : y_i w^T x_i \geq 1$$

אזי, w^* המקיים $\|w^*\|^2 > 0$ הינו הפתרון האופטימלי. נתבונן ב-Soft-SVM ובכן:

$$\min_{w \in \mathbb{R}^d, \xi_1, \dots, \xi_n} \frac{1}{2} \|w\|_2^2 + \|w^*\|^2 \sum_{i=1}^n \xi_i \text{ s.t } \forall i : \xi_i \geq 1 - y_i w^T x_i \wedge \xi_i \geq 0$$

נשים לב כי המידע פריד לינארית, לפי הנתון. יהי $\hat{w}$ פתרון של Soft-SVM. לפי הגדרה, נשים לב כי בהכרח מתקיים

$$\frac{1}{2} \|\hat{w}\|_2^2 + \|w^*\|^2 \sum_{i=1}^n \xi_i \leq \frac{1}{2} \|w^*\|^2$$

נסדר ונקבל:

$$\frac{1}{2} \|\hat{w}\|_2^2 \leq \left(\frac{1}{2} - \sum_{i=1}^n \xi_i \right) \|w^*\|^2$$

כיוון ש $\xi_i \geq 0$, וגם $\|w^*\|^2 > 0$, וכך גם $\frac{1}{2} \|\hat{w}\|_2^2 \geq 0$ נשים לב כי בהכרח $\frac{1}{2} - \sum_{i=1}^n \xi_i \geq 0$, כלומר

$$\frac{1}{2} \geq \sum_{i=1}^n \xi_i$$

כיוון ש $\xi_i \geq 0$, משמעות הדבר כי לכל i מתקיים $\frac{1}{2} \geq \xi_i$.

מכאן, לכל i :

$$\frac{1}{2} \geq \xi_i \geq 1 - y_i (w')^T x_i$$

$$y_i (w')^T x_i \geq \frac{1}{2} > 0$$

ולכן לכל i אכן עם w' המידע פריד לינארית, כנדרש.

שאלה 3

א. יהיו $x, z \in \mathbb{R}^2$. הוכח כי הפונקציה הבאה היא קרנל:

$$K(x, z) = (1 + x^T z)^2$$

כמה פעולות חישוביות נשמרו ע"י חישוב הקרנל במקום מכפלות פנימיות של Feature maps?

- ב. נתון דטה-סט $\{(x_i, y_i)\}_{i=1}^n$ כאשר לכל $x_i \in \mathbb{R}^d$ וכן $y_i \in \{+1, -1\}$. כתוב פסאודו קוד עבור אלגוריתם הפרספטרון, כמו כן כתבו את אלגוריתם פרספטרון כאופטימיזציה SGD עבור Hinge Loss (עם Zero-margin). שימו לב להגדיר את כל המשתנים.
- ג. הניחו כי ממפים את הדוגמאות מסעיף ב' למימד גבוה יותר $D \gg d$ ע"י Feature mapping הנתון ע"י $\phi : \mathbb{R}^d \rightarrow \mathbb{R}^D$ ואז מקבלים את וקטורי הפיצ'רים $\{\phi(x_i)\}_{i=1}^n$. עדכנו את הפסאודו קוד מסעיף ב' כדי לקבל אלגוריתם דמוי פרספטרון שזכות פועל על $\phi(x_1), \dots, \phi(x_n)$. הראו כי המשקולות הם צירוף לינארי של $y_1 \phi(x_1), \dots, y_n \phi(x_n)$ כלומר קיימים קבועים $\alpha_1, \dots, \alpha_n$ כך ש $w = \sum_{i=1}^n \alpha_i y_i \phi(x_i)$.
- ד. ניתן להשתמש ב Feature mapping מסעיף ג' על מנת להגדיר פונקציית קרנל, המסומנת ע"י $K(x, x') = \phi(x)^T \phi(x')$. עדכנו את הפסדודו-קוד מסעיף ג' כדי לקבל אלגוריתם דמוי-פרספטרון שמשמש בקרנל טריק ע"י החלפת w עם $w = \sum_{i=1}^n \alpha_i y_i \phi(x_i)$ כן שהפרמטרים הנלמדים הם $\alpha_1, \dots, \alpha_n$.

פתרון:

א. הרי שנצטרך אל $\binom{2+2}{2} = \frac{4!}{2!2!} = 6$ ובכן נסמן $x = (x_1, x_2), z = (z_1, z_2)$ מכאן:

$$x^T z = (x_1 z_1 + x_2 z_2)$$

$$(1 + x_1 z_1 + x_2 z_2)^2 = 1 + 2x_1 z_1 + x_1^2 z_1^2 + 2x_2 z_2 + 2x_2 z_2 x_1 z_1 + x_2^2 z_2^2$$

נגדיר

$$\phi(x) : \mathbb{R}^2 \rightarrow \mathbb{R}^6$$

$$\phi(x_1, x_2) := \begin{pmatrix} 1 \\ \sqrt{2}x_1 \\ x_1^2 \\ \sqrt{2}x_2 \\ \sqrt{2}x_1 x_2 \\ x_2^2 \end{pmatrix}$$

- והרי שמתקיים כעת $K(x, z) = \phi(x)^T \phi(z)$. לכן מדובר בקרנל חוקי. נשים לב כי אם היינו זקוקים לבצע חישוב מכפלות פנימיות היה עולה הדבר $6^2 = 36$. לעומת זאת, החישוב $1 + x^T z$ תוך 4 פעולות (או 5 אם נחשיב את החיבור של 1) והעלאה בריבוע פעולה נוספת, כלומר כ-6 פעולות. כלומר לינארי לעומת ריבועי. משמעותי.
- ב. נכתוב פסודו קוד ראשית עבור הפרספטרון המקורי. בהינתן דטה סט $\{(x_i, y_i)\}_{i=1}^n$ כך שלכל $x_i \in \mathbb{R}^d$ וכן $y_i \in \{+1, -1\}$ נגדיר: $\text{Perceptron}(\{(x_i, y_i)\}_{i=1}^n)$.
- א. אתחל וקטור משקולות $w \in \mathbb{R}^d$ באופן אקראי.
- ב. לכל $1 \leq i \leq n$ בצע (עד שלכל i יתקיים $y_i = \hat{y}_i$):
- חשב $\hat{y}_i = \text{sign}(w^T x_i)$.
 - אם $\hat{y}_i \neq y_i$:
1. אם $y_i > 0$ בצע $w = w + x_i$
 2. אם $y_i < 0$ בצע $w = w - x_i$
 - ג. בסיום, החזר את w .
- כעת, נתבונן בפונקציית Hinge Loss. נסמנה

$$\ell(w, x_i, y_i) := \max(0, -y_i w^T x_i)$$

בהתאמה נגזרתה: כאשר $y_i w^T x_i > 0$ נגזרתה אפס, אחרת נגזרתה $-y_i x_i$.

נגדיר את האלגוריתם הבא:
 Preceptron-HingeLoss-SGD($\{(x_i, y_i)\}_{i=1}^n, \eta > 0$)
 א. אתחל וקטור משקולות אקראי $w \in \mathbb{R}^d$.
 ב. בצע עד שכל הדגימות מסווגות נכון:
 - בחר דוגמה אקראית (x_i, y_i) מהדטה-סט.
 - אם $y_i w^T x_i > 0$ התקדם לאיטרציה הבאה.
 - אחרת: $w = w + \eta y_i x_i$
 ג. בסיום, החזר את w .

סעיף ג'.

נעדכן את הפסודו באופן הבא:
 Precptron($\{(x_i, y_i)\}_{i=1}^n$)
 א. אתחל וקטור משקולות $w \in \mathbb{R}^d$ ל-0.
 ב. לכל $1 \leq i \leq n$ בצע (עד שלכל i יתקיים $y_i = \hat{y}_i$):
 - חשב $\hat{y}_i = \text{sign}(w^T \phi(x_i))$
 - אם $\hat{y}_i \neq y_i$:
 1. אם $y_i > 0$ בצע $w = w + \phi(x_i)$
 2. אם $y_i < 0$ אזי בצע $w = w - \phi(x_i)$
 ג. בסיום, החזר את w .

נשים לב שבכל שלב צעד העדכון הינו $w = w + y_i \phi(x_i)$. כיוון שעדכנו את האלגוריתם כך שיאותחל ל-0, נטען באינדוקציה כי בכל שלב של האלגוריתם (ובפרט בסיום האלגוריתם) מתקיים כי w הוא צ"ל של $\{y_i \phi(x_i)\}_{i=1}^n$.
 בסיס: צעד 0, בשלב זה וקטור המשקולות מאותחל ל-0 ואכן צ"ל באופן טריוואלי.
 צעד: נניח כי בצעד הקודם $w = \sum_{i=1}^n \alpha_i y_i \phi(x_i)$.
 נשים לב כי בצעד הנוכחי, נסמנו j מתקיים כי $w = w + y_j \phi(x_j)$. כלומר, מתקיים:

$$w = \sum_{i=1}^n \alpha_i y_i \phi(x_i) + y_j \phi(x_j)$$

זהו אכן צ"ל. נגדיר אלפאות חדשות β כך שלכל $j \neq i$ נגדיר $\beta_i = \alpha_i$ ואחרת נגדיר $\beta_i = \alpha_i + 1$. אזי יתקיים

$$w = \sum_{i=1}^n \beta_i y_i \phi(x_i)$$

וזהו צ"ל כנדרש.

ד. נשים לב כי לפי האבחנה מסעיף קודם, בכל שלב

$$\text{Sign}(w^T x_j) = \text{Sign}\left(\left(\sum_{i=1}^n \alpha_i y_i \phi(x_i)\right)^T x_j\right) = \text{Sign}\left(\sum_{i=1}^n \alpha_i y_i \phi(x_i)^T x_j\right) = \text{Sign}\left(\sum_{i=1}^n \alpha_i y_i K(x_i, x_j)\right)$$

תחת התבונה הזו נגדיר את האלגוריתם הבא:

Kernel-Preceptron($\{(x_i, y_i)\}_{i=1}^n$)

א. אתחל $\alpha_1, \dots, \alpha_n \rightarrow 0$.
 ב. בצע עד שאין השתפרות:
 ג. בחר באקראי דוגמה מהדטה-סט (x_j, y_j) .
 ד. חשב $\hat{y}_j = \text{Sign}\left(\sum_{i=1}^n \alpha_i y_i K(x_i, x_j)\right)$
 ה. אם $\hat{y}_j \neq y_j$ בצע $\alpha_j = \alpha_j + 1$.
 ו. בסיום, החזר $\{\alpha_i\}_{i=1}^n$.