

# סיכום מתומצת להסתברות

15 ביוני 2025

## מבוא

- \* **הסתברות מותנית:** נסמן כך -  $P(A|B)$  והמשמעות היא "מה הסיכוי של  $A$  בהינתן ש- $B$  קרה". הנוסחה -  $P(A|B) = \frac{P(A \cap B)}{P(B)}$ .
- \* **כלל הכללה והפרדה:**  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ .
- \* **משפט ההסתברות השלמה:** תהי חלוקה של מרחב המדגם  $\Omega$  למאורעות  $A_1, A_2, \dots, A_n$ . כמו כן, לכל  $i$  נתון  $P(A_i)$  וכן  $P(B|A_i)$ . אז -  $P(B) = \sum_{i=1}^n P(A_i) * P(B|A_i)$ .
- \* **כלל בייס:**  $P(A|B) = \frac{P(B|A)*P(A)}{P(B)}$
- \* **אי תלות:** תהי  $\Omega$  מרחב מדגם ויהיו  $A, B$  מאורעות. נאמר כי אלו מאורעות בלתי תלויים אם מתקיים  $P(A \cap B) = P(A) * P(B)$ .
- \* **נוסחת ברנולי:** הסתברות ל- $k$  הצלחות מתוך  $n$  נסיעות בהתפלגות בינומית כאשר ההסתברות להצלחה היא  $p$  היא -  $P_n(k) = \binom{n}{k} * p^k * (1-p)^{n-k}$ .

## משתנה רנדומי בדיד

- \* **פונקציית מסת ההסתברות:** נקראת גם  $PMF$ . משגיחת כל ערך להסתברות שמתאימה לו. מסומנת  $f$  לרוב ברציף  $x$  ו-  $p_x$  בבדיקה. כמובן  $\sum_x p_x = 1$ .
- \* **פונקציית הCDF / התפלגות:** נקראת  $CDF$  ומוגדרת להיות  $F_X(t) = P(x \leq t)$ . ככלומר, הסתברות לקבלת כל הערכים שקטנים מ- $t$ . כמובן  $P(x > t) = \overline{F_X(t)} = 1 - P(x \leq t)$ . וכן  $P(a < x \leq b) = F_x(b) - F_x(a)$

## משתנה ברנולי:

- \* **יסום**  $x \sim Ber(p)$  משתנה עם פרמטר  $p$  אם מתקיים שיש שתי אפשרויות בלבד - הצלחה או כשלון. במצב זה  $p$  סיכוי להצלחה ו-  $1-p$  לכשלון.
- \*  $E[X] = p$
- \*  $V[X] = p(1-p)$

## משתנה אחיד:

- \* **יסום**  $x \sim U[a, b]$  משתנה עם פרמטרים  $a \leq b$  כאשר המשתנה יכול לקבל את הערכים מ- $[a, b]$  בהסתברות שווה (למשל הטלתקוביה). ההסתברות למאורע תהיה  $\frac{1}{b-a+1}$ .
- \* **פונקציית מסת ההסתברות** תהיה קו מקביל לציר האיקס -  $P(x) = \frac{1}{b-a+1}$
- \*  $E[X] = \frac{a+b}{2}$
- \*  $Var[X] = \frac{(b-a+1)^2-1}{12}$
- \* **השונות** תהיה  $(b-a+1)^2$

## משתנה ביןומי:

יסומן גם  $n \sim Bin(n, p)$ .  $x$  הטלות בלתי תלויות כאשר הסיכוי להצלחה הוא  $p$ . במקרה כזה הסיכוי  $P_x(k) = \binom{n}{k} * p^k * (1-p)^{n-k}$ .

- \*  $E[X] = np$
- \*  $Var[X] = np(1-p)$

## משתנה גאומטרי:

יסומן גם  $x \sim Geo(p)$ . הטלת נוספת מטבעות בלתי תלויות, אם הסיכוי לקבלת תוצאה היא  $p$  אז המשתנה בודק את הסיכוי לקבלת תוצאה לאחר  $k$  פעמים.

- \*  $E[X] = \frac{1}{p}$  התוחלת משתנה גאומטרי (כולל ההצלחה) היא  $E[X] = \frac{1-p}{p}$ .
- \* טענה:  $P_{X-n|x>n}(k) = P_x(k)$  כשלוניות עד להצלחה (לא ההצלחה) היא  $P_x(k) = (1-p)^{k-1} * p$ .
- \* פונקציית מסת ההסתברות  $P_x(k) = \frac{1-p}{p^2}$
- \* השונות  $Var[X] = \frac{1-p}{p^2}$

## על תוחלת ושונות

**הגדלה של תוחלת:**  $E[c] = c$ . אם  $c$  קבועizi איזי  $E[X] = \sum_x x * P_x(X = x)$ .  $E[aX + b] = aE[X] + b$

**הגדלה של שונות:** כמה המשתנים המקרים רחוקים זה מזה.  $Var[x] = E[(X - E[X])^2]$ .

**טענה:**  $Var[aX + B] = a^2 Var[x]$

**טענה:**  $Var[x] = E[X^2] - (E[X])^2$

**סטיית תקן**  $\sigma_x = \sqrt{Var[X]}$

**התנייה של משתנה רנדומרי במאורע**  $P_{x|A}(x) = P(X = x|A) = \frac{P(\{X=x\} \cap A)}{P(A)}$

**משפט התוחלת השלמה** - נחלק את מרחב המדגם לקבוצות  $A_1, \dots, A_n$  ואז מתקיים כי  $E[X] = P(A_1) * E[X|A_1] + \dots + P(A_N) * E[X|A_N]$ .

**פונקציית מסת ההסתברות המשותפת:**  $P_{x,y}(x, y) = P(X = x \& Y = y)$ . כמובן, ההסתברות שנייה המשתנים קיבלו כל אחד את הערך שלו.

**תוחלת לשני משתנים:**  $E[X + Y] = E[X] + E[Y]$

**טענה חשובה:**  $E[E[X|Y]] = E[X]$

**תוחלת מותנית:**  $E[X|A] = \sum_x x p_{X|A}(x)$

**אי תלות בין מאורע ומשתנה מקרי:**  $\forall x, P(X = x \wedge A) = p(x) * p(A) = p(x) * p(A) = p_x(x)$

\* ב כדי להראות שמשתנים הם תלויים יש להראות דוגמה אחת בה השווין לא מתקיים. בשביל להראות אי תלות צריך לעבור על כל הזוגות האפשרים ולהראות שמתקיים השוויון.

\* אם  $X, Y$  בלתי תלויים איזי  $E[XY] = E[X] * E[Y]$  וכן  $Var[X + Y] = Var[X] + Var[Y]$

**שונות מותנית:**  $Var[X|Y] = E[(X - E[X|Y])^2|Y = y]$

**משפט השונות שלמה:**  $Var[x] = E[Var(X|Y)] + Var[E[X|Y]]$

**מניפולציה על משתנים מקרים:** בהינתן שני משתנים מקרים, נניח והגדרנו  $Z = X + Y$ . אז  $p_Z(z) = p(X + Y = z) = \sum_{(x,y)|x+y=z} P(X = x, Y = y) = \sum_x p(X = x, Y = z - x) = \sum_x p_X(x) * p_Y(z - x)$ .

## שונות משותפת:

תסומן  $Cov(X, Y)$  ותתאר את הקשר בין המשתנים. הערך עצמו פחות רלוונטי. אם קיבלנו כי הוא חיובי איז כל שאحد עולה השני עולה ואם שלילי איז כל שאחד עולה השני יורד. נגידר כך -

$Cov(X, Y) = E[(X - E[X])(Y - E[Y])]$

**הגדרה שקולה ונוחה יותר**  $Cov(X, Y) = E[XY] - E[X]E[Y]$ . **תכונות מעניינות** -

$$\begin{aligned}
Cov(X, X) &= E[X^2] - (E[X])^2 = Var(X) * \\
Cov(aX + b, Y) &= aCov(X, Y) * \\
Cov(X, Y + Z) &= Cov(X, Y) + Cov(X, Z) * \\
Var[\sum_{i=1}^n X_i] &= \sum_{i=1}^n Var[X_i] + \sum_{(i,j):i \neq j} Cov(X_i, X_j) * \\
Var[X + Y] &= VAR[X] + VAR[Y] + 2Cov(X, Y) * \\
\text{חשיבות מואוד} &- \rho(X, X) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} \text{ עבורו מתקיים } \rho(X, -X) = -1 \text{ וכן } \rho(X, X) = 1 \\
\text{מקדים המתאימים: נגידו כך} &\rho(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} \text{ ל민וס אחד. ככל שמקדם המתאים קרוב יותר לאחד, כך הקשר בין} \\
&\text{שני המשתנים קרוב לילינארי.}
\end{aligned}$$

### משתנה מקרי רציף

**פונקציית צפיפות ההסתברות:** תקרה כאן ותסומן כאן  $f_X$ .  $P(X < t) = P(X < t) = \int_{-\infty}^t f_x(x)dx$ .

**פונקציית הCDF:** תוגדר כאן להיות  $CDF$ .  $P_X(t) = \int_{-\infty}^t f_x(x)dx$ .

**חשיבות מתקיים:** קלומר אם נזור את  $CDF$  קיבל את  $(PMF)$ . וכן  $\rightarrow x \rightarrow \infty \Rightarrow F_X(x) = 1$  ו $x \rightarrow -\infty \Rightarrow F_X(x) = 0$ .

**תוחלת:**  $E[X] = \int_{-\infty}^{\infty} x f_x(x) dx$ .

**שונות:**  $Var[X] = \int_{-\infty}^{\infty} (x - E[X])^2 f_X(x) dx$ .

**פונקציית הסתברות בהינתן התנייה:**

$$f_{X|X \in A}(x) := \begin{cases} \frac{f_x(x)}{P(A)} & x \in A \\ 0 & x \notin A \end{cases}$$

**תוחלת מותנית:**  $E[X|A] = \int_{-\infty}^{\infty} x f_{X|A}(x) dx$

**משפט ההסתברות השלמה למשתנה רציף:**  $f_x(x) = P(A_1) * f_{X|A_1} + \dots + P(A_n) * f_{X|A_n}$

**משפט התוחלת השלמה למשתנה רציף:**  $E[X] = P(A_1)E[X|A_1] + \dots + P(A_n)E[X|A_n]$

### משתנה רציף אחיד

אם  $x \sim U[a, b]$ , אז  $PDF$  יהיה -

$$f_x(x) := \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & x > b \vee x < a \end{cases}$$

וכן  $CDF$  יהיה:

$$F(x) := \begin{cases} 0 & x \leq a \\ \frac{x-a}{b-a} & a < x < b \\ 1 & x \geq b \end{cases}$$

$$\begin{aligned}
E[X] &= \frac{a+b}{2} \\
\sigma(x) &= \sqrt{\frac{b-a}{12}}, \text{ וסטיית התקן} \\
Var[x] &= \frac{(b-a)^2}{12}
\end{aligned}$$

## משתנה מקרי מעריצי

יסומן  $(\lambda) \sim exp \sim x$ . מייצג את הזמן עד למאורע מסוים. כלומר - עד המאורע הראשון של אותו אירוע.

**פונקציית PDF :**

$$f_X(x) := \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

**פונקציית CDF :**

$$F_X(x) := \begin{cases} 1 - e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

\* **התוחלת** תהיה  $E[X] = \frac{1}{\lambda^2}$  וכן **השונות**  $Var[X] = \frac{1}{\lambda}$  וכך השונות  $E[X] = \frac{1}{\lambda}$  טענה:  $X$  חסר זכרון  $\iff \left\{ \begin{array}{l} x \sim G(p) \\ x \sim exp(\lambda) \end{array} \right\}$

## משתנה מקרי פואסוני

נסמן  $(\lambda) \sim Poi(x)$ . ישנו מאורע שיכל לקרות בכל רגע, אך יש את הנتون לכמה ממנה קורים ביחידת זמן מסוימת. המשטנה יגדיר את ההסתברות למופע אחד לאורך יחידת הזמן. חשוב לשים לב להגדיר היטב את יחידת הזמן ולפעול לפיה.

- \* פונקציית מסת ההסתברות - ההסתברות  $k$  מופעים בזמן הדגימה  $f_x(k) = e^{-\lambda} \frac{\lambda^k}{k!}$ .
- \* תוחלת ושונות:  $E[X] = Var[X] = \lambda$ .
- \* הקשר בין פואסוני למעריצי: אם נגדיר  $(\lambda) \sim Poi(X)$ , מס' מאורעות ביחידת זמן כאשר הצפי הוא  $\lambda$  מאורעות ביחידת זמן, נגדיר  $Y$  - זמן ההמתנה עד להתרחשות המאורע הראשון, אז  $Y \sim exp(\lambda)$ .

## משתנה מקרי נורמלי

לרוב בשאלות יהיה נתון לנו משתנה מתפלג נורמלי.

- \* **סטנדרטי:** התוחלת היא 0 והשונות היא 1 אזי  $N(0, 1)$ :  $f_x(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$  (או פונקציית הפעמון).
- \* **גaussini:** משתנה נורמלי כללי.  $N(\mu, \sigma^2) : f_x(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ .
- \* **טענה:** בהינתן  $(\mu, \sigma^2) : X \sim N(\mu, \sigma^2)$  אם נגדיר  $Y = aX + b$ ,  $E[Y] = a\mu + b$ ,  $Var[Y] = a^2\sigma^2$  וכן  $Y \sim N(a\mu + b, a^2\sigma^2)$ , כלומר הזזה לינארית של משתנה נורמלי הוא משתנה נורמלי.
- \* לא ניתן לבצע אינטגרל על פונקציית ההסתברות - איןנו ניתן לתאר באמצעות פונקציות אלמנטריות. לכן יש טבלה שטמפה ערכיהם. כלומר את  $\Phi(Y) = F_Y(y) = \int_{-\infty}^y \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}$
- \* **טענה:** תמיד מתקיים  $1 = \phi(X) + \phi(-x)$
- \* **כיצד עוברים ממשטנה נורמלי כלשהו לסטנדרטי על מנת להשתמש בטבלה?** נגדיר תמיד  $Y = \frac{X - E[X]}{\sigma[X]}$  שקיים  $N(0, 1) \sim Y$  וכן את אי השוויון שרצינו נתרגם במונחים של  $Y$ .

## משתנה מקרי מעורב

כאשר מתקיים

$$X := \begin{Bmatrix} Y & p \\ Z & 1-p \end{Bmatrix}$$

למשל, וכן  $Y$  בדיד ו $Z$  רציף, נקרא  $X$  משתנה מעורב. במקרה זה  $CDF$  יהיה

$$P_X(x) = pP(Y \leq x) + (1-p)P(Z \leq x) = pF_Y(y) + (1-p)F_Z(z)$$

### משתנים מקרים מרובים

**פונקציה** -  $P((X, Y) \in B) = \int \int_{(x,y) \in B} f(x, y) dx dy$

**מעבר PDF משותף לשולי:**  $f_y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx, f_x(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy$

**פונקציית מסת ההסתברות המשותפת:**  $P_X(x) = P(X < x) = \int_{-\infty}^x \int_{-\infty}^{\infty} f_{X,Y}(u, v) du dv$  (מדוע המשתנה  $x$ ?)

לע? יש משתנה באינטגרל  $x$ . את  $y$  יכלנו להשאיר אך בחרנו אחדות מחלוקת ושיםנו גם

**חשיבות** - תמיד מתקיים  $f_x(x) = \frac{dF_x(x)}{dx} = \int_{-\infty}^{\infty} f_{X,Y}(x, v) dv$

**פונקצייתCDF:**  $F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^y \int_{-\infty}^x f_{x,y}(u, v) du dv$

**חשיבות** - מתקיים  $\frac{\partial^2 F_{X,Y}(x,y)}{\partial x \partial y} = f_{X,Y}(x, y)$  אף פעם איקס ופעם אחת לפיה  $y$  קיבל את  $f_{X,Y}$ .

**התנייה:**  $f_X(x) = \int_{-\infty}^{\infty} f_{X|Y}(x|y) f_Y(y) dy = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy, f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$

**תוחלת בהtnייה:**  $E[X|Y = y] = \int_{-\infty}^{\infty} x f_{X|Y}(x|y) dx$

**אי תלות:** אם  $X$  ו $Y$  בלתי תלויים כלומר  $f_{X,Y}(x, y) = f_x(x) * f_Y(y)$ , אז  $E[XY] = E[X]E[Y]$  וכן  $VAR[X+Y] = VAR[X] + VAR[Y]$

**מינימולציה על משתנים מקרים רציפים:** אם  $Y$  אז  $Z = X + Y$

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx$$

### אי שוויונות

**אי שוויון מרקוב:** אם  $0 \geq X \geq a$  אז  $P(X \geq a) \leq \frac{E[X]}{a}$

**אי שוויון צ'בישב:** יהי  $X$  משתנה מקרי כך ש  $0 > C$ , אז  $P(|X - E[X]| \geq c) \leq \frac{Var[X]}{c^2}$

**החוק החלש של המספרים הגדולים:** נתונים  $X_1, \dots, X_n$  משתנים בלתי תלויים זהים (כלומר עם אותה התפלגות) עם תוחלת  $\mu$  וdispersion  $\sigma^2$ . כלומר לכל  $1 \leq i \leq n$  מתקיים  $E[X_i] = \mu$ . נסתכל על ממוצע המדגמים:  $M_n = \frac{X_1 + \dots + X_n}{n}$ ,  $E[M_n] = \frac{X_1 + \dots + X_n}{n}$  ונשים לב  $\mu$  ככל  $n \rightarrow \infty$  כאשר  $Var[M_n] = \frac{\sigma^2}{n}$ . אז,  $M_n$  מתקיים  $\rightarrow \infty$

$$P(|M_n - \mu| \geq \epsilon) = P\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| \geq \epsilon\right) \rightarrow 0$$

**משמעות החוק החלש:** חוזרים מס' רב של פעמים על אותו הניסוי. בכל שלב מקבלים תוצאה  $+W_i$  כך ש  $W_i$  בלתי תלויים, אז לא סביר שסכום המדגם יהיה גדול מהתוחלת באמת. לא סביר - הסתברות אפס.

**משפט הגבול המרכזי:** נתונים  $X_1, \dots, X_n$  משתנים בלתי תלויים זהים (כלומר עם אותה התפלגות) עם תוחלת  $\mu$  וdispersion  $\sigma^2$ . כלומר לכל  $1 \leq i \leq n$  מתקיים  $E[X_i] = \mu$ . נגיד  $X_1 + X_2 + \dots + X_n = S_n$ . אז  $S_n$  מתקיים  $E[S_n] = n\mu$  ו $Var[S_n] = n\sigma^2$ . נסתכל על  $Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}}$ .  $Z_n \sim N(0, 1)$ .

$$\forall z : \lim_{n \rightarrow \infty} P(Z_n \leq z) = P(Z \leq z) = \Phi(z)$$

מה החידוש כאן? לא משנה כיצד  $X_1, \dots, X_n$  התפלגו קודם לכן.  $Z_n$  תמיד יהיה משתנה מקרי נורמלי. לרוב נרצה לפתור  $P(S_n \leq a) \approx b$ . כאשר שניים יהיו נתונים ונרצה למצוא השלישי.  
**קירוב זה מועיאר לפלאס:**  $S_n \sim \text{Bin}(n, p)$  וכן  $k, l$  שלמים חיוביים. אז,

$$P(k \leq S_n \leq l) = \Phi\left(\frac{l + \frac{1}{2} - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k - \frac{1}{2} - np}{\sqrt{np(1-p)}}\right)$$